Incertitude des Large Language Models

ENSAE Paris – Société Générale

Projet de Statistique et Sciences des Données Appliquées

Auteurs

Kénan DARFILALI
Grégoire MARGUIER
William DÉJEAN
Samuel MACÉ

Année universitaire 2025–2026

Table des matières

1 Lien entre score de confiance et proximité à la vérité **1**
1.1 Motivation et cadre de l'analyse 1
1.2 Mesures de distance à la vérité 3
1.3 Définition des scores de confiance 4
1.4 Résultats 6
1.4.1 Dispersion des scores de confiance 6
1.4.2 Capacité de discrimination des scores de confiance 7
1.4.3 Calibration des scores probabilistes 7
1.4.4 Lien entre confiance et proximité à la vérité 8
1.4.5 Robustesse aux différentes mesures de distance 9

Annexes **10**

A Prompts utilisés **10**
A.1 Prompt pour la génération de la réponse et la confiance verbalisée . . . 10
A.2 Prompt pour le jugement externe (LLM-as-a-judge) 10

B Tableaux de résultats **12**

1 Lien entre score de confiance et proximité à la vérité

1.1 Motivation et cadre de l'analyse

L'un des objectifs de ce projet est de mieux comprendre ce que signifie réellement la *confiance* exprimée par un Large Language Model. Lorsqu'un modèle produit une réponse accompagnée d'un score de confiance élevé, on s'attend intuitivement à ce que cette réponse soit plus fiable ou plus proche de la vérité.

Une manière naturelle d'évaluer cette intuition consiste à comparer deux quantités : d'une part un score de confiance associé à la réponse du modèle, et d'autre part une mesure de distance entre cette réponse et la vérité. Si le score de confiance constitue un bon indicateur de fiabilité, on devrait alors observer que les réponses associées à une confiance élevée sont, en moyenne, plus proches de la vérité.

Cette idée semble a priori simple, mais elle repose implicitement sur une hypothèse importante : celle selon laquelle la proximité à la réponse correcte reflète effectivement la qualité du raisonnement ayant conduit à cette réponse. Or cette hypothèse n'est pas toujours vérifiée. Dans certains cas, une réponse peut être numériquement proche de la vérité tout en reposant sur un raisonnement incorrect, tandis qu'un raisonnement plus pertinent peut conduire à une réponse légèrement plus éloignée en raison d'une erreur locale.

Un exemple simple permet d'illustrer ce phénomène. Considérons la question suivante :

Combien de paires différentes peut-on former avec 10 personnes ?

La bonne réponse correspond au nombre de combinaisons de deux personnes parmi dix :

$$\binom{10}{2} = \frac{10 \times 9}{2} = 45.$$

Supposons maintenant que deux modèles produisent les réponses suivantes.

Un premier modèle interprète la question comme : *combien de paires peut-on former simultanément avec 10 personnes.* Dans ce cas, il raisonne de la manière suivante : chaque paire contient deux personnes, donc avec dix personnes on peut former $10/2 = 5$ paires. La réponse proposée est alors 5.

Un second modèle adopte un raisonnement combinatoire plus proche du problème posé. Il observe que l'on peut choisir une première personne parmi dix, puis une seconde parmi les neuf restantes, et conclut qu'il existe $10 \times 9 = 90$ paires possibles. Cette approche est structurellement proche du raisonnement correct, mais elle oublie que chaque paire est comptée deux fois.

Dans cet exemple, la réponse 5 est numériquement plus proche de la vérité que la réponse 90, bien qu'elle provienne d'une mauvaise compréhension du problème. À l'inverse, la réponse 90 résulte d'un raisonnement presque correct, mais conduit à une erreur plus importante.

Cet exemple met en évidence une difficulté fondamentale : la distance à la bonne réponse ne constitue pas nécessairement un indicateur fiable de la qualité du raisonnement sous-jacent. Autrement dit, une réponse peut être proche de la vérité pour de mauvaises raisons, et relativement éloignée pour de bonnes raisons.

Cette observation a une conséquence importante pour la construction de notre protocole expérimental. Si l'objectif est d'étudier la relation entre un score de confiance et la proximité à la vérité, il est nécessaire de travailler dans un cadre où la distance à la bonne réponse possède un sens interprétable.

Pour éviter cette ambiguïté, nous avons choisi de travailler sur des questions factuelles issues du dataset **TriviaQA**. Ces questions portent généralement sur des informations culturelles ou encyclopédiques bien définies (dates historiques, records, mesures, durées, etc.), pour lesquelles il existe une réponse correcte unique.

Nous avons cependant introduit une contrainte supplémentaire : nous avons conservé uniquement les questions dont la réponse attendue est un nombre. Ce filtrage permet de définir naturellement une notion de distance entre la réponse produite par le modèle et la vérité terrain.

Par exemple :

In what year were the Summer Olympic Games hosted in Montreal ?

La réponse correcte est : 1976

Dans ce type de question, une réponse comme 1975 ou 1977 est naturellement interprétée comme plus proche de la vérité qu'une réponse comme 1950. La distance numérique possède donc une signification claire et peut être utilisée comme une mesure d'erreur.

1.2 Mesures de distance à la vérité

Une fois le cadre expérimental défini, il reste à préciser comment mesurer l'écart entre la réponse produite par le modèle et la vérité terrain. Dans notre cadre, les réponses considérées sont des valeurs numériques, ce qui permet de définir naturellement différentes mesures de distance.

Soit y_i la valeur correcte associée à la question i, et $\hat{y}_i$ la réponse produite par le modèle. L'objectif est de quantifier l'erreur commise par le modèle à partir de ces deux quantités.

Nous considérons tout d'abord la **distance absolue**, définie par :

$$D_i^{(abs)} = |\hat{y}_i - y_i|.$$

Cette métrique correspond à l'erreur brute commise par le modèle. Elle constitue la mesure la plus directe de l'écart entre la prédiction et la valeur correcte.

Cependant, une même erreur absolue peut avoir des significations différentes selon l'ordre de grandeur de la valeur correcte. Par exemple, une erreur de 10 unités n'a pas la même importance si la valeur correcte est 50 ou si elle est 10 000. Pour tenir compte de cet effet d'échelle, nous introduisons également la **distance relative normalisée** :

$$D_i^{(rel)} = \frac{|\hat{y}_i - y_i|}{|y_i| + \varepsilon},$$

où $\varepsilon > 0$ est un terme de stabilisation permettant d'éviter les divisions par zéro lorsque la valeur correcte est proche de 0.

Enfin, pour certaines quantités strictement positives, il peut être pertinent de mesurer l'erreur sur une échelle logarithmique. Cela permet de capturer plus directement les écarts multiplicatifs entre la prédiction et la vérité. Nous considérons ainsi la **distance logarithmique** :

$$D_i^{(log)} = |\log(\hat{y}_i) - \log(y_i)|\,.$$

Ces différentes métriques permettent d'analyser la relation entre confiance et proximité à la vérité sous plusieurs angles, en capturant à la fois l'erreur brute, l'erreur relative et les écarts multiplicatifs.

1.3 Définition des scores de confiance

Afin d'étudier la relation entre confiance et proximité à la vérité, nous comparons plusieurs signaux de confiance produits par les modèles. Ces signaux correspondent à différentes manières d'estimer la fiabilité d'une réponse générée. Les prompts utilisés pour obtenir les scores fondés sur une interaction en langage naturel sont présentés en annexe.

Confiance verbalisée Dans un premier temps, le modèle est explicitement invité à fournir un score de confiance associé à la réponse qu'il vient de produire. La sortie attendue est un objet JSON contenant une réponse numérique et un score de confiance compris entre 0 et 1. Ce score est interprété comme une probabilité subjective de correction de la réponse :

$$C_i^{(\text{verb})} \in [0, 1].$$

Par exemple, une valeur de 0.7 signifie que le modèle estime être correct environ 70% du temps pour ce type de réponse.

Confiance par jugement externe (*LLM-as-a-judge*) Nous considérons également une estimation externe de la plausibilité de la réponse. Dans ce cadre, un second modèle de langage reçoit la question ainsi que la réponse produite par le premier modèle et attribue un score de confiance reflétant la crédibilité de cette réponse :

$$C_i^{(\text{judge})} \in [0, 1].$$

Ce score peut être interprété comme une évaluation externe de la plausibilité de la réponse générée.

Scores fondés sur les log-probabilités internes du modèle Lors de la génération d'une réponse, le modèle produit une séquence de tokens

$$(t_1, \ldots, t_T).$$

Pour chaque token généré t_k, l'API fournit la log-probabilité conditionnelle associée :

$$\log p(t_k \mid t_{<k}, x_i),$$

où x_i désigne la question et $t_{<k}$ représente les tokens générés précédemment.

Ces log-probabilités permettent de construire plusieurs scores de confiance internes.

Probabilité jointe de la séquence En exponentiant la somme des log-probabilités, on obtient la probabilité jointe de la séquence générée :

$$P_i^{(\text{joint})} = \prod_{k=1}^{T} p(t_k \mid t_{<k}, x_i).$$

Cette quantité correspond à la probabilité que le modèle attribue à la séquence exacte qu'il a produite.

Probabilité géométrique moyenne Afin d'obtenir une mesure indépendante de la longueur de la séquence, nous considérons également la moyenne géométrique des probabilités des tokens :

$$P_i^{(\text{geo})} = \left(\prod_{k=1}^{T} p(t_k \mid t_{<k}, x_i) \right)^{1/T}.$$

Cette métrique peut être interprétée comme la probabilité moyenne attribuée par le modèle à chaque token généré.

Perplexité Nous calculons également la perplexité associée à la séquence générée :

$$\text{Perplexity}_i = \exp\left(-\frac{1}{T} \sum_{k=1}^{T} \log p(t_k \mid t_{<k}, x_i) \right).$$

La perplexité mesure le degré d'incertitude du modèle : une perplexité plus faible correspond à une séquence jugée plus probable par le modèle.

Probabilité minimale des tokens Afin de détecter les tokens particulièrement incertains, nous considérons également la probabilité minimale parmi les tokens générés :

$$p_{\min} = \min_k p(t_k \mid t_{<k}, x_i).$$

Cette métrique permet d'identifier si la génération contient un token auquel le modèle attribue une probabilité très faible.

Scores restreints aux tokens de la réponse Dans la mesure où notre analyse porte sur des réponses numériques, nous calculons également l'ensemble de ces métriques en ne conservant que les tokens correspondant à la réponse du LLM.

Ces scores permettent d'isoler le niveau de confiance du modèle spécifiquement associé à la génération de la valeur numérique prédite.

1.4 Résultats

1.4.1 Dispersion des scores de confiance

Nous commençons par examiner la distribution des différents scores de confiance produits par les modèles. Le tableau 1 présente des statistiques descriptives pour chacun des signaux étudiés.

Table 1: Résumé descriptif des différents scores de confiance

Confidence score	n	Mean	Min	Max
Conf verbalisée	3395	0.959623	0.100000	1.000000
Conf judge	3391	0.908139	0.010000	1.000000
Prob joint seq	3395	0.973050	0.000001	1.000000
Prob mean seq	3395	0.986256	0.101102	1.000000
Logprob sum seq	3395	-0.054219	-13.531101	0.000013
Logprob mean seq	3395	-0.018517	-2.291625	0.000004
Perplexity seq	3395	1.029233	0.999996	9.890997
Prob min seq	3395	0.974415	0.041966	1.000004
Prob joint all	3395	0.643894	0.000000	0.998803
Prob mean all	3395	0.978124	0.629143	0.999954
Logprob sum all	3395	-0.632608	-16.218891	-0.001197
Logprob mean all	3395	-0.022516	-0.463397	-0.000046
Perplexity all	3395	1.023202	1.000046	1.589464
Prob min all	3395	0.664897	0.038462	0.999041

Un premier résultat frappant concerne le niveau moyen de confiance. La confiance verbalisée par le modèle et la confiance attribuée par le modèle juge présentent des moyennes élevées, respectivement proches de 0.96 et 0.91. Ces valeurs sont supérieures à l'exactitude empirique du modèle, d'environ 0.86, ce qui indique une tendance générale à la surconfiance.

Les probabilités internes associées aux tokens de la réponse sont elles aussi très concentrées vers des valeurs élevées, avec des moyennes souvent comprises entre 0.97 et 0.99. À l'inverse, les probabilités calculées sur l'ensemble de la génération sont un peu moins concentrées, avec des moyennes parfois nettement plus basses, autour de 0.64 à 0.98 selon la métrique considérée.

Ces écarts de dispersion sont importants pour la suite, car un score très concentré près de 1 peut difficilement produire une discrimination fine entre réponses correctes et incorrectes.

1.4.2 Capacité de discrimination des scores de confiance

Nous examinons ensuite dans quelle mesure les différents scores permettent de distinguer les réponses correctes des réponses incorrectes. Pour cela, nous utilisons l'aire sous la courbe ROC (AUC), présentée dans le tableau 2.

Table 2: Capacité de discrimination des scores de confiance mesurée par l'AUC

Confidence score	n	Accuracy	AUC
Logprob mean seq	3395	0.863623	0.857214
Logprob sum seq	3395	0.863623	0.856671
Prob min seq	3395	0.863623	0.849128
Prob mean seq	3395	0.863623	0.843973
Prob joint seq	3395	0.863623	0.843529
Conf verbalisée	3395	0.863623	0.719345
Conf judge	3391	0.864347	0.679321
Prob mean all	3395	0.863623	0.631333
Logprob mean all	3395	0.863623	0.631333
Prob joint all	3395	0.863623	0.628024
Logprob sum all	3395	0.863623	0.628024
Prob min all	3395	0.863623	0.599377
Perplexity all	3395	0.863623	0.368667
Perplexity seq	3395	0.863623	0.142786

L'AUC mesure la probabilité qu'un score attribue une valeur plus élevée à une réponse correcte qu'à une réponse incorrecte choisie au hasard. Une valeur de 0.5 correspond à un classement aléatoire, tandis qu'une valeur proche de 1 indique une forte capacité de discrimination.

Les résultats mettent en évidence une hiérarchie assez claire entre les signaux étudiés. Les probabilités internes associées aux tokens de la réponse obtiennent les meilleures performances, avec des AUC de l'ordre de 0.84 à 0.86. Les scores explicites de confiance se situent à un niveau intermédiaire, avec des AUC proches de 0.68 à 0.72. Enfin, les métriques calculées sur l'ensemble de la génération sont les moins informatives, avec des AUC souvent comprises entre 0.60 et 0.63, et même beaucoup plus faibles pour la perplexité.

Autrement dit, les signaux les plus utiles pour distinguer les bonnes et les mauvaises réponses sont ceux qui portent directement sur les tokens de la réponse elle-même.

1.4.3 Calibration des scores probabilistes

Au-delà de leur capacité de discrimination, il est également important d'examiner si les scores interprétés comme des probabilités sont bien calibrés. Un score est bien calibré si une confiance annoncée de p correspond approximativement à une fréquence empirique de réponses correctes égale à p.

Le tableau 3 présente plusieurs indicateurs de calibration, notamment le score de Brier et l'Expected Calibration Error (ECE).

Table 3: Indicateurs de calibration des scores probabilistes

Confidence score	Brier	ECE
Prob joint seq	0.113852	0.113843
Conf verbalisée	0.117459	0.096000
Prob mean seq	0.120535	0.122633
Conf judge	0.124606	0.081828
Prob mean all	0.127775	0.114501
Prob min all	0.212136	0.223550
Prob joint all	0.215552	0.242211

Les résultats confirment l'impression donnée par l'analyse descriptive : les modèles ont tendance à être surconfiants. Les scores moyens de confiance se situent souvent entre 0.91 et 0.99, alors que l'exactitude empirique reste proche de 0.86. Les scores de Brier les plus faibles sont obtenus par certaines probabilités associées aux tokens de la réponse, avec des valeurs proches de 0.11 à 0.12, tandis que les probabilités calculées sur l'ensemble de la génération peuvent dépasser 0.21. De même, les ECE les plus faibles restent de l'ordre de 0.08 à 0.10, ce qui indique que la calibration reste imparfaite.

Ainsi, même lorsque certains scores discriminent correctement les réponses justes et fausses, ils ne doivent pas être interprétés comme des probabilités parfaitement calibrées.

1.4.4 Lien entre confiance et proximité à la vérité

Nous analysons enfin la relation entre les scores de confiance et la distance entre la réponse produite par le modèle et la vérité terrain. Les résultats détaillés sont présentés en annexe dans les tableaux 4 et 5.

Afin d'évaluer cette relation, nous utilisons principalement la corrélation de Spearman, qui mesure une relation monotone entre deux variables et est moins sensible aux valeurs extrêmes que la corrélation de Pearson.

Sur l'ensemble des réponses, la confiance est globalement négativement corrélée avec l'erreur : les réponses auxquelles le modèle attribue davantage de confiance tendent en moyenne à être plus proches de la vérité terrain. Les corrélations les plus marquées sont observées pour les probabilités internes associées aux tokens de la réponse, avec des coefficients de Spearman pouvant approcher -0.5. Les scores explicites de confiance présentent des corrélations plus modestes, de l'ordre de -0.26, tandis que les métriques calculées sur l'ensemble de la génération restent plus faibles, souvent proches de -0.15.

Lorsque l'on restreint l'analyse aux seules réponses incorrectes, ces corrélations diminuent nettement et se situent le plus souvent entre environ -0.13 et -0.22 pour les meilleurs signaux. Les scores de confiance semblent donc surtout utiles pour distinguer les réponses correctes des réponses incorrectes, mais beaucoup moins pour mesurer

finement l'ampleur de l'erreur parmi les seules réponses fausses.

1.4.5 Robustesse aux différentes mesures de distance

Nous avons également examiné si les résultats dépendaient du choix de la métrique utilisée pour mesurer la distance à la vérité terrain. Plusieurs mesures ont été considérées : l'erreur absolue, l'erreur relative, l'erreur logarithmique et la transformation $\log(1 + |\hat{y} - y|)$.

Les corrélations obtenues sont très proches pour ces différentes métriques. Pour un même score de confiance, les coefficients de Spearman ne varient généralement que de quelques centièmes, et le classement des différents signaux reste inchangé.

Cette stabilité s'explique en partie par le fait que certaines de ces métriques correspondent à des transformations monotones de l'erreur absolue, auxquelles la corrélation de Spearman est invariante. Les résultats obtenus apparaissent donc robustes au choix de la mesure de distance utilisée.

Annexes

A Prompts utilisés

Les réponses des modèles sont demandées au format `JSON` afin de garantir la stabilité des sorties et de faciliter l'extraction automatique des informations nécessaires à l'analyse.

Les prompts sont rédigés en anglais. Ce choix est motivé par deux raisons : d'une part les questions du dataset TriviaQA sont formulées en anglais, et d'autre part les modèles de langage présentent généralement de meilleures performances dans cette langue.

A.1 Prompt pour la génération de la réponse et la confiance verbalisée

```
You must answer in STRICT JSON with exactly two keys: "answer" and "confidence".

Rules:
- Return ONLY the JSON object. No extra text, no markdown, no explanation.
- "answer": a number in decimal notation (examples: 1945, 3.14, -12.5).
  No commas. No units. No text.
- "confidence": a float between 0 and 1 (inclusive). This number must be
  the confidence you have in the answer. If you respond 0.7 then 7 times
  out of 10 you are correct. Be careful, you must not overstate your
  confidence. It must be a JSON number, not a string.

Question:
{q}
```

A.2 Prompt pour le jugement externe (LLM-as-a-judge)

```
You are an assistant that evaluates the correctness of a model's answer
to a question.

Return a single JSON object with exactly one key: "judge_confidence".

- "judge_confidence" must be a JSON number in [0, 1].
```

```
- Return ONLY the JSON object. No markdown, no extra text.

The judge confidence must be the probability that the model's answer
is correct, calibrated as best as possible. If the model's answer is
very likely correct, return a value close to 1. If it's likely
incorrect, return a value close to 0.

Question:
{question.strip()}

Model answer (numeric text):
{model_answer_text.strip()}
```

B Tableaux de résultats

Table 4: Corrélations entre les signaux de confiance et la distance à la vérité terrain (ensemble des réponses)

Confidence score	Distance	n	Pearson	Spearman	Effect
Conf verbalisée	abs_error	3395	-0.042457	-0.270188	faible à modéré
Conf verbalisée	log1p_abs_error	3395	-0.284130	-0.270188	faible à modéré
Conf verbalisée	log_error	3395	-0.126969	-0.264358	faible à modéré
Conf verbalisée	rel_error	3395	-0.044167	-0.261465	faible à modéré
Conf judge	abs_error	3391	-0.015042	-0.266805	faible à modéré
Conf judge	log1p_abs_error	3391	-0.162569	-0.266805	faible à modéré
Conf judge	log_error	3391	-0.111472	-0.265185	faible à modéré
Conf judge	rel_error	3391	-0.017058	-0.263898	faible à modéré
Logprob mean all	abs_error	3395	-0.018171	-0.156858	faible
Logprob mean all	log1p_abs_error	3395	-0.156985	-0.156858	faible
Logprob mean all	log_error	3395	-0.063546	-0.158993	faible
Logprob mean all	rel_error	3395	-0.021559	-0.155558	faible
Logprob sum all	abs_error	3395	-0.024755	-0.152897	faible
Logprob sum all	log1p_abs_error	3395	-0.152380	-0.152897	faible
Logprob sum all	log_error	3395	-0.062083	-0.154579	faible
Logprob sum all	rel_error	3395	-0.028308	-0.151168	faible
Prob min all	abs_error	3395	-0.011096	-0.117806	faible
Prob min all	log1p_abs_error	3395	-0.088027	-0.117806	faible
Prob min all	log_error	3395	-0.031333	-0.118992	faible
Prob min all	rel_error	3395	-0.014023	-0.115786	faible
Perplexity all	abs_error	3395	0.017245	0.156858	faible
Perplexity all	log1p_abs_error	3395	0.156418	0.156858	faible
Perplexity all	log_error	3395	0.062005	0.158993	faible
Perplexity all	rel_error	3395	0.020503	0.155558	faible
Prob mean all	abs_error	3395	-0.018971	-0.156858	faible
Prob mean all	log1p_abs_error	3395	-0.156938	-0.156858	faible
Prob mean all	log_error	3395	-0.064649	-0.158993	faible
Prob mean all	rel_error	3395	-0.022465	-0.155558	faible
Prob joint all	abs_error	3395	-0.030863	-0.152897	faible
Prob joint all	log1p_abs_error	3395	-0.135008	-0.152897	faible
Prob joint all	log_error	3395	-0.063948	-0.154579	faible
Prob joint all	rel_error	3395	-0.035082	-0.151168	faible
Logprob mean seq	abs_error	3395	-0.002167	-0.425641	modéré
Logprob mean seq	log1p_abs_error	3395	-0.230650	-0.425641	modéré
Logprob mean seq	log_error	3395	-0.103590	-0.426609	modéré
Logprob mean seq	rel_error	3395	-0.002963	-0.425326	modéré
Logprob sum seq	abs_error	3395	-0.014186	-0.425553	modéré
Logprob sum seq	log1p_abs_error	3395	-0.192564	-0.425553	modéré
Logprob sum seq	log_error	3395	-0.077316	-0.426768	modéré
Logprob sum seq	rel_error	3395	-0.015566	-0.425616	modéré
Prob min seq	abs_error	3395	-0.025617	-0.414901	modéré
Prob min seq	log1p_abs_error	3395	-0.277212	-0.414901	modéré
Prob min seq	log_error	3395	-0.129688	-0.415452	modéré
Prob min seq	rel_error	3395	-0.027940	-0.413848	modéré
Perplexity seq	abs_error	3395	-0.000183	0.425641	modéré
Perplexity seq	log1p_abs_error	3395	0.170671	0.425641	modéré
Perplexity seq	log_error	3395	0.070058	0.426609	modéré
Perplexity seq	rel_error	3395	0.000278	0.425326	modéré
Prob mean seq	abs_error	3395	-0.005150	-0.493118	modéré
Prob mean seq	log1p_abs_error	3395	-0.262131	-0.493118	modéré
Prob mean seq	log_error	3395	-0.123225	-0.495540	modéré
Prob mean seq	rel_error	3395	-0.006231	-0.492954	modéré
Prob joint seq	abs_error	3395	-0.042301	-0.492527	modéré
Prob joint seq	log1p_abs_error	3395	-0.294001	-0.492527	modéré
Prob joint seq	log_error	3395	-0.141104	-0.494483	modéré
Prob joint seq	rel_error	3395	-0.045566	-0.491914	modéré

Table 5: Corrélations entre les signaux de confiance et la distance à la vérité terrain (réponses incorrectes uniquement)

Confidence score	Distance	n	Pearson	Spearman	Effect
Conf verbalisée	abs_error	463	-0.030027	-0.131958	faible
Conf verbalisée	log1p_abs_error	463	-0.119430	-0.131958	faible
Conf verbalisée	log_error	463	-0.053670	0.142835	faible
Conf verbalisée	rel_error	463	-0.035792	0.156776	faible
Conf judge	abs_error	460	-0.006305	-0.032685	quasi nul
Conf judge	log1p_abs_error	460	-0.125426	-0.032685	quasi nul
Conf judge	log_error	460	-0.129213	0.037922	quasi nul
Conf judge	rel_error	460	-0.012207	0.047376	quasi nul
Logprob mean all	abs_error	463	-0.005060	-0.047283	quasi nul
Logprob mean all	log1p_abs_error	463	-0.011949	-0.047283	quasi nul
Logprob mean all	log_error	463	-0.003188	-0.039990	quasi nul
Logprob mean all	rel_error	463	-0.012972	-0.021579	quasi nul
Logprob sum all	abs_error	463	-0.016364	-0.043605	quasi nul
Logprob sum all	log1p_abs_error	463	-0.013528	-0.043605	quasi nul
Logprob sum all	log_error	463	-0.004346	-0.021224	quasi nul
Logprob sum all	rel_error	463	-0.024170	-0.003246	quasi nul
Prob min all	abs_error	463	-0.006719	-0.002648	quasi nul
Prob min all	log1p_abs_error	463	-0.009901	-0.002648	quasi nul
Prob min all	log_error	463	0.009012	0.038276	quasi nul
Prob min all	rel_error	463	-0.016270	0.053115	très faible
Perplexity all	abs_error	463	0.003264	0.047283	quasi nul
Perplexity all	log1p_abs_error	463	0.008786	0.047283	quasi nul
Perplexity all	log_error	463	0.000089	0.039990	quasi nul
Perplexity all	rel_error	463	0.010631	0.021579	quasi nul
Prob mean all	abs_error	463	-0.006841	-0.047283	quasi nul
Prob mean all	log1p_abs_error	463	-0.015102	-0.047283	quasi nul
Prob mean all	log_error	463	-0.006134	-0.039990	quasi nul
Prob mean all	rel_error	463	-0.015233	-0.021579	quasi nul
Prob joint all	abs_error	463	-0.047488	-0.043605	quasi nul
Prob joint all	log1p_abs_error	463	-0.061255	-0.043605	quasi nul
Prob joint all	log_error	463	-0.041647	-0.021224	quasi nul
Prob joint all	rel_error	463	-0.060540	-0.003246	quasi nul
Logprob mean seq	abs_error	463	0.023010	-0.146024	faible
Logprob mean seq	log1p_abs_error	463	-0.003988	-0.146024	faible
Logprob mean seq	log_error	463	-0.012803	-0.214042	faible à modéré
Logprob mean seq	rel_error	463	0.019848	-0.192430	faible
Logprob sum seq	abs_error	463	0.005245	-0.152643	faible
Logprob sum seq	log1p_abs_error	463	-0.003516	-0.152643	faible
Logprob sum seq	log_error	463	-0.000056	-0.185736	faible
Logprob sum seq	rel_error	463	0.001876	-0.165006	faible
Prob min seq	abs_error	463	0.000384	-0.132909	faible
Prob min seq	log1p_abs_error	463	-0.032132	-0.132909	faible
Prob min seq	log_error	463	-0.032686	-0.158881	faible
Prob min seq	rel_error	463	-0.005630	-0.138356	faible
Perplexity seq	abs_error	463	-0.018036	0.146024	faible
Perplexity seq	log1p_abs_error	463	0.000509	0.146024	faible
Perplexity seq	log_error	463	0.001004	0.214042	faible à modéré
Perplexity seq	rel_error	463	-0.015957	0.192430	faible
Prob mean seq	abs_error	463	0.024038	-0.149965	faible
Prob mean seq	log1p_abs_error	463	-0.010225	-0.149965	faible
Prob mean seq	log_error	463	-0.023712	-0.222229	faible à modéré
Prob mean seq	rel_error	463	0.020074	-0.198807	faible
Prob joint seq	abs_error	463	-0.020382	-0.152014	faible
Prob joint seq	log1p_abs_error	463	-0.051953	-0.152014	faible
Prob joint seq	log_error	463	-0.044534	-0.180300	faible
Prob joint seq	rel_error	463	-0.027630	-0.158374	faible