# Note d'étape 1 – StatApp

Incertitude des Large Language Models

ENSAE Paris – Société Générale

15 décembre 2025

## 1 Contexte et objectifs

Les Large Language Models (LLMs) tels que GPT-4 ou Gemini génèrent des réponses textuelles fluides mais sans indication de leur degré de confiance. Cette limitation compromet leur fiabilité dans des contextes critiques où l'utilisateur doit pouvoir distinguer une réponse fiable d'une potentielle hallucination. Notre projet, encadré par la Société Générale, vise à implémenter et évaluer différentes méthodes de quantification de l'incertitude des LLMs, en distinguant les approches *black-box* (sans accès aux logits) des approches *white-box* (avec accès aux probabilités internes).

## 2 Revue de littérature

Notre travail s'appuie sur trois articles fondateurs que nous avons étudiés en détail (résumés en annexe sur Github).

**Can LLMs Express Their Uncertainty ? An Empirical Evaluation of Confidence Elicitation in LLMs** (Xiong et al., ICLR 2024) propose un cadre systématique pour l'évaluation de confiance en mode *black-box*. Les auteurs décomposent l'estimation en trois modules : *prompting* (verbalisation de la confiance), *sampling* (génération multiple pour mesurer la stabilité) et *agrégation* (fusion des signaux de confiance). Les résultats montrent une surconfiance systématique des LLMs, mais l'approche par sampling améliore significativement la détection d'erreurs.

**Benchmarking LLMs via Uncertainty Quantification** (Ye et al., 2024) introduit la prédiction conforme comme cadre rigoureux pour quantifier l'incertitude. Cette méthode construit des ensembles de prédiction $C(X_t)$ garantissant $P(Y_t \in C(X_t)) \geq 1 - \alpha$, où la taille de l'ensemble capture l'incertitude. L'étude révèle une décorrélation importante entre accuracy et incertitude : un modèle plus précis n'est pas nécessairement plus certain.

**SelfCheckGPT : Zero-Resource Black-Box Hallucination Detection for Generative Large Language Models** (Manakul et al., 2023) propose une détection d'hallucinations *zero-resource* basée sur la cohérence des réponses échantillonnées. Cinq variantes sont évaluées : BERTScore, n-gram, NLI, QA et Prompt. La méthode SelfCheckGPT-Prompt atteint une AUC-PR de 93.42% pour la détection de contenus non-factuels, surpassant les méthodes *grey-box* nécessitant l'accès aux probabilités.

## 3 Travail réalisé

### 3.1 Infrastructure et organisation

Nous avons mis en place un dépôt Git structuré contenant le code d'implémentation, les datasets prétraités et la documentation méthodologique. L'environnement de développement utilise Python 3.12 avec les dépendances gérées via `requirements.txt`. L'accès aux modèles est configuré via l'API Gemini.

### 3.2 Implémentation des méthodes white-box

Nous avons développé la classe `UnifiedProbGeminiBatch` qui exploite les log-probabilités des tokens retournées par Gemini. Le système supporte trois modes de réponse : booléen (`true/false`), numé-

rique (`float`) et QCM (`string`). Pour chaque question, le modèle génère une réponse au format JSON strict, et le code agrège les logprobs pour calculer un score de confiance $P = \exp(\sum_i \log p(t_i|t_{<i}))$.

### 3.3 Implémentation de SelfCheckGPT

La classe `SelfCheckGeminiBatch` implémente la variante *Prompt* de SelfCheckGPT. Pour chaque phrase à évaluer, le système vérifie sa cohérence avec plusieurs passages de référence. Le LLM joue le rôle de juge et répond par `true` (supporté) ou `false` (non supporté). Les scores sont agrégés en matrice $M \times K$ et moyennés par phrase.

## 4 Méthodes

Nous distinguons deux familles d'approches pour quantifier l'incertitude des LLMs. Les méthodes *white-box* exploitent l'accès aux probabilités internes du modèle (entropie, probabilité de séquence, probabilité des tokens clefs, prédiction conforme). Les méthodes *black-box*, applicables aux modèles fermés via API, reposent sur l'analyse des sorties textuelles (verbalisation de confiance, cohérence multi-échantillons, SelfCheckGPT). La liste exhaustive des méthodes et leur formalisation sont détaillées en annexe.

## 5 Datasets retenus

Nous avons identifié plusieurs datasets adaptés à notre étude et nous avons pour l'instant décidé d'en garder deux (fiche méthodologique en annexe) :

**MMLU** (Massive Multitask Language Understanding) : 15 908 questions à choix multiples couvrant 57 disciplines académiques, idéal pour évaluer la calibration sur des tâches de connaissances générales. C'est notre dataset principal pour les expériences de prédiction conforme.

**GSM8K** (Grade School Math) : problèmes arithmétiques en langage naturel, particulièrement adapté pour évaluer l'incertitude sur les tâches de raisonnement où les méthodes de sampling montrent de bonnes performances.

## 6 Statistiques descriptives sur MMLU

Le dataset MMLU contient 15 858 questions réparties sur 57 sujets académiques, avec une moyenne de 278 questions par sujet. La distribution thématique couvre les domaines STEM, sciences humaines et sociales de manière relativement déséquilibrée : les deux sujets les plus représentés dépassent les 1000 questions tandis que les moins représentés dépassent à peine 100 questions.

**Nature des réponses.** La majorité des questions (91.5%) proposent des réponses textuelles, 7% des réponses purement numériques et 1.5% sont mixtes, reflétant la nature principalement conceptuelle du benchmark.

**Longueur des questions.** Les questions contiennent en moyenne 47 mots avec une distribution concentrée. La méthode IQR identifie environ 11% de questions longues (>118.5 mots), conservées car elles reflètent la diversité naturelle du benchmark et testent la capacité des modèles à traiter des contextes étendus.

**Distribution des réponses correctes.** Le test du $\chi^2$ révèle que la distribution originale des bonnes réponses (A, B, C, D) n'est pas uniforme ($p < 0.001$), avec un biais vers la position D (26.7%). Un shuffle aléatoire des choix rend cette distribution statistiquement uniforme ($p = 0.16$). Ce mélange est donc recommandé pour l'évaluation afin d'éliminer les biais de position et empêcher les modèles d'exploiter des patterns artificiels.

Les graphiques décrivant le dataset et le code sont disponibles en annexe sur Github.

# 7 Perspectives

La suite du projet s'articulera autour de trois axes. Premièrement, nous compléterons l'implémentation des méthodes de prédiction conforme sur MMLU. Deuxièmement, nous conduirons une évaluation comparative systématique des méthodes *black-box* vs *white-box* selon les différentes métriques. Troisièmement, nous appliquerons SelfCheckGPT au dataset FEVER pour quantifier sa capacité de détection d'hallucinations dans un cadre contrôlé.

## Annexes

*Les résumés détaillés des trois articles, la fiche récapitulative des datasets et des méthodes, les différents fichiers de code et les graphiques des statistiques descriptives sont disponibles sur le Github du projet.*

https://github.com/gregouzeee/statapp