



StatApp : Quantification statistique de l'incertitude des grands modèles de langage (LLM)

Rapport final

Auteurs : Kénan Darfilali, William Dejean, Samuel Macé et Grégoire Marguier

Encadrant : Alexis Vignard

Référent : Azadeh Khaleghi

Table des matières

1	Introduction	3
1.1	Notations et métriques d'évaluation	3
2	Revue de littérature	5
2.1	Méthodes white-box et confiance verbalisée	5
2.2	SelfCheckGPT et entropie sémantique	5
2.3	Prédiction conforme appliquée aux LLMs	6
2.4	WEPR : détection supervisée d'erreurs	6
2.5	Synthèse et positionnement du projet	6
3	Analyse descriptive des datasets	6
3.1	GSM8K	7
3.2	MMLU	7
3.3	TriviaQA	7
3.4	ELI5	7
4	Lien entre score de confiance et proximité à la vérité	8
4.1	Problématique et cadre expérimental	8
4.2	Résultats	8
5	Cas des questions à choix multiples : MMLU et prédiction conforme	10
5.1	Cadre et scores de confiance	10
5.2	Prédiction conforme : principe et variantes	11
5.3	Résultats	12
6	Analyse de l'incertitude dans les générations longues	13
6.1	Motivation et cadre	13
6.2	Résultats	14
7	Détection d'erreurs par WEPR	14
7.1	Méthode	14
7.2	Résultats	15
7.3	Extension non linéaire : XGBoost	15
7.4	Synthèse	17
8	Comparaison transverse et transfert des méthodes	17
8.1	Motivation et trois ponts	17
8.2	Transfert de WEPR à GSM8K	17
8.3	Entropie sémantique appliquée à TriviaQA-numérique	18
8.4	Table croisée et lectures transverses	18
8.5	Comparaison aux résultats de la littérature	19
9	Conclusion	21
A	Statistiques descriptives détaillées des datasets	22
A.1	GSM8K	22
A.2	MMLU	23
A.3	TriviaQA	24

A.4	ELI5	25
B	Définition formelle des scores de confiance (TriviaQA)	25
C	Tableaux complets section TriviaQA-num	26
C.1	Distribution des scores	26
C.2	Tableaux numériques	26
D	Indicateurs et tableaux pour GSM8K (générations longues)	29
D.1	Indicateurs construits sur les log-probabilités	29
D.2	Tableaux complets	30
E	Prédiction conforme sur MMLU : compléments	31
E.1	Scores de non-conformité	31
E.2	Protocole de calibration	31
F	WEPR : compléments	32
F.1	Courbes ROC et distributions de score	32
F.2	Coefficients de la régression logistique et inversion de signe	32
F.3	Extension non linéaire : XGBoost	33
G	Transfert WEPR et entropie sémantique : compléments	33
G.1	Protocole de transfert	33
G.2	WEPR sur GSM8K par sous-séquence	34
G.3	Sous-ensemble aligné pour la table croisée	34
G.4	Entropie sémantique : définition formelle et clustering	34
H	Prompts utilisés	35
H.1	TriviaQA-numérique : génération et confiance verbalisée	35
H.2	TriviaQA-numérique : jugement externe (LLM-as-a-judge)	35
H.3	TriviaQA-WEPR : génération de la réponse libre	36
H.4	TriviaQA-WEPR : juge de factualité (annotation Y)	36
H.5	GSM8K : raisonnement <i>chain-of-thought</i> et réponse finale	36
H.6	MMLU : choix forcé pour extraction des log-probabilités	37
H.7	ELI5 : génération longue	37
H.8	Entropie sémantique : juge NLI (clustering)	38

1 Introduction

Les grands modèles de langage (*Large Language Models*, LLMs) occupent une place croissante dans de nombreux usages, mais leur déploiement dans des environnements sensibles se heurte à une difficulté majeure : l’absence d’une mesure fiable de leur propre incertitude. Un LLM peut produire une réponse erronée avec une assurance apparente comparable à celle d’une réponse correcte, et les scores de confiance verbalisés par les modèles sont souvent mal calibrés. Il devient ainsi essentiel de disposer d’outils permettant d’évaluer rigoureusement la fiabilité des réponses générées.

Le projet **StatApp**, réalisé en partenariat avec **Société Générale**, vise à développer des méthodes statistiques de quantification de l’incertitude des LLMs. Il repose sur deux familles d’approches complémentaires : les méthodes *white-box*, qui exploitent les signaux internes du modèle (log-probabilités, entropie, perplexité), et les méthodes *black-box*, qui s’appuient sur des mécanismes externes (jugement par un LLM, auto-vérification). Au-delà de la simple détection des réponses correctes, le projet aborde plusieurs questions plus fines : calibration des scores, prédiction conforme, analyse des générations longues et lien entre confiance et proximité à la vérité.

Les expériences couvrent plusieurs types de tâches afin de tester la robustesse des méthodes proposées. **MMLU** est utilisé pour les questions à choix multiples, **GSM8K** et **TriviaQA** pour des réponses factuelles courtes ou avec raisonnement, et **ELI5** pour des réponses longues et explicatives. Le présent rapport synthétise les résultats obtenus selon quatre axes : lien entre confiance et proximité à la vérité (section 4), incertitude dans le cadre des QCM (section 5), analyse des générations longues (section 6), et détection supervisée d’erreurs par WEPR (section 7). Une comparaison transverse (section 8) met enfin ces approches en regard sur un même axe.

1.1 Notations et métriques d’évaluation

Cette sous-section rassemble les définitions des principaux scores et métriques utilisés de façon récurrente dans la suite du rapport. Les scores et notions plus spécifiques (EPR/WEPR, entropie sémantique, prédiction conforme LAC/APS, cosine similarity, etc.) sont définis au point d’usage dans chaque section.

Scores de confiance fondés sur les log-probabilités

Soit $(t_1, \dots, t_T)$ une séquence de tokens générée pour une question x , et $p_k = p(t_k \mid t_{<k}, x)$ la probabilité conditionnelle attribuée par le modèle au k -ième token.

Probabilité jointe de la séquence.

$$P^{(\text{joint})} = \prod_{k=1}^T p_k.$$

C’est la probabilité que le modèle attribue à la séquence exacte produite. Elle décroît mécaniquement avec la longueur : pour une séquence longue, même si chaque p_k est élevé, le produit s’écrase vers zéro.

Probabilité géométrique moyenne.

$$P^{(\text{geo})} = \left(\prod_{k=1}^T p_k \right)^{1/T} = \exp \left(\frac{1}{T} \sum_{k=1}^T \log p_k \right).$$

C'est la moyenne géométrique des probabilités des tokens, équivalente à $P^{(\text{joint})}$ normalisée par la longueur. Elle s'interprète comme la probabilité moyenne attribuée par token et reste comparable entre séquences de longueurs différentes.

Perplexité.

$$\text{Perplexity} = \exp\left(-\frac{1}{T} \sum_{k=1}^T \log p_k\right) = \left(P^{(\text{geo})}\right)^{-1}.$$

La perplexité est l'inverse de la probabilité géométrique : une perplexité faible correspond à une séquence jugée probable par le modèle. Comme c'est une transformation strictement monotone de $P^{(\text{geo})}$, les deux quantités produisent la même AUC et la même corrélation de Spearman.

Probabilité minimale.

$$p_{\min} = \min_{1 \leq k \leq T} p_k.$$

Permet de détecter la présence d'un token particulièrement incertain dans la séquence ; complémentaire des moyennes ci-dessus.

Scores restreints aux tokens de la réponse. Lorsque la sortie du modèle contient à la fois un raisonnement et une réponse finale (ou lorsque la réponse est isolée par parsing JSON), nous calculons également chacun des scores ci-dessus en restreignant la suite (p_k) aux seuls tokens correspondant à la réponse. Ces variantes sont indiquées dans la suite par la mention « tokens de la réponse ».

Métriques d'évaluation

AUC et AUROC. L'*AUC* (*Area Under the ROC Curve*, parfois notée AUROC) mesure la capacité d'un score s à discriminer une classe positive d'une classe négative. Elle est égale à la probabilité qu'une observation positive tirée au hasard reçoive un score plus élevé qu'une observation négative tirée au hasard :

$$\text{AUC} = \mathbb{P}(s(X^+) > s(X^-)).$$

Une AUC de 0,5 correspond à un classement aléatoire, 1 à une discrimination parfaite. L'AUC est invariante par toute transformation strictement monotone du score, ce qui la rend robuste aux choix d'échelle (par exemple, $-\log p$ et p donnent la même AUC).

Average Precision (AP). L'*AP* est l'aire sous la courbe précision-rappel. Elle est plus sensible à la performance sur la classe positive que l'AUC, ce qui la rend particulièrement pertinente sur les tâches très déséquilibrées (par exemple GSM8K, où 96% des réponses sont correctes).

Brier score. Pour un score $\hat{p}_i \in [0, 1]$ interprété comme probabilité d'être correct et une cible $y_i \in \{0, 1\}$, le *Brier score* est l'erreur quadratique moyenne :

$$\text{BS} = \frac{1}{n} \sum_{i=1}^n (\hat{p}_i - y_i)^2.$$

Il combine discrimination et calibration : un score peut avoir une faible AUC mais un bon Brier (et inversement).

Expected Calibration Error (ECE). L’ECE mesure l’écart entre la confiance annoncée et l’exactitude empirique. On partitionne les prédictions en B *bins* selon la valeur du score (typiquement $B = 10$), puis :

$$\text{ECE} = \sum_{b=1}^B \frac{|I_b|}{n} \left| \overline{\text{conf}}(I_b) - \overline{\text{acc}}(I_b) \right|,$$

où $\overline{\text{conf}}(I_b)$ est la confiance moyenne des prédictions du bin b et $\overline{\text{acc}}(I_b)$ leur exactitude moyenne. Un score parfaitement calibré a $\text{ECE} = 0$.

Corrélation de Spearman. Le coefficient de Spearman ρ_s est la corrélation de Pearson appliquée aux *rangs* de deux variables. Il mesure une relation monotone (non nécessairement linéaire) et est invariant par toute transformation strictement monotone des variables. Il est donc moins sensible aux valeurs extrêmes que la corrélation de Pearson, ce qui le rend pertinent pour comparer des scores de confiance et des distances numériques sur plusieurs ordres de grandeur (section 4).

2 Revue de littérature

La quantification de l’incertitude des LLMs s’organise autour de quatre familles méthodologiques bien identifiées, qui ont directement nourri nos choix expérimentaux.

2.1 Méthodes white-box et confiance verbalisée

Xiong et al. (2024) étudient comment éliciter la confiance d’un LLM lorsqu’on n’a pas accès à ses probabilités internes. Leur cadre décompose le pipeline en trois modules : *prompting* (vanilla, chain-of-thought, top-K), *sampling* (self-random, prompt paraphrasing) et agrégation (consistency, average confidence, Pair-Rank). Ils évaluent en parallèle trois méthodes white-box classiques fondées sur les log-probabilités. Leurs trois conclusions sont décisives pour notre travail : (i) les LLMs verbalisent une surconfiance systématique, (ii) l’apport des méthodes white-box reste modeste sur certaines tâches (AUROC typiquement de 0,52 à 0,60), ce qui montre que les logits reflètent surtout l’incertitude syntaxique locale et non l’incertitude sémantique globale, et (iii) la combinaison Top-K + Self-Random + Avg-Conf offre le meilleur compromis pratique. Ces résultats motivent notre comparaison systématique de plusieurs scores white-box (perplexité, P_{joint} , P_{geo}) avec la confiance verbalisée et le jugement externe.

2.2 SelfCheckGPT et entropie sémantique

Manakul et al. (2023) proposent SelfCheckGPT, méthode *zero-resource* purement *black-box* : si un LLM possède effectivement une connaissance sur un fait, ses générations stochastiques doivent rester cohérentes ; à l’inverse, pour un fait halluciné, les échantillons divergent. Cinq variantes mesurent cette cohérence (BERTScore, NLI, Unigram, QA, Prompt). Kuhn et al. (2023) reprennent cette intuition et la formalisent dans un cadre information-théorique : pour une question, on génère K réponses, on les regroupe par classes d’équivalence sémantique, puis on calcule l’entropie de la distribution sur ces *clusters*. Cette définition distingue les variations syntaxiques (qui ne devraient pas augmenter l’incertitude) des variations sémantiques (qui en sont le signal). Nous transposons cette idée au cadre numérique de TriviaQA en définissant l’équivalence sémantique comme l’identité numérique au seuil près (section 8).

2.3 Prédiction conforme appliquée aux LLMs

Ye et al. (2024) défendent l’idée qu’un benchmark de LLM ne peut se réduire à l’*accuracy* et qu’il faut intégrer l’incertitude des prédictions. Ils s’appuient sur la **prédiction conforme**, qui transforme une heuristique (typiquement le softmax) en garantie statistique *distribution-free* : pour chaque entrée, le modèle produit un *ensemble de prédiction* contenant la bonne réponse avec probabilité au moins $1 - \alpha$, l’incertitude étant alors mesurée par la taille de cet ensemble. Deux fonctions de score sont étudiées : LAC (qui minimise la taille moyenne) et APS (qui exploite l’ensemble du vecteur de probabilités). Sur 9 familles de LLMs et 5 tâches, les auteurs montrent que la couverture empirique respecte la garantie théorique $\geq 1 - \alpha$, et que *accuracy* et incertitude sont décorréliées. Ces résultats fondent notre section 5, où nous comparons LAC et APS sur MMLU.

2.4 WEPR : détection supervisée d’erreurs

Moslonka et al. (2026) proposent un *détecteur supervisé* d’erreurs fondé sur les distributions top- K . Pour chaque token et chaque rang k , on définit la contribution entropique $s(k, j) = -p(k, j) \log p(k, j)$. La quantité non supervisée $EPR = \frac{1}{L} \sum_{j,k} s(k, j)$ (*Entropy Production Rate*) constitue une baseline. La contribution centrale est d’observer que tous les rangs ne portent pas la même information, et qu’une régression logistique sur les moyennes et maxima de $s(k, j)$ par rang ($2K$ features) améliore significativement la détection (+2 à +3 points d’AUC). Les auteurs documentent un plateau de performance autour de $K \approx 8-10$. Nous reprenons cette formulation dans la section 7 et l’étendons par une analyse non linéaire (XGBoost, voir annexe F.3).

2.5 Synthèse et positionnement du projet

Ces quatre familles éclairent des aspects complémentaires de l’incertitude. Les méthodes white-box capturent une incertitude *locale* liée à la concentration de la distribution sur le prochain token ; SelfCheckGPT et l’entropie sémantique mesurent une incertitude *externe* liée à l’instabilité entre échantillons ; la prédiction conforme fournit des garanties *statistiques* sur la couverture ; WEPR enfin propose un détecteur *supervisé*. Notre projet ne propose pas une nouvelle famille de méthodes, mais un dialogue empirique entre ces approches : chacune de nos sections applique une ou plusieurs d’entre elles à un cadre expérimental contrôlé, et la section 8 les compare sur un même axe.

3 Analyse descriptive des datasets

Quatre jeux de données sont mobilisés, couvrant différents régimes de génération. Le tableau 1 en synthétise les caractéristiques ; les figures détaillées sont reportées en annexe A.

TABLE 1 – Récapitulatif des datasets utilisés.

Dataset	Taille	Type de réponse	Longueur	Vérité	Section
MMLU	$\sim 14\,000$ (107*)	QCM (4 options)	–	stricte	5
TriviaQA-num	3 397	numérique courte	~ 4 tokens	stricte	4
TriviaQA-WEPR	73 793	textuelle libre	~ 10 mots	juge LLM	7
GSM8K	1 319	numérique + raisonnement	~ 188 tokens	stricte	6
ELI5	100	explication longue	~ 53 mots	juge LLM	8

*Pour MMLU, l’analyse expérimentale porte sur un sous-échantillon de 107 questions pour lesquelles les log-probabilités complètes sur les quatre options sont disponibles.

3.1 GSM8K

GSM8K est un benchmark de raisonnement arithmétique. Les questions sont relativement courtes (~ 46 mots) et contiennent en moyenne 3,44 valeurs numériques. Les opérations dominantes sont multiplication, addition, soustraction, division. La distribution des réponses est très asymétrique avec environ 15% de valeurs extrêmes. La difficulté principale réside dans l’enchaînement de plusieurs étapes simples plutôt que dans la complexité de chaque opération individuelle.

3.2 MMLU

MMLU regroupe des QCM couvrant 57 sujets académiques, avec une distribution hétérogène (droit, scénarios moraux particulièrement représentés). Les réponses sont majoritairement textuelles ($> 90\%$). La distribution initiale des bonnes réponses parmi $\{A, B, C, D\}$ est légèrement biaisée mais devient uniforme après permutation aléatoire, garantissant que la position de la bonne réponse ne constitue pas un signal exploitable.

3.3 TriviaQA

TriviaQA est un benchmark de questions-réponses factuelles construit à partir de quiz culturels. Les questions sont courtes (médiane 12 mots, IQR [9, 16]). Nous l’utilisons dans deux configurations : *TriviaQA-num* restreint aux 3 397 questions à réponse strictement numérique (dont $\sim 56\%$ d’années), ce qui permet de définir une notion naturelle de *distance à la vérité* ; et *TriviaQA-WEPR*, qui conserve l’intégralité des 73 793 réponses sous leur forme textuelle, étiquetées par un juge LLM (84,7% jugées correctes), pour entraîner le détecteur d’erreurs WEPR.

3.4 ELI5

ELI5 (*Explain Like I’m 5*) sollicite des explications longues et accessibles. Les questions sont courtes (~ 15 mots) mais les réponses humaines de référence comptent 72 mots en moyenne, contre 53 pour les générations Gemini. La perplexité moyenne est faible (1,32) malgré la longueur, ce qui illustre directement le problème : une génération longue présente une probabilité jointe extrêmement faible en valeur absolue, rendant la perplexité brute peu informative. ELI5 est le seul dataset où la vérité n’est pas vérifiable automatiquement ; il permet de tester la robustesse des méthodes black-box dans un régime de génération longue.

4 Lien entre score de confiance et proximité à la vérité

4.1 Problématique et cadre expérimental

Dans les applications réelles, une réponse n’est pas simplement « juste » ou « fausse ». Pour la question « *En quelle année les Jeux Olympiques d’été ont-ils eu lieu à Montréal ?* » (réponse : 1976), une prédiction de 1975 paraît plus proche de la vérité que 1950. La question naturelle devient : un score de confiance élevé correspond-il à une réponse plus proche de la vérité, ou seulement à une réponse plus souvent exacte ?

Cette interprétation suppose que la distance numérique reflète la qualité du raisonnement, ce qui n’est pas toujours vrai (une réponse peut être numériquement proche pour de mauvaises raisons). Par exemple, à la question « *Combien de paires différentes peut-on former avec 10 personnes ?* », la réponse correcte est 45. Une réponse 5 (issue d’une mauvaise interprétation du problème) est numériquement plus proche que 90, qui provient pourtant d’un raisonnement presque correct (mais comptant chaque paire deux fois). La proximité à la vérité ne reflète donc pas nécessairement la qualité du raisonnement.

Pour neutraliser cette ambiguïté, nous travaillons sur **TriviaQA-numérique**, restreint aux 3 397 questions à réponse numérique. Ce choix permet de se placer dans un cadre où la notion de distance à la vérité est bien définie et interprétable, en particulier pour des questions factuelles (dates, mesures, quantités) admettant une réponse unique. La distance entre la prédiction $\hat{y}_i$ et la vérité y_i est mesurée par trois métriques complémentaires (absolue, relative, logarithmique). Nous comparons trois familles de signaux suivant la typologie de Xiong et al. (2024) : la *confiance verbalisée* $C^{(\text{verb})}$ fournie par le modèle au format JSON, la *confiance par jugement externe* $C^{(\text{judge})}$ d’un second LLM, et les *scores fondés sur les log-probabilités* (P_{joint} , P_{geo} , perplexité, p_{min}), calculés sur l’ensemble de la génération ou restreints aux tokens de la réponse. Les définitions formelles sont reportées en annexe B.

4.2 Résultats

Surconfiance systématique. La confiance verbalisée et le jugement externe affichent des moyennes de 0,96 et 0,91, soit nettement au-dessus de l’exactitude empirique du modèle (0,86). Les probabilités internes sur les tokens de la réponse sont également très concentrées (moyennes entre 0,97 et 0,99).

Capacité de discrimination. Le tableau 2 synthétise les AUC. Les probabilités internes sur les tokens de la réponse dominent largement ($\text{AUC} \sim 0,84\text{--}0,86$), suivies par les scores explicites (0,68–0,72), puis les métriques sur l’ensemble de la génération (0,60–0,63). Les tableaux complets figurent en annexe C.

TABLE 2 – AUC des principaux scores de confiance sur TriviaQA-num.

Score	AUC
Probabilité géométrique sur tokens de la réponse	$\sim 0,86$
Probabilité jointe sur tokens de la réponse	$\sim 0,84$
Confiance par jugement externe	$\sim 0,72$
Confiance verbalisée	$\sim 0,68$
Perplexité (génération complète)	$\sim 0,60$

Calibration imparfaite. Malgré une bonne discrimination, les scores ne sont pas correctement calibrés : Brier scores $\sim 0,11\text{--}0,12$ et ECE $\sim 0,08\text{--}0,10$. Cette absence de calibration n’est pas surprenante : les softmax des LLMs sont entraînés à produire des distributions piquées sur le prochain token, pas à fournir des estimations de la probabilité d’être globalement correct. Une AUC élevée traduit ici un bon *classement*, pas une bonne *calibration* : les scores ne peuvent pas être interprétés directement comme $\mathbb{P}(\text{correct})$.

Lien entre confiance et proximité à la vérité. Le tableau 3 reporte les corrélations de Spearman entre les principaux scores et l’erreur, sur l’ensemble des réponses puis sur les seules réponses incorrectes. Trois points méritent attention.

TABLE 3 – Corrélations de Spearman entre score de confiance et erreur sur TriviaQA-num. Une corrélation négative est attendue (plus de confiance $\Leftrightarrow$ moins d’erreur). Tableaux complets en annexe C.

Score	Toutes réponses			Réponses incorrectes seules		
	abs.	rel.	log.	abs.	rel.	log.
P_{geo} tokens réponse	−0,49	−0,50	−0,48	−0,21	−0,22	−0,19
P_{joint} tokens réponse	−0,45	−0,46	−0,44	−0,19	−0,20	−0,17
Confiance par jugement externe	−0,28	−0,29	−0,27	−0,15	−0,16	−0,14
Confiance verbalisée	−0,26	−0,27	−0,25	−0,13	−0,14	−0,13
Perplexité (génération complète)	−0,15	−0,16	−0,15	−0,08	−0,09	−0,07

Premièrement, sur l’ensemble des réponses, les corrélations sont négatives comme attendu, avec une hiérarchie cohérente avec celle des AUC : les probabilités internes restreintes aux tokens de la réponse atteignent $\rho \simeq -0,5$, contre $-0,26$ pour la confiance verbalisée. Ce résultat indique qu’une confiance plus élevée est bien associée, en moyenne, à une réponse plus proche de la vérité.

Deuxièmement, et c’est le résultat le plus instructif, lorsqu’on restreint l’analyse aux seules réponses *incorrectes*, ces corrélations s’effondrent : les meilleurs signaux passent de $-0,5$ à $-0,2$, et la confiance verbalisée à peine $-0,13$. Autrement dit, les scores de confiance permettent de *distinguer* les réponses correctes des incorrectes, mais ne permettent que très partiellement de *grader* l’erreur parmi les réponses fausses. Une réponse à confiance 0,99 qui se trompe n’est pas significativement plus proche de la vérité qu’une réponse à confiance 0,80 qui se trompe également. Cette observation est importante pour les usages opérationnels : la confiance d’un LLM ne fournit pas un indicateur fin de la qualité d’une réponse erronée.

Troisièmement, les corrélations sont remarquablement stables entre les trois métriques de distance (les écarts entre colonnes ne dépassent pas 0,03). Cette stabilité est partiellement attendue : la corrélation de Spearman est invariante par toute transformation strictement monotone, ce qui rend équivalentes la distance absolue et la distance logarithmique sur les valeurs strictement positives. La distance relative diffère un peu plus, mais l’ordre induit reste essentiellement le même. Le classement des scores est donc robuste au choix de la mesure de distance.

Une exploration parallèle : la cosine similarity *leave-one-out*. En complément des scores agrégés ci-dessus, nous avons exploré une approche différente, orientée vers la

localisation de l’information dans la génération plutôt que vers une mesure globale de confiance. Pour chaque position j , on construit un vecteur de log-probabilités à partir des top- K candidats à cette position, puis on compare le vecteur moyen sur toute la séquence au vecteur moyen calculé sans la position j . L’importance du token est définie par

$$I_j = 1 - \cos(\bar{v}_{\text{full}}, \bar{v}_{-j}),$$

ce qui mesure dans quelle mesure le token j modifie le profil global de confiance. Sur TriviaQA, cette méthode atteint un *hit-rate* de $\sim 85\%$ au niveau du mot (les tokens identifiés comme importants coïncident avec les tokens porteurs de la réponse), ce qui dépasse les performances obtenues en triant simplement par perplexité locale. La cosine similarity *leave-one-out* est donc une méthode efficace pour *repérer* où se trouve l’information dans une réponse.

Nous n’avons cependant pas exploité davantage ce signal dans la suite du projet, pour deux raisons. Premièrement, le score I_j produit un *vecteur* d’importances par token, pas un score global directement interprétable comme une probabilité d’être correct : il ne s’inscrit pas naturellement dans le cadre AUC/calibration utilisé dans le reste du rapport. Deuxièmement, et surtout, le projet s’est réorienté vers la détection d’*erreurs* (section 7), pour laquelle la question pertinente n’est pas « où est l’information ? » mais « cette information est-elle correcte ? ». Cosine similarity et WEPR mesurent en réalité deux choses différentes : l’une localise les tokens porteurs de sens dans une réponse donnée, l’autre détecte si la réponse globale est probablement fausse. Une combinaison des deux approches, par exemple en restreignant les features WEPR aux positions identifiées comme importantes par cosine, constitue une piste de prolongement non explorée ici.

Synthèse. Les signaux probabilistes internes contiennent une information sur la fiabilité, plus discriminante que les scores verbalisés. Cependant, leur utilité pour mesurer la *proximité* à la vérité parmi les réponses fausses reste limitée : ils discriminent bien correct/incorrect mais ne gradent pas finement l’erreur. Cela motive l’extension à des cadres plus complexes : générations longues (section 6) et détecteur supervisé multi-features (section 7).

5 Cas des questions à choix multiples : MMLU et prédiction conforme

5.1 Cadre et scores de confiance

Afin de compléter l’analyse précédente, nous nous plaçons désormais dans un cadre où l’ensemble des réponses possibles est fini et explicitement donné. Contrairement aux questions numériques, il n’existe plus ici de notion naturelle de distance à la vérité : une réponse est soit correcte, soit incorrecte, sans structure métrique intermédiaire.

Le benchmark **MMLU** regroupe des QCM à 4 options $\{A, B, C, D\}$. Lorsque les log-probabilités $(\ell_{i,A}, \dots, \ell_{i,D})$ sont disponibles, on construit une distribution softmax $p_{i,j} = \exp(\ell_{i,j}) / \sum_k \exp(\ell_{i,k})$, qui permet trois scores de confiance : la *probabilité maximale* $C_i^{(\max)} = \max_j p_{i,j}$, l’*entropie normalisée* $C_i^{(\text{ent})} = 1 - H_i / \log 4$, et la *confiance déclarée* $C_i^{(\text{decl})}$. L’analyse porte sur 107 questions disposant des log-probabilités complètes.

Dans ce cadre discret, un score de confiance pertinent doit avant tout permettre de classer les réponses selon leur probabilité d’être exactes. La qualité du classement induit

par chaque score est évaluée via les courbes *accuracy-coverage* : on trie par confiance décroissante, ne conserve que les γn plus confiantes, et calcule l’accuracy résiduelle.

5.2 Prédiction conforme : principe et variantes

Les scores de confiance présentés ci-dessus permettent de *classer* les réponses selon leur fiabilité attendue, mais ne fournissent pas de garantie probabiliste explicite. La prédiction conforme (Angelopoulos & Bates, 2023) propose précisément un cadre permettant de transformer ces scores en prédictions assorties de garanties statistiques.

Plus précisément, la prédiction conforme transforme un classifieur probabiliste en un prédicteur d’ensembles avec garantie de couverture. Pour chaque entrée x_i , le prédicteur retourne un ensemble $\mathcal{C}(x_i) \subseteq \{A, B, C, D\}$ tel que, pour un niveau α fixé,

$$\mathbb{P}(y_i \in \mathcal{C}(x_i)) \geq 1 - \alpha,$$

où la probabilité est prise sur le couple test (x_i, y_i) supposé *i.i.d.* par rapport à un ensemble de calibration. La taille moyenne $\mathbb{E}[|\mathcal{C}(x_i)|]$ devient alors une mesure naturelle d’incertitude : un modèle confiant produit des singletons, un modèle incertain produit des ensembles plus grands.

Le principe repose sur la définition d’un *score de non-conformité* $s : (x, y) \mapsto \mathbb{R}$ mesurant le désaccord entre une réponse candidate y et la prédiction du modèle pour x . Ce score est évalué sur un ensemble de calibration $\{(x_i, y_i)\}_{i=1}^{n_{\text{cal}}}$, dont on extrait le quantile empirique

$$\hat{q}_\alpha = \text{Quantile}\left(\{s_i\}_{i=1}^{n_{\text{cal}}}, \frac{\lceil (n_{\text{cal}}+1)(1-\alpha) \rceil}{n_{\text{cal}}}\right).$$

L’ensemble de prédiction sur une nouvelle entrée x est alors défini par

$$\mathcal{C}(x) = \{y \in \{A, B, C, D\} : s(x, y) \leq \hat{q}_\alpha\}.$$

La correction $(n_{\text{cal}} + 1)/n_{\text{cal}}$ assure la garantie de couverture en échantillon fini.

Dans notre cadre, les scores de non-conformité sont directement construits à partir des probabilités softmax introduites précédemment, ce qui permet d’évaluer dans quelle mesure ces signaux internes peuvent être exploités pour produire des ensembles prédictifs fiables.

Nous comparons deux variantes :

- **LAC** (*Least Ambiguous set-valued Classifier*) : score $s(x_i, y) = 1 - p_{i,y}$. Une option est incluse si sa probabilité dépasse un seuil $1 - \hat{q}_\alpha$. LAC minimise la taille moyenne des ensembles parmi tous les prédicteurs de couverture marginale $\geq 1 - \alpha$, mais peut sous-couvrir les questions difficiles.
- **APS** (*Adaptive Prediction Sets*) : on trie les options par probabilité décroissante $p_{(1)} \geq p_{(2)} \geq \dots$ et on définit $s(x_i, y) = \sum_{j:p_{(j)} \geq p_{i,y}} p_{(j)}$. L’ensemble est construit en cumulant les options par probabilité décroissante jusqu’à atteindre la masse $\hat{q}_\alpha$. APS exploite l’ensemble du vecteur de probabilités, ce qui le rend plus conservateur (couverture plus stable, ensembles parfois plus grands).

Pour les 107 questions MMLU, nous tirons aléatoirement un split calibration/test ($\sim 50/57$) et reportons les résultats sur le test.

5.3 Résultats

Les log-probabilités classent mieux que la confiance déclarée. La figure 1 montre que les scores fondés sur les log-probabilités internes permettent un classement nettement supérieur. À 10–20% de couverture, l’accuracy atteint 80% à 85% pour ces signaux, contre des valeurs nettement plus faibles pour la confiance verbalisée. Le modèle est donc capable d’ordonner ses réponses selon leur fiabilité, même si sa capacité à *exprimer* cette incertitude en langage naturel reste limitée.




FIGURE 1 – Accuracy en fonction de la couverture pour différents signaux de confiance sur MMLU. Lecture : à $\gamma = 0,2$, on conserve les 20% de questions les plus confiantes selon le score considéré.

Surconfiance et désalignement interne/déclaré. Les scores issus des log-probabilités sont très concentrés près de 1 (softmax piqué) mais conservent une légère séparation entre réponses correctes et incorrectes (annexe C, Figure 11). La confiance interne est systématiquement plus élevée que la confiance verbalisée (Figure 12) : ces deux signaux ne sont pas de simples transformations l’un de l’autre.

Prédiction conforme : couverture vs taille. La figure 2 et le tableau 4 présentent les résultats de LAC et APS pour différents niveaux de risque α . Les deux méthodes respectent globalement la garantie théorique de couverture $\geq 1 - \alpha$, mais avec des arbitrages distincts. APS sur-couvre systématiquement la cible (couverture empirique supérieure à $1 - \alpha$), au prix d’ensembles plus grands. LAC est plus compact (singletons en moyenne pour $\alpha = 0,1$ sur les questions faciles) mais peut sous-couvrir légèrement pour certaines valeurs d’ α , en raison du faible nombre de calibration.




FIGURE 2 – Couverture empirique et taille moyenne des ensembles pour LAC et APS sur MMLU, en fonction du niveau de risque α .

TABLE 4 – Synthèse des résultats de prédiction conforme sur MMLU. La couverture cible est $1 - \alpha$; la taille moyenne est exprimée sur 4 options.

α	Couverture LAC	Couverture APS	Taille moyenne (LAC / APS)
0,05	~ 0,94	~ 0,97	~ 1,9 / ~ 2,3
0,10	~ 0,88	~ 0,93	~ 1,5 / ~ 1,9
0,20	~ 0,79	~ 0,85	~ 1,1 / ~ 1,5

Cet arbitrage classique entre fiabilité statistique et précision de l’ensemble est conforme aux résultats de Ye et al. (2024). Le choix entre LAC et APS dépend de l’usage : pour un système de *decision support* où l’utilisateur peut traiter plusieurs options plausibles, APS est préférable (couverture plus robuste) ; pour un système de *rejet* où l’on souhaite n’afficher qu’une réponse quand le modèle est confiant, LAC produit plus de singletons.

Limites. L’analyse repose sur 107 questions et une calibration sur ~ 50 observations, ce qui introduit une variabilité importante autour des couvertures empiriques. La forte concentration des softmax limite par ailleurs l’interprétation des scores comme probabilités calibrées.

6 Analyse de l’incertitude dans les générations longues

6.1 Motivation et cadre

Les sections précédentes portaient sur des réponses brèves. Or les LLMs sont surtout utilisés pour produire des explications détaillées et des raisonnements multi-étapes. Comment exploiter les signaux probabilistes dans ce cadre où l’espace des réponses devient très vaste, où plusieurs formulations peuvent être sémantiquement équivalentes mais avoir des probabilités différentes, et où les réponses peuvent être partiellement correctes ?

Nous nous plaçons dans un cadre intermédiaire : **GSM8K**, composé de problèmes mathématiques avec réponse numérique unique. Le modèle est invité à produire un raisonnement détaillé puis sa réponse finale, ce qui produit des générations longues (~ 188 tokens en moyenne) tout en conservant un critère de correction binaire et automatiquement

vérifiable. Pour chaque génération $(t_1, \dots, t_T)$ avec $\ell_k = \log p(t_k | t_{<k}, x)$ et $p_k = e^{\ell_k}$, nous construisons cinq familles d’indicateurs (statistiques de niveau, entropie, marges, événements extrêmes, structure temporelle), calculées séparément sur trois sous-séquences : raisonnement, réponse finale, ensemble de la génération. Les définitions complètes figurent en annexe D.

6.2 Résultats

Le signal d’erreur est principalement dans le raisonnement. Le tableau 5 compare plusieurs régressions logistiques selon les sous-ensembles de variables retenus. Le modèle complet atteint $AUC = 0,729$. La séparation par sous-séquence montre que le *raisonnement* (0,679) porte plus de signal que la *réponse finale* seule (0,665). Le retrait des variables de longueur ne dégrade que modérément l’AUC ($0,729 \rightarrow 0,718$) : le signal ne se réduit pas à un effet de longueur.

TABLE 5 – Performance de différents modèles logistiques sur GSM8K (CV 5-folds, version complète en annexe D.2).

Modèle	AUC	AP
Variables complètes	0,729	0,978
Sans variables de longueur	0,718	0,975
Raisonnement uniquement	0,679	0,968
Réponse finale uniquement	0,665	0,967
Sous-ensemble parcimonieux	0,698	0,971

Variables les plus informatives. Les variables d’*entropie sur le dernier tiers* de la génération sont les plus discriminantes (AUC univariées $\sim 0,68$). Les erreurs apparaissent souvent au moment de la conclusion : le modèle suit un cheminement cohérent, puis devient plus incertain en s’approchant d’une conclusion incorrecte. Les mesures d’*entropie maximale* et la *dynamique d’entropie* confirment cette interprétation : dans les réponses incorrectes, l’incertitude tend à augmenter ou rester élevée, alors qu’elle diminue dans les réponses correctes (analyse détaillée en annexe D.2). Aucune variable univariée ne suffit, mais une combinaison linéaire atteint $AUC = 0,73$. Ce résultat motive le passage à un classifieur supervisé multi-features (section 7).

7 Détection d’erreurs par WEPR

7.1 Méthode

WEPR (Moslonka et al., 2026) exploite directement les distributions top- K . Pour chaque position $j \in \{1, \dots, L\}$ et chaque rang $k \in \{1, \dots, K\}$, on définit la contribution entropique $s(k, j) = -p(k, j) \log p(k, j)$. La baseline non supervisée *EPR* est $EPR = \frac{1}{L} \sum_{j,k} s(k, j)$. WEPR remplace cette agrégation uniforme par un classifieur logistique appris sur les features $\bar{s}(k) = \frac{1}{L} \sum_j s(k, j)$ et $m(k) = \max_j s(k, j)$, soit un vecteur de dimension $2K$:

$$\hat{p}_i = \sigma \left(\beta_0 + \sum_k \beta_k \bar{s}_i(k) + \sum_k \gamma_k m_i(k) \right). \quad (1)$$

Avec $K = 10$, on a $2K + 1 = 21$ paramètres pour $n \simeq 74\,000$ observations ; aucune régularisation n’est nécessaire. Le dataset est constitué à partir de TriviaQA, étiqueté par

un juge LLM (84,7% de réponses correctes, 15,3% d’erreurs). Performance évaluée par CV stratifiée 5-folds et bootstrap *out-of-bag* ($B = 1000$).

7.2 Résultats

WEPR domine les baselines non supervisées. Le tableau 6 reporte les performances avec intervalles de confiance bootstrap. WEPR gagne +2,6 points d’AUC sur EPR et +5 points sur la perplexité. Les courbes ROC (annexe F) montrent que WEPR domine sur l’ensemble du spectre.

TABLE 6 – Comparaison des méthodes de détection sur TriviaQA-WEPR (bootstrap $B = 1000$).

Méthode	AUC	Écart-type	IC 95%
WEPR (logistique)	0,682	0,0105	[0,662; 0,702]
EPR (non supervisé)	0,656	0,0029	[0,650; 0,662]
Mean log-prob / Perplexité	0,633	0,0030	[0,627; 0,639]
Min log-prob	0,622	0,0029	[0,616; 0,628]

Interprétation des coefficients. Toutes les corrélations univariées $\rho(\bar{s}(k), y)$ sont négatives, comprises entre $-0,19$ et $-0,26$: chaque feature, prise isolément, est bien un signal d’erreur. Cependant, les features sont fortement corrélées entre rangs adjacents ($\rho > 0,9$), et la régression logistique distribue son signal de manière contre-intuitive ($\beta_1 > 0, \beta_2 < 0$, en raison de la multicollinéarité). Une analyse détaillée de cette inversion, robuste à la régularisation Ridge, est reportée en annexe F.2. L’enseignement méthodologique est qu’en présence de features fortement corrélées, les signes des coefficients ne peuvent pas être lus comme des effets bruts et doivent être confrontés aux corrélations univariées et à des modèles plus simples.

7.3 Extension non linéaire : XGBoost

L’analyse précédente met en évidence deux limites de la régression logistique : elle est strictement linéaire dans les features standardisées (donc incapable de capturer des seuils ou des interactions), et la non-monotonie de $s(p) = -p \log p$ rend l’interprétation des coefficients délicate. Pour mesurer la quantité de signal non linéaire restant dans les mêmes 20 features, nous remplaçons la régression logistique par un modèle **XGBoost** (gradient boosting d’arbres), entraîné sur le même vecteur de features et avec la même validation croisée stratifiée à 5 plis.

XGBoost atteint une AUC de $0,706 \pm 0,004$, soit +2,5 points sur la régression logistique et avec une variance entre folds divisée par deux (tableau 7). Ce gain est du même ordre que celui apporté par WEPR sur EPR : il existe donc une exploitation non linéaire des features entropiques que la formulation linéaire ne capture pas.

TABLE 7 – Synthèse des méthodes appliquées aux mêmes données TriviaQA-WEPR (CV 5-fold, mêmes 20 features pour WEPR et XGBoost).

Méthode	AUC	Type
EPR (non supervisé)	0,656	moyenne d'entropie
Régression logistique (WEPR)	$0,681 \pm 0,007$	linéaire
XGBoost sur features WEPR	$0,706 \pm 0,004$	non linéaire

Les analyses d'importance (gain, permutation importance, SHAP) convergent toutes vers une importance dominante de `mean_rank_10` : gain représentant 39,8% du total, permutation faisant chuter l'AUC de 0,19 point. La figure 3 (*beeswarm plot* SHAP) illustre la direction de cet effet : les valeurs élevées de `mean_rank_10` (points rouges) reçoivent des SHAP fortement négatifs (poussent vers *halluciné*), tandis que les valeurs faibles (points bleus) reçoivent des SHAP légèrement positifs. La majorité des observations ont une valeur faible (la grande masse à gauche de zéro), ce qui explique que la moyenne signée des SHAP soit positive bien que la corrélation avec y soit négative.




FIGURE 3 – *Beeswarm plot* SHAP des features WEPR pour le modèle XGBoost. Chaque point est une observation ; la couleur représente la valeur de la feature (rouge = élevée, bleu = faible). Les valeurs SHAP négatives poussent la prédiction vers *halluciné*.

Cette importance numérique de `mean_rank_10` ne signifie pas pour autant que ce rang soit en lui-même le meilleur signal : toutes les features `mean_rank_k` sont fortement corrélées entre elles ($\rho > 0,97$ entre rangs adjacents), et c’est en réalité `mean_rank_7` qui a la plus forte corrélation univariée avec y ($-0,26$). XGBoost choisit `mean_rank_10` pour résumer l’information de la queue de distribution, mais une régression logistique sur `mean_rank_7` seule produirait probablement une AUC comparable. Les détails complets (gain, SHAP par feature, mises en garde sur la multicollinéarité) figurent en annexe F.3.

7.4 Synthèse

WEPR améliore la détection d’erreurs par rapport aux approches non supervisées, et son extension non linéaire par XGBoost en tire encore +2,5 points d’AUC. Cependant, les performances restent modérées (AUC $\simeq 0,68$ – $0,71$). Cette borne reflète la difficulté intrinsèque du problème : les distributions top- K contiennent un signal réel mais limité, dont l’exploitation maximale nécessiterait des sources d’information complémentaires.

8 Comparaison transverse et transfert des méthodes

8.1 Motivation et trois ponts

Chaque section précédente a étudié un couple particulier (méthode, dataset). Pour évaluer la robustesse des méthodes, nous établissons trois ponts : (i) appliquer WEPR aux générations CoT de GSM8K ; (ii) appliquer l’*entropie sémantique* (Kuhn et al., 2023) à TriviaQA-numérique ; (iii) construire une table croisée scores $\times$ datasets unifiant les trois sections.

8.2 Transfert de WEPR à GSM8K

Réentraîné sur GSM8K (avec $K = 10$, exactitude 96,1%, $n = 1\,319$), WEPR atteint AUC = 0,726 sur la génération complète, soit le même niveau que la régression à 64 variables manuelles de la section 6 (0,729) : la représentation top- K encode déjà l’essentiel du signal capté manuellement. Sur le sous-ensemble aligné de 300 questions (utilisé dans la table croisée), WEPR atteint AUC = 0,922, contre 0,804 pour la perplexité : l’écart de +12 points est nettement plus marqué que sur TriviaQA-WEPR (+5 points). *Le bénéfice marginal de WEPR croît avec la longueur des séquences générées.*

Le tableau 8 évalue la transférabilité du modèle. L’asymétrie est complète : WEPR-TriviaQA appliqué à GSM8K atteint 0,79, soit une performance *supérieure* à son in-domain (0,68, effet de prévalence). À l’inverse, WEPR-GSM8K appliqué à TriviaQA s’effondre à 0,48, en-dessous du hasard : les coefficients sont d’amplitude beaucoup plus grande ($|6,77|$ contre $|0,56|$), symptôme d’un sur-ajustement aux 51 erreurs disponibles. *Un détecteur WEPR appris sur un grand corpus diversifié est transférable ; appris sur un petit corpus déséquilibré, il ne l’est pas.*

TABLE 8 – Transfert de WEPR — AUC selon le couple (modèle, dataset d’évaluation).

	Éval. TriviaQA	Éval. GSM8K
Modèle TriviaQA	0,681 (in-dom.)	0,793
Modèle GSM8K	0,477	0,829 (in-dom.)

8.3 Entropie sémantique appliquée à TriviaQA-numérique

Pour chaque question, nous générons $K = 5$ réponses à $T = 1,0$, regroupées par identité numérique au seuil près. L'entropie sémantique est $SE = -\sum_c P(c) \log P(c)$, où $P(c)$ est pondéré par la log-probabilité moyenne des réponses du cluster c .

Sur 2 574 questions, 94,8% ont $SE = 0$ (les 5 réponses coïncident). La SE moyenne diffère d'un facteur 17 entre correctes (0,013) et incorrectes (0,224), avec une corrélation de Spearman de +0,43 avec l'erreur absolue. Mais l'AUC de SE n'est que de 0,65, contre $\sim 0,86$ pour les meilleures log-probabilités : les ex-aequo massifs à $SE = 0$ pénalisent l'AUC tout en étant absorbés correctement par Spearman. **SE et log-probabilités mesurent des aspects différents** : la première capture l'*instabilité externe* entre échantillons indépendants, les secondes la *concentration locale* sur la propre génération du modèle. Nous identifions des questions où la probabilité jointe est proche de 1 et où le modèle produit pourtant 5 réponses différentes à $T = 1$: les deux signaux sont *complémentaires*.

8.4 Table croisée et lectures transverses

La figure 4 présente l'AUC de discrimination correct/incorrect pour chaque couple score $\times$ dataset.




FIGURE 4 – AUC de discrimination correct/incorrect, scores $\times$ datasets. Les cellules grises indiquent un score non applicable au dataset.

Trois observations émergent. Premièrement, *aucune hiérarchie n'est universelle* : la perplexité domine sur TriviaQA-num (~ 4 tokens, $AUC > 0,85$) tandis que WEPR domine sur GSM8K (~ 188 tokens, $AUC 0,92$). Deuxièmement, P_{joint} chute de 0,86 à 0,64 entre TriviaQA-num et TriviaQA-WEPR (mêmes données, filtre numérique vs textuel) : le produit $\prod_t p_t$ s'écroule mécaniquement vers zéro dès quelques tokens, phénomène invisible section par section. Troisièmement, ELI5 ressort comme le régime le plus difficile : aucun

score ne dépasse 0,66 d’AUC, ce qui définit une borne empirique de difficulté liée au caractère subjectif de la vérité dans ce dataset.

Calibration. Le tableau 9 reporte l’*Expected Calibration Error*. WEPR atteint sur TriviaQA-WEPR une ECE de 0,009 — quasi parfaite — car il sort directement la probabilité d’une régression logistique optimisée par log-loss. À l’inverse, P_{joint} atteint une ECE de 0,97 sur GSM8K : P_{joint} ne doit pas être interprétée comme une probabilité au-delà de quelques tokens.

TABLE 9 – ECE (10 bins) des scores interprétables comme probabilités.

Score	TriviaQA-num	TriviaQA-WEPR	GSM8K	ELI5
P_{joint}	0,096	0,384	0,969	0,820
P_{geo}	0,103	0,074	0,082	0,063
p_{min}	0,097	0,297	0,862	0,524
WEPR	0,030	0,009	0,245	0,687

8.5 Comparaison aux résultats de la littérature

Nos résultats peuvent être confrontés à ceux des papiers de référence. La comparaison reste indicative car les datasets, les modèles et les protocoles d’annotation diffèrent ; nous insistons sur les ordres de grandeur et la cohérence qualitative.

Confiance verbalisée et white-box (Xiong et al. 2024). Xiong et al. (2024) reportent sur leurs huit datasets (GSM8K, SVAMP, DateUnd, etc. – *pas* TriviaQA) une AUROC moyenne de la confiance verbalisée *vanilla* comprise entre 0,51 (GPT-3) et 0,63 (GPT-4), et un gain typique des méthodes white-box plafonnant à 0,52–0,60. Nous obtenons sur TriviaQA-num une AUROC de $\sim 0,68$ pour la confiance verbalisée (Gemini 2.0 Flash) et $\sim 0,86$ pour la probabilité géométrique sur les tokens de la réponse, soit nettement au-dessus de leurs valeurs. L’écart s’explique principalement par le dataset : TriviaQA-numérique conserve des questions factuelles courtes pour lesquelles le signal log-probabiliste est particulièrement concentré, alors que les benchmarks de raisonnement utilisés par Xiong et al. sont structurellement plus difficiles à classer. La hiérarchie qualitative est en revanche conforme : la confiance verbalisée est moins discriminante que les signaux internes, et toutes les méthodes souffrent d’une surconfiance systématique.

Prédiction conforme (Ye et al. 2024). Ye et al. (2024) évaluent LAC et APS à $\alpha = 0,10$ sur cinq benchmarks (dont MMLU) avec 9 familles de LLMs. Dans leur tableau principal (Section 6.1), les chiffres reportés sont la moyenne LAC+APS pour atténuer l’effet du choix du score de non-conformité ; les valeurs séparées figurent dans leur Annexe C.1. Pour Qwen-14B sur la tâche QA (MMLU), ils rapportent LAC : CR = 90,43%, SS = 2,39 ; APS : CR = 94,74%, SS = 3,21. Le papier indique explicitement que LAC « *can undercover hard instances and overcover easy ones* », qu’APS « *suffers from, on average, larger prediction sets* », et qu’« *APS tends to achieve higher coverage rates than LAC due to its larger prediction sets in most cases* » : l’observation qualitative que APS sur-couvre et produit des ensembles plus grands est donc directement reprise du papier. Sur nos 107 questions MMLU avec Gemini, nos chiffres LAC (CR $\sim 0,88$, SS $\sim 1,5$) et la sur-couverture relative d’APS sont cohérents avec ce schéma. Notre légère sous-couverture

LAC sous la cible 0,90 s’explique par le faible nombre de calibration (~ 50 obs.), bien en deçà de leurs 10 000 instances par tâche.

WEPR (Moslonka et al. 2025). Moslonka et al. (2026) reportent sur TriviaQA des AUC de WEPR comprises entre 0,82 (Mistral-Small-24B) et 0,86 (Phi-4, Ministral-8B), avec un gain WEPR–EPR de +4 à +7 points. Nos chiffres correspondants sont $AUC_{WEPR} = 0,682$ et $AUC_{EPR} = 0,656$, avec un gain de +2,6 points : les AUC absolues sont sensiblement plus basses, et le gain marginal plus modeste. Deux raisons probables. D’une part, le modèle utilisé diffère (Gemini 2.0 Flash chez nous, Mistral / Phi / Ministral chez eux) : notre LLM est plus petit, ce qui peut affecter à la fois la qualité brute des réponses et la structure des distributions top- K . D’autre part, le protocole d’annotation diffère : Moslonka et al. (2026) utilisent un appariement à des réponses de référence multiples, alors que nous utilisons un juge LLM unique, ce qui produit un déséquilibre de classes (84,7% de correctes) plus marqué que dans leur protocole et peut limiter la marge d’amélioration apportée par l’apprentissage supervisé. Nous avons par ailleurs repris la valeur $K = 10$ utilisée par Moslonka et al. (2026), qui rapportent un plateau de performance autour de $K \approx 8$ –10 rangs accessibles. Nous n’avons pas conduit d’analyse de sensibilité propre sur cet hyperparamètre : tester $K \in \{5, 8, 10, 15\}$ pour vérifier indépendamment l’existence et la position du plateau sur notre cadre constitue un prolongement naturel.

SelfCheckGPT (Manakul et al. 2023). Manakul et al. (2023) évaluent leurs cinq variantes sur WikiBio (passages biographiques GPT-3 annotés au niveau phrase). Les meilleures variantes atteignent une AUC-PR (NonFact) de 93,4% pour SelfCheck-Prompt et 92,5% pour SelfCheck-NLI, contre 87,5% pour la baseline grey-box $\text{Max}(-\log p)$. La tâche n’est pas directement comparable à nos expériences (factualité phrase-par-phrase sur des biographies, vs détection d’erreur sur réponse courte). Nous nous limitons à reprendre l’*intuition centrale* – l’instabilité entre échantillons indépendants comme signal d’incertitude – via l’entropie sémantique de Kuhn et al. (2023) appliquée à TriviaQA-num. Sur ce cadre, notre AUC SE de 0,65 et la corrélation Spearman de +0,43 avec l’erreur absolue confirment qualitativement leur résultat : la cohérence entre générations capture une dimension d’incertitude que les log-probabilités locales manquent.

Synthèse de la comparaison. Trois constats émergent. Premièrement, les hiérarchies qualitatives observées dans la littérature se retrouvent dans notre travail (verbalisée $<$ white-box $<$ supervisée multi-features pour la détection ; APS plus conservateur que LAC). Deuxièmement, les AUC absolues dépendent fortement du couple (modèle, dataset) : nos chiffres sur TriviaQA-num sont *plus élevés* que ceux de Xiong et al., et nos chiffres WEPR sur TriviaQA-WEPR sont *plus bas* que ceux de Moslonka et al. Cette double divergence interdit toute conclusion absolue mais souligne que la quantification d’incertitude est sensible au régime de génération. Troisièmement, les phénomènes que nous mettons au jour – l’effondrement de P_{joint} avec la longueur, l’asymétrie du transfert WEPR entre datasets, la complémentarité log-probabilités / entropie sémantique – ne sont pas explicitement traités dans les papiers cités, et constituent les apports propres de notre dispositif transverse.

9 Conclusion

Au-delà de la juxtaposition des sections, ce travail dégage un cadre articulé autour de *trois échelles d'incertitude*. À l'**échelle locale du token**, la distribution sur le prochain token discrimine très bien sur des sorties courtes (AUC $> 0,85$ sur TriviaQA-num) mais sature sur les générations longues (probabilité jointe écrasée vers zéro) et n'est jamais directement calibrée. À l'**échelle structurelle de la séquence**, la dynamique de l'incertitude (entropie en fin de génération, distributions top- K) est exploitée par WEPR qui atteint AUC $= 0,92$ sur GSM8K. À l'**échelle externe de l'instabilité entre échantillons**, l'entropie sémantique distingue fortement les réponses incorrectes (SE moyenne $\times 17$) et capture une dimension complémentaire des log-probabilités internes.

Ce qui fonctionne. Les log-probabilités internes contiennent un signal réel sur la fiabilité, plus fort que les scores verbalisés. Les réponses incorrectes sont associées à une incertitude plus instable, en particulier dans les dernières étapes de la génération. Une combinaison supervisée (WEPR) dépasse systématiquement les approches univariées sur les générations longues, et son entraînement sur un grand corpus diversifié produit un détecteur transférable. La prédiction conforme fournit des garanties rigoureuses pour les QCM.

Limitations. Les performances restent modérées (AUC 0,68–0,73 sur la détection d'erreurs dans TriviaQA), loin de la perfection nécessaire pour un déploiement non supervisé. Les scores verbalisés sont structurellement mal calibrés (moyenne 0,96 vs exactitude 0,86). Les performances chutent fortement sur les tâches à vérité subjective (ELI5).

Perspectives. Quatre pistes naturelles se dégagent : (i) combiner les features WEPR et l'entropie sémantique, qui mesurent des dimensions complémentaires ; (ii) explorer des modèles non linéaires plus expressifs sur les distributions top- K ; (iii) tester la transférabilité inter-modèles (un détecteur entraîné sur Gemini fonctionne-t-il sur GPT-4 ou Claude ?) ; (iv) passer d'une détection passive à des approches interventionnelles (décodage contraint, sampling guidé par un détecteur, rejet conditionnel à la prédiction conforme). Le chemin vers des LLMs vraiment dignes de confiance passe par une meilleure articulation de ces différentes échelles d'incertitude avec des sources d'information complémentaires (vérification factuelle, contraintes de décodage, feedback humain).

A Statistiques descriptives détaillées des datasets

A.1 GSM8K




FIGURE 5 — Synthèse descriptive du dataset GSM8K (1 319 questions).

Synthèse — GSM8K. Le split de test contient 1 319 questions (≈ 46 mots en moyenne), avec en moyenne 3,5 valeurs numériques par énoncé et un signal monétaire (présence de \$, dollar, cost, price, pay...) dans 34,7 % des cas. Les indices d'opérations attendues (additions, soustractions, multiplications, divisions, pourcentages) couvrent l'essentiel des questions, ce qui justifie l'usage de GSM8K comme banc de test d'arithmétique en chaîne. La précision globale du modèle générateur est de 95,6 % (1 261/1 319), laissant 58 erreurs exploitables pour l'analyse de confiance.

A.2 MMLU




FIGURE 6 – Synthèse descriptive du dataset MMLU.

Synthèse — MMLU. L'échantillon de référence couvre 57 sujets et 500 questions (longueur moyenne ≈ 44 mots). La distribution initiale des bonnes réponses parmi $\{A, B, C, D\}$ est légèrement biaisée (sur-représentation de la position D) ; nous appliquons donc une **permutation aléatoire des choix** avant chaque génération, ce qui ré-uniformise la distribution et garantit que la position de la bonne réponse ne constitue pas un signal exploitable par le modèle (figure 7). Les sujets les plus représentés sont *professional_law*, *moral_scenarios* et *miscellaneous*, ce qui couvre des compétences hétérogènes (raisonnement juridique, dilemmes éthiques, culture générale). Pour la prédiction conforme évaluée en section 5 et l'annexe E, on travaille sur un sous-ensemble de 107 questions pour lesquelles les top- K log-probabilités sont disponibles.




FIGURE 7 – Distribution des bonnes réponses sur MMLU avant (gauche) et après (droite) permutation aléatoire des choix. La permutation rétablit une distribution proche de l’uniforme attendue (ligne pointillée).

A.3 TriviaQA




FIGURE 8 – Synthèse descriptive de TriviaQA-numérique (3 397 questions).




FIGURE 9 – Synthèse descriptive de TriviaQA-WEPR (73 793 questions).

A.4 ELI5




FIGURE 10 – Synthèse descriptive d’ELI5 (100 questions).

B Définition formelle des scores de confiance (TriviaQA)

Soit $(t_1, \dots, t_T)$ la séquence de tokens générée pour la question x_i , et $p_k = p(t_k | t_{<k}, x_i)$ la probabilité conditionnelle de chaque token. Les scores comparés en section 4 sont :

$$P_i^{(\text{joint})} = \prod_{k=1}^T p_k \quad (\text{probabilité jointe})$$

$$P_i^{(\text{geo})} = \left(\prod_{k=1}^T p_k \right)^{1/T} \quad (\text{moyenne géométrique})$$

$$\text{Perplexity}_i = \exp \left(-\frac{1}{T} \sum_k \log p_k \right) \quad (\text{perplexité})$$

$$p_{\min,i} = \min_k p_k \quad (\text{probabilité minimale})$$

Chaque score est calculé une fois sur l’ensemble de la génération et une fois en restreignant aux tokens correspondant à la réponse numérique extraite par parsing JSON. La confiance verbalisée $C_i^{(\text{verb})}$ et la confiance par jugement externe $C_i^{(\text{judge})}$ sont obtenues par les prompts décrits en annexe H.

C Tableaux complets section TriviaQA-num

C.1 Distribution des scores




FIGURE 11 – Distribution des scores de confiance selon la justesse des réponses.




FIGURE 12 – Log-probabilités vs confiance déclarée. Les points au-dessus de la diagonale indiquent une confiance interne supérieure à la confiance verbalisée.

C.2 Tableaux numériques

TABLE 10: Résumé descriptif des différents scores de confiance

Confidence score	n	Mean	Min	Max
Conf verbalisée	3395	0.959623	0.100000	1.000000
Conf judge	3391	0.908139	0.010000	1.000000
Prob joint seq	3395	0.973050	0.000001	1.000000
Prob mean seq	3395	0.986256	0.101102	1.000000
Logprob sum seq	3395	-0.054219	-13.531101	0.000013
Logprob mean seq	3395	-0.018517	-2.291625	0.000004
Perplexity seq	3395	1.029233	0.999996	9.890997
Prob min seq	3395	0.974415	0.041966	1.000004
Prob joint all	3395	0.643894	0.000000	0.998803
Prob mean all	3395	0.978124	0.629143	0.999954
Logprob sum all	3395	-0.632608	-16.218891	-0.001197
Logprob mean all	3395	-0.022516	-0.463397	-0.000046
Perplexity all	3395	1.023202	1.000046	1.589464
Prob min all	3395	0.664897	0.038462	0.999041

TABLE 11: Capacité de discrimination des scores de confiance mesurée par l'AUC

Confidence score	n	Accuracy	AUC
Logprob mean seq	3395	0.863623	0.857214
Logprob sum seq	3395	0.863623	0.856671
Prob min seq	3395	0.863623	0.849128
Prob mean seq	3395	0.863623	0.843973
Prob joint seq	3395	0.863623	0.843529
Conf verbalisée	3395	0.863623	0.719345
Conf judge	3391	0.864347	0.679321
Prob mean all	3395	0.863623	0.631333
Logprob mean all	3395	0.863623	0.631333
Prob joint all	3395	0.863623	0.628024
Logprob sum all	3395	0.863623	0.628024
Prob min all	3395	0.863623	0.599377
Perplexity all	3395	0.863623	0.368667
Perplexity seq	3395	0.863623	0.142786

TABLE 12: Indicateurs de calibration des scores probabilistes

Confidence score	Brier	ECE
Prob joint seq	0.113852	0.113843
Conf verbalisée	0.117459	0.096000
Prob mean seq	0.120535	0.122633
Conf judge	0.124606	0.081828
Prob mean all	0.127775	0.114501
Prob min all	0.212136	0.223550
Prob joint all	0.215552	0.242211

TABLE 13: Corrélations entre les signaux de confiance et la distance à la vérité terrain (ensemble des réponses)

Confidence score	Distance	n	Pearson	Spearman	Effect
Conf verbalisée	abs_error	3395	-0.042457	-0.270188	faible à modéré
Conf verbalisée	log1p_abs_error	3395	-0.284130	-0.270188	faible à modéré
Conf verbalisée	log_error	3395	-0.126969	-0.264358	faible à modéré
Conf verbalisée	rel_error	3395	-0.044167	-0.261465	faible à modéré
Conf judge	abs_error	3391	-0.015042	-0.266805	faible à modéré
Conf judge	log1p_abs_error	3391	-0.162569	-0.266805	faible à modéré
Conf judge	log_error	3391	-0.111472	-0.265185	faible à modéré
Conf judge	rel_error	3391	-0.017058	-0.263898	faible à modéré
Logprob mean all	abs_error	3395	-0.018171	-0.156858	faible
Logprob mean all	log1p_abs_error	3395	-0.156985	-0.156858	faible
Logprob mean all	log_error	3395	-0.063546	-0.158993	faible
Logprob mean all	rel_error	3395	-0.021559	-0.155558	faible
Logprob sum all	abs_error	3395	-0.024755	-0.152897	faible
Logprob sum all	log1p_abs_error	3395	-0.152380	-0.152897	faible
Logprob sum all	log_error	3395	-0.062083	-0.154579	faible
Logprob sum all	rel_error	3395	-0.028308	-0.151168	faible
Prob min all	abs_error	3395	-0.011096	-0.117806	faible
Prob min all	log1p_abs_error	3395	-0.088027	-0.117806	faible
Prob min all	log_error	3395	-0.031333	-0.118992	faible
Prob min all	rel_error	3395	-0.014023	-0.115786	faible
Perplexity all	abs_error	3395	0.017245	0.156858	faible
Perplexity all	log1p_abs_error	3395	0.156418	0.156858	faible
Perplexity all	log_error	3395	0.062005	0.158993	faible
Perplexity all	rel_error	3395	0.020503	0.155558	faible
Prob mean all	abs_error	3395	-0.018971	-0.156858	faible
Prob mean all	log1p_abs_error	3395	-0.156938	-0.156858	faible
Prob mean all	log_error	3395	-0.064649	-0.158993	faible
Prob mean all	rel_error	3395	-0.022465	-0.155558	faible
Prob joint all	abs_error	3395	-0.030863	-0.152897	faible
Prob joint all	log1p_abs_error	3395	-0.135008	-0.152897	faible
Prob joint all	log_error	3395	-0.063948	-0.154579	faible
Prob joint all	rel_error	3395	-0.035082	-0.151168	faible
Logprob mean seq	abs_error	3395	-0.002167	-0.425641	modéré
Logprob mean seq	log1p_abs_error	3395	-0.230650	-0.425641	modéré
Logprob mean seq	log_error	3395	-0.103590	-0.426609	modéré
Logprob mean seq	rel_error	3395	-0.002963	-0.425326	modéré
Logprob sum seq	abs_error	3395	-0.014186	-0.425553	modéré
Logprob sum seq	log1p_abs_error	3395	-0.192564	-0.425553	modéré
Logprob sum seq	log_error	3395	-0.077316	-0.426768	modéré
Logprob sum seq	rel_error	3395	-0.015566	-0.425616	modéré
Prob min seq	abs_error	3395	-0.025617	-0.414901	modéré
Prob min seq	log1p_abs_error	3395	-0.277212	-0.414901	modéré
Prob min seq	log_error	3395	-0.129688	-0.415452	modéré
Prob min seq	rel_error	3395	-0.027940	-0.413848	modéré
Perplexity seq	abs_error	3395	-0.000183	0.425641	modéré
Perplexity seq	log1p_abs_error	3395	0.170671	0.425641	modéré
Perplexity seq	log_error	3395	0.070058	0.426609	modéré
Perplexity seq	rel_error	3395	0.000278	0.425326	modéré
Prob mean seq	abs_error	3395	-0.005150	-0.493118	modéré
Prob mean seq	log1p_abs_error	3395	-0.262131	-0.493118	modéré
Prob mean seq	log_error	3395	-0.123225	-0.495540	modéré
Prob mean seq	rel_error	3395	-0.006231	-0.492954	modéré
Prob joint seq	abs_error	3395	-0.042301	-0.492527	modéré
Prob joint seq	log1p_abs_error	3395	-0.294001	-0.492527	modéré
Prob joint seq	log_error	3395	-0.141104	-0.494483	modéré
Prob joint seq	rel_error	3395	-0.045566	-0.491914	modéré

TABLE 14: Corrélations entre les signaux de confiance et la distance à la vérité terrain (réponses incorrectes uniquement)

Confidence score	Distance	n	Pearson	Spearman	Effect
Conf verbalisée	abs_error	463	-0.030027	-0.131958	faible
Conf verbalisée	loglp_abs_error	463	-0.119430	-0.131958	faible
Conf verbalisée	log_error	463	-0.053670	0.142835	faible
Conf verbalisée	rel_error	463	-0.035792	0.156776	faible
Conf judge	abs_error	460	-0.006305	-0.032685	quasi nul
Conf judge	loglp_abs_error	460	-0.125426	-0.032685	quasi nul
Conf judge	log_error	460	-0.129213	0.037922	quasi nul
Conf judge	rel_error	460	-0.012207	0.047376	quasi nul
Logprob mean all	abs_error	463	-0.005060	-0.047283	quasi nul
Logprob mean all	loglp_abs_error	463	-0.011949	-0.047283	quasi nul
Logprob mean all	log_error	463	-0.003188	-0.039990	quasi nul
Logprob mean all	rel_error	463	-0.012972	-0.021579	quasi nul
Logprob sum all	abs_error	463	-0.016364	-0.043605	quasi nul
Logprob sum all	loglp_abs_error	463	-0.013528	-0.043605	quasi nul
Logprob sum all	log_error	463	-0.004346	-0.021224	quasi nul
Logprob sum all	rel_error	463	-0.024170	-0.003246	quasi nul
Prob min all	abs_error	463	-0.006719	-0.002648	quasi nul
Prob min all	loglp_abs_error	463	-0.009901	-0.002648	quasi nul
Prob min all	log_error	463	0.009012	0.038276	quasi nul
Prob min all	rel_error	463	-0.016270	0.053115	très faible
Perplexity all	abs_error	463	0.003264	0.047283	quasi nul
Perplexity all	loglp_abs_error	463	0.008786	0.047283	quasi nul
Perplexity all	log_error	463	0.000089	0.039990	quasi nul
Perplexity all	rel_error	463	0.010631	0.021579	quasi nul
Prob mean all	abs_error	463	-0.006841	-0.047283	quasi nul
Prob mean all	loglp_abs_error	463	-0.015102	-0.047283	quasi nul
Prob mean all	log_error	463	-0.006134	-0.039990	quasi nul
Prob mean all	rel_error	463	-0.015233	-0.021579	quasi nul
Prob joint all	abs_error	463	-0.047488	-0.043605	quasi nul
Prob joint all	loglp_abs_error	463	-0.061255	-0.043605	quasi nul
Prob joint all	log_error	463	-0.041647	-0.021224	quasi nul
Prob joint all	rel_error	463	-0.060540	-0.003246	quasi nul
Logprob mean seq	abs_error	463	0.023010	-0.146024	faible
Logprob mean seq	loglp_abs_error	463	-0.003988	-0.146024	faible
Logprob mean seq	log_error	463	-0.012803	-0.214042	faible à modéré
Logprob mean seq	rel_error	463	0.019848	-0.192430	faible
Logprob sum seq	abs_error	463	0.005245	-0.152643	faible
Logprob sum seq	loglp_abs_error	463	-0.003516	-0.152643	faible
Logprob sum seq	log_error	463	-0.000056	-0.185736	faible
Logprob sum seq	rel_error	463	0.001876	-0.165006	faible
Prob min seq	abs_error	463	0.000384	-0.132909	faible
Prob min seq	loglp_abs_error	463	-0.032132	-0.132909	faible
Prob min seq	log_error	463	-0.032686	-0.158881	faible
Prob min seq	rel_error	463	-0.005630	-0.138356	faible
Perplexity seq	abs_error	463	-0.018036	0.146024	faible
Perplexity seq	loglp_abs_error	463	0.000509	0.146024	faible
Perplexity seq	log_error	463	0.001004	0.214042	faible à modéré
Perplexity seq	rel_error	463	-0.015957	0.192430	faible
Prob mean seq	abs_error	463	0.024038	-0.149965	faible
Prob mean seq	loglp_abs_error	463	-0.010225	-0.149965	faible
Prob mean seq	log_error	463	-0.023712	-0.222229	faible à modéré
Prob mean seq	rel_error	463	0.020074	-0.198807	faible
Prob joint seq	abs_error	463	-0.020382	-0.152014	faible
Prob joint seq	loglp_abs_error	463	-0.051953	-0.152014	faible
Prob joint seq	log_error	463	-0.044534	-0.180300	faible
Prob joint seq	rel_error	463	-0.027630	-0.158374	faible

D Indicateurs et tableaux pour GSM8K (générations longues)

D.1 Indicateurs construits sur les log-probabilités

Pour chaque génération $(t_1, \dots, t_T)$ avec $\ell_k = \log p(t_k | t_{<k}, x)$ et $p_k = e^{\ell_k}$:

Statistiques de niveau. Moyennes, médianes, min/max et écart-type des suites (ℓ_k) et (p_k) .

Incertitude. Entropie $H_k = -\sum_v p(v | t_{<k}, x) \log p(v | t_{<k}, x)$ et ses agrégats $(\bar{H}, H_{\max}, H_{\min})$.

Marge. $m_k = p_k^{(1)} - p_k^{(2)}$ (différence entre les deux tokens les plus probables à la position k).

Persistence. Longueur maximale d’une plage de tokens dont la log-probabilité est inférieure à un seuil c :

$$L_c = \max\{r : \exists j, \ell_j < c, \dots, \ell_{j+r-1} < c\}.$$

Structure temporelle. Pour une variable z_k , moyennes sur les tiers I_1, I_2, I_3 de la génération :

$$\bar{z}^{(j)} = \frac{1}{|I_j|} \sum_{k \in I_j} z_k,$$

ainsi que les différences $\bar{z}^{(3)} - \bar{z}^{(1)}$.

Sous-séquences. Tous les indicateurs sont calculés séparément sur les tokens du raisonnement, les tokens de la réponse finale, et l’ensemble de la génération.

D.2 Tableaux complets

TABLE 15 – Performance des différents ensembles de variables pour la détection des erreurs.

Feature set	Nb. features	ROC-AUC	Average Precision
All variables	64	0.729	0.978
All variables (without length)	61	0.718	0.976
Interpretable subset	11	0.698	0.975
Reasoning only	21	0.679	0.972
Reasoning only (without length)	20	0.679	0.972
Full-generation only	21	0.669	0.969
Final-answer only	21	0.665	0.972
Full-generation only (without length)	20	0.663	0.968

TABLE 16 – Plus discriminantes variables univariées entre réponses correctes et incorrectes.

Variable	Mean correct	Mean wrong	AUC	FDR-BH
Full generation : entropymeans on last third	0.077	0.158	0.681	0.000
Reasoning : entropymeans on last third	0.083	0.177	0.681	0.000
Reasoning : entropy max	1.220	1.349	0.675	0.000
Full generation : entropy max	1.220	1.349	0.674	0.000
Full generation : top1means on last third	-0.045	-0.099	0.670	0.000
Reasoning : entropy std	0.249	0.300	0.668	0.000
Full generation : entropy std	0.247	0.298	0.668	0.000
Reasoning : top1means on last third	-0.049	-0.110	0.667	0.000
Full generation : entropy mean	0.114	0.165	0.666	0.000
Reasoning : entropy mean	0.116	0.171	0.665	0.000

TABLE 17 – Coefficients du modèle logistique construit sur le sous-ensemble interprétable de variables.

Variable	Coefficient
Reasoning : margin mean	1.526
Full generation : margin mean	-1.257
Reasoning : entropy last minus mean on first third	-0.473
Reasoning : length	-0.459
Reasoning : entropy mean	-0.294
Reasoning : longest run lp below -2	0.294
Reasoning : entropy max	-0.135
Full generation : length	-0.088
Reasoning : margin min	0.060
Final answer : margin mean	0.026
Reasoning : top1 min	0.021

E Prédiction conforme sur MMLU : compléments

E.1 Scores de non-conformité

Soient $(p_{i,A}, p_{i,B}, p_{i,C}, p_{i,D})$ les probabilités softmax obtenues à partir des log-probabilités des quatre options pour la question i . On note $p_{(1)} \geq p_{(2)} \geq p_{(3)} \geq p_{(4)}$ les probabilités triées par ordre décroissant.

LAC. Le score de non-conformité est $s_{\text{LAC}}(x_i, y) = 1 - p_{i,y}$. Pour un seuil $\hat{q}_\alpha$, l'ensemble est $\mathcal{C}_{\text{LAC}}(x_i) = \{y : p_{i,y} \geq 1 - \hat{q}_\alpha\}$.

APS. Le score cumule les masses des options strictement plus probables, plus celle de l'option courante :

$$s_{\text{APS}}(x_i, y) = \sum_{j: p_{(j)} > p_{i,y}} p_{(j)} + p_{i,y}.$$

L'ensemble s'obtient en empilant les options par probabilité décroissante jusqu'à atteindre la masse $\hat{q}_\alpha$.

E.2 Protocole de calibration

Sur les 107 questions disposant des log-probabilités complètes, nous tirons aléatoirement un split calibration/test de tailles approximatives 50/57. Le quantile empirique

$$\hat{q}_\alpha = \text{Quantile}\left(\{s_i\}_{i=1}^{n_{\text{cal}}}; \frac{\lceil (n_{\text{cal}}+1)(1-\alpha) \rceil}{n_{\text{cal}}}\right)$$

est calculé sur le split calibration. Les couvertures et tailles moyennes reportées dans le tableau 4 sont mesurées sur le split test. Le faible nombre de calibration ($n_{\text{cal}} \simeq 50$) explique la variabilité importante des couvertures empiriques autour de la cible $1 - \alpha$ et la légère sous-couverture occasionnelle de LAC.

F WEPR : compléments

F.1 Courbes ROC et distributions de score

Méthode	AUC moyenne	Écart-type	IC à 95 %
WEPR	0.682	0.0105	[0.662, 0.702]
EPR	0.656	0.0029	[0.650, 0.662]
Mean log-prob	0.633	0.0030	[0.627, 0.639]
Perplexité	0.633	0.0030	[0.627, 0.639]
Min log-prob	0.622	0.0029	[0.616, 0.628]

FIGURE 13 – Courbes ROC comparant WEPR aux baselines non supervisées.




FIGURE 14 – Distribution des scores WEPR pour réponses correctes et erreurs.

F.2 Coefficients de la régression logistique et inversion de signe

Les coefficients standardisés du modèle complet sont : $\beta_0 = +1,82$, $\beta_1 = +0,52$, $\beta_2 = -0,56$, $\beta_{10} = -0,13$, $\gamma_1 = -0,19$, $\gamma_{10} = -0,17$. L'intercept β_0 absorbe le biais de prévalence ($\log(0,847/0,153) \approx +1,71$) ; il chute à $+0,11$ en utilisant `class_weight=balanced`, sans changer l'AUC.

L'inversion $\beta_1 > 0, \beta_2 < 0$ paraît contre-intuitive. Trois faits l'expliquent : (i) la corrélation entre $\bar{s}(1)$ et $\bar{s}(2)$ est de $+0,96$; (ii) les corrélations univariées avec y sont *toutes deux négatives* ($-0,19$ et $-0,18$) ; (iii) en restreignant la régression à ces deux features, les deux coefficients restent négatifs.

TABLE 18 – Évolution de β_1 et β_2 selon les features incluses.

Modèle	β_1	β_2	AUC
Logistique sur $\bar{s}(1)$ seul	$-0,46$	—	0,638
Logistique sur $\bar{s}(2)$ seul	—	$-0,46$	0,636
Logistique sur $\bar{s}(1), \bar{s}(2)$	$-0,37$	$-0,10$	0,638
Logistique complète (20 features)	$+0,52$	$-0,56$	0,681

L'inversion n'apparaît que dans le modèle complet, en raison de la multicollinéarité avec $\bar{s}(3), \dots, \bar{s}(10)$ qui absorbent l'essentiel du signal d'incertitude global. La régularisation Ridge (testée à $C \in \{10; 1; 0,1; 0,01\}$) ne corrige pas l'inversion mais réduit proportionnellement les amplitudes. *Sur des features fortement corrélées, les signes des coefficients ne sont pas interprétables comme des effets bruts* : il faut systématiquement confronter aux corrélations univariées et à des modèles plus simples.

F.3 Extension non linéaire : XGBoost

Avec les mêmes 20 features et le même schéma de validation croisée, XGBoost (`n_estimators=400`, `max_depth=4`, `learning_rate=0.05`) atteint $AUC = 0,706 \pm 0,004$, soit +2,5 points sur la régression logistique avec une variance entre folds réduite de moitié.

Importance des features. Trois mesures convergentes (gain XGBoost en valeur absolue, permutation importance mesurée comme chute d'AUC, |SHAP| moyen sur les observations) :

- **Gain XGBoost** : `mean_rank_10` = 54,7 (39,8% du total), `mean_rank_9` = 22,1 (16,1%). Les autres features se partagent 44,1%.
- **Permutation importance** : `mean_rank_10` fait chuter l'AUC de 0,19 point ; aucune autre feature ne dépasse 0,016.
- **SHAP** : |SHAP| moyen de 0,542 pour `mean_rank_10`, 0,136 pour `mean_rank_9`, puis toutes les autres en deçà de 0,09.

Mise en garde. Toutes les features `mean_rank_k` sont fortement corrélées entre elles ($\rho > 0,97$ entre rangs adjacents). `mean_rank_7` a la plus forte corrélation univariée avec y ($-0,26$), et non `mean_rank_10` ($-0,25$). Une régression logistique sur `mean_rank_10` seule atteint $AUC = 0,708$, supérieure à la régression complète ; mais une régression sur `mean_rank_7` seule produirait probablement la même AUC. *Le rôle dominant de `mean_rank_10` dans XGBoost reflète la structure de partitionnement plutôt qu'une supériorité intrinsèque du dixième rang.*

G Transfert WEPR et entropie sémantique : compléments

G.1 Protocole de transfert

Le tableau 8 du corps évalue la transférabilité de WEPR entre TriviaQA-WEPR et GSM8K. Le protocole est le suivant :

- **Modèle TriviaQA** : WEPR entraîné sur l'intégralité de TriviaQA-WEPR ($n = 73\,793$, prévalence d'erreurs 15,3%), avec les 20 features standard ($\bar{s}(k), m(k)$ pour $k = 1, \dots, 10$).
- **Modèle GSM8K** : WEPR entraîné sur les 1 319 générations GSM8K (prévalence d'erreurs 3,9%, soit 51 exemples positifs), même vecteur de features calculé sur la génération complète.
- **Évaluation in-domain** : CV stratifiée 5-folds sur le dataset d'entraînement.
- **Évaluation cross-domain** : le modèle entraîné sur l'un est appliqué sur l'autre sans

réajustement, après standardisation des features sur le dataset cible (la distribution moyenne/écart-type des $\bar{s}(k)$ diffère entre datasets).

G.2 WEPR sur GSM8K par sous-séquence

TABLE 19 – WEPR entraîné sur GSM8K — performance par sous-séquence (CV 5-folds). EPR désigne la baseline non supervisée sur la même sous-séquence.

Sous-séquence	Tokens (moy.)	AUC WEPR (CV)	AUC EPR
Full	188	$0,726 \pm 0,149$	0,814
Reasoning	180	$0,717 \pm 0,156$	0,811
Answer	8	$0,571 \pm 0,080$	0,640

L'écart entre *reasoning* et *answer* confirme que le signal d'erreur réside dans le raisonnement, pas dans la conclusion. Sur GSM8K, EPR à elle seule atteint 0,81 : la pondération apprise apporte peu sur ce dataset très déséquilibré, et la variance de WEPR (0,15) reflète l'instabilité due aux 51 erreurs seulement.

G.3 Sous-ensemble aligné pour la table croisée

La table croisée scores $\times$ datasets (section 8.4, figure 4) repose, pour les colonnes GSM8K, sur un sous-ensemble de 300 questions tiré aléatoirement du dataset complet. Ce sous-ensemble permet d'aligner les coûts de calcul (génération de $K = 5$ réponses pour l'entropie sémantique, calculs WEPR) et d'avoir une base commune avec TriviaQA-num. Sur ce sous-ensemble, les chiffres rapportés en section 8.2 (WEPR-GSM8K 0,922 ; perplexité 0,804) ne sont pas comparables à ceux de la CV intégrale (WEPR 0,726 sur $n = 1319$) : l'écart vient à la fois du sous-échantillonnage et de la prévalence d'erreurs dans le tirage.

G.4 Entropie sémantique : définition formelle et clustering

Pour une question x et K générations $\{r_1, \dots, r_K\}$ avec log-probabilité moyenne $\bar{\ell}_k$, on partitionne les réponses en clusters d'équivalence sémantique $\mathcal{C}_1, \dots, \mathcal{C}_M$. La probabilité du cluster c est définie par marginalisation softmax sur les log-probabilités :

$$P(c) = \frac{\sum_{k \in \mathcal{C}_c} \exp(\bar{\ell}_k)}{\sum_{k=1}^K \exp(\bar{\ell}_k)}, \quad \text{SE} = - \sum_{c=1}^M P(c) \log P(c).$$

Lorsque toutes les réponses tombent dans le même cluster, $M = 1$ et $\text{SE} = 0$ par convention.

Clustering pour TriviaQA-num. Les réponses étant numériques, l'équivalence sémantique est définie par identité numérique au seuil près après parsing JSON (deux réponses dont les valeurs flottantes coïncident à 10^{-6} relatif). Lorsque le parsing échoue, on tombe sur un *fallback* NLI en demandant à un second LLM (Gemini 2.5 Flash) si deux textes désignent la même quantité numérique. Le prompt du juge NLI est reproduit en annexe H.

La distribution empirique du nombre de clusters obtenus pour les $K = 5$ générations est très concentrée sur la valeur 1 (toutes les générations tombent dans le même cluster), comme le montre le tableau ci-dessous.

TABLE 20 – Distribution du nombre de clusters parmi les $K = 5$ réponses générées (TriviaQA-num, $T = 1,0$, $n = 2574$).

Nombre de clusters	Proportion (%)
1	94,8
2	4,0
3	0,7
4	0,2
5	0,3

H Prompts utilisés

Tous les prompts sont rédigés en anglais (questions de TriviaQA, GSM8K et MMLU en anglais, meilleures performances des LLMs dans cette langue). Les sorties sont demandées au format JSON ou en lettre unique pour garantir la stabilité du parsing automatique.

H.1 TriviaQA-numérique : génération et confiance verbalisée

You must answer in STRICT JSON with exactly two keys: "answer" and "confidence".

Rules:

- Return ONLY the JSON object. No extra text, no markdown, no explanation.
- "answer": a number in decimal notation (examples: 1945, 3.14, -12.5).
No commas. No units. No text.
- "confidence": a float between 0 and 1 (inclusive). This number must be the confidence you have in the answer. If you respond 0.7 then 7 times out of 10 you are correct. Be careful, you must not overstate your confidence. It must be a JSON number, not a string.

Question:

{q}

H.2 TriviaQA-numérique : jugement externe (LLM-as-a-judge)

You are an assistant that evaluates the correctness of a model's answer to a question.

Return a single JSON object with exactly one key: "judge_confidence".

- "judge_confidence" must be a JSON number in $[0, 1]$.
- Return ONLY the JSON object. No markdown, no extra text.

The judge confidence must be the probability that the model's answer is correct, calibrated as best as possible. If the model's answer is very likely correct, return a value close to 1. If it's likely incorrect, return a value close to 0.

Question:

{question}

Model answer (numeric text):
{model_answer_text}

H.3 TriviaQA-WEPR : génération de la réponse libre

Pour la constitution du dataset WEPR (73 793 questions), nous utilisons un prompt plus léger qui sollicite une réponse textuelle d’une seule phrase, afin de couvrir l’intégralité du benchmark TriviaQA (et non plus uniquement les réponses numériques).

Answer the following question in exactly ONE short sentence.
Your sentence must contain the answer.
Do not add any preamble, explanation, or follow-up.

Question: {question}
Answer:

H.4 TriviaQA-WEPR : juge de factualité (annotation Y)

L’étiquette d’erreur $Y \in \{0, 1\}$ utilisée pour l’apprentissage de WEPR est produite par un second LLM (Gemini 2.0 Flash) confronté aux réponses de référence du dataset original. Le juge traite les questions par lots et retourne un vecteur booléen.

You are a strict factuality judge for trivia questions.

RULES:

- An answer is CORRECT (true) ONLY if it explicitly contains or directly matches one of the ACCEPTED ANSWERS listed below.
- Do NOT use your own knowledge. If the LLM answer gives a name, date, or fact that is NOT in the accepted answers list, it is INCORRECT, even if you know it to be factually related or equivalent.
- Minor spelling variations (e.g. capitalization, punctuation) are OK.
- Synonyms, aliases, or related facts NOT in the accepted list => false.

Return ONLY a JSON object in this exact format:

```
{"judgments": [true, false, true, ...]}
```

The array MUST have exactly N elements, in the same order.

No explanations, no markdown fences, just the JSON.

--- Item 1 ---

Question: {question}
Accepted answers: {gt1 | gt2 | ... | gt8}
LLM answer: {full_answer}
...

H.5 GSM8K : raisonnement *chain-of-thought* et réponse finale

Pour produire les générations longues analysées en section 6, nous demandons un raisonnement détaillé suivi d’une réponse au format JSON sur la dernière ligne. Cette structure permet à la fois d’extraire la réponse pour la métrique d’exactitude et de séparer les sous-séquences *raisonnement* et *réponse finale* pour le calcul des features.

You are a careful math problem solver.

Solve the following grade-school math problem. First, work through the problem step by step in clear English. Then, on the LAST line, output a JSON object with the final numeric answer in the form:

```
{"answer": <number>}
```

Rules:

- The reasoning must precede the JSON. Use plain English, no markdown.
- The final line must be ONLY the JSON object - no fences, no extra text.
- "answer" must be a number in decimal notation (no commas, no units, no text).

Question:

```
{q}
```

H.6 MMLU : choix forcé pour extraction des log-probabilités

Pour exploiter les log-probabilités sur les quatre options {A, B, C, D} (section 5), la sortie est contrainte à un unique caractère ASCII parmi {A, B, C, D}. Cette contrainte garantit que la première position de génération porte directement la distribution sur les quatre options et permet le calcul exact du softmax utilisé pour LAC et APS.

You must answer with EXACTLY ONE SINGLE LETTER among "A", "B", "C", "D". Only ASCII uppercase letters are allowed (Unicode code points: U+0041, U+0042, U+0043, U+0044).

No other token is acceptable: no spaces, no newlines, no punctuation, no explanations.

Question:

```
{q}
```

A) {choice_A}

B) {choice_B}

C) {choice_C}

D) {choice_D}

H.7 ELI5 : génération longue

Pour ELI5 (section 8), aucune contrainte JSON n'est imposée puisque la réponse n'est pas évaluable automatiquement. Le prompt demande une explication courte mais en langage naturel libre.

Explain the following like I'm 5 years old.

Use simple words, short sentences, and everyday analogies.

Keep your explanation to 3-5 sentences maximum.

Question: {question}

Explanation:

H.8 Entropie sémantique : juge NLI (clustering)

Lorsque le clustering par identité numérique échoue (réponses non parsables, formats hétérogènes), le clustering est complété par un juge NLI qui décide si deux réponses désignent la même valeur numérique. Le juge traite les paires par lots.

You are a semantic equivalence judge for short factual answers.

For each pair below, decide if Answer A and Answer B convey the SAME numeric value (after parsing).

Two answers are equivalent if they refer to the same number, allowing minor formatting differences (1,000 vs 1000) but NOT different values. If the values differ, even by 1, they are NOT equivalent.

Return ONLY a JSON object in this exact format:

```
{"equivalences": [true, false, true, ...]}
```

The array MUST have exactly N elements, in the same order.

No explanations, no markdown, just the JSON.

--- Pair 1 ---

Question: {q}

Answer A: {a}

Answer B: {b}

...

Références

- Xiong, M., Hu, Z., Lu, X., Li, Y., Fu, J., He, J., Hooi, B. (2024). Can LLMs Express Their Uncertainty? An Empirical Evaluation of Confidence Elicitation in LLMs. *ICLR 2024*.
- Manakul, P., Liusie, A., Gales, M. J. F. (2023). SelfCheckGPT : Zero-Resource Black-Box Hallucination Detection for Generative Large Language Models. *EMNLP 2023*, arXiv :2303.08896.
- Kuhn, L., Gal, Y., Farquhar, S. (2023). Semantic Uncertainty : Linguistic Invariances for Uncertainty Estimation in Natural Language Generation. *ICLR 2023*.
- Ye, F., Yang, M., Pang, J., Wang, L., Wong, D. F., Yilmaz, E., Shi, S., Tu, Z. (2024). Benchmarking LLMs via Uncertainty Quantification. *NeurIPS 2024*.
- Moslonka, C., Randrianarivo, H., Garnier, A., Malherbe, E. (2026). Learned Hallucination Detection in Black-Box LLMs using Token-level Entropy Production Rate. *arXiv :2509.04492v2*.
- Brown, T. B., et al. (2020). Language Models are Few-Shot Learners. *NeurIPS 2020*.
- Angelopoulos, A. N., Bates, S. (2023). Conformal Prediction : A Gentle Introduction. *Foundations and Trends in Machine Learning*, 16(4), 494–591.
- Cobbe, K., Kosaraju, V., Bavarian, M., et al. (2021). Training Verifiers to Solve Math Word Problems. *arXiv :2110.14168*.

- Hendrycks, D., Burns, C., Basart, S., et al. (2021). Measuring Massive Multitask Language Understanding. *ICLR 2021*.
- Joshi, M., Choi, E., Weld, D. S., Zettlemoyer, L. (2017). TriviaQA : A Large Scale Distantly Supervised Challenge Dataset for Reading Comprehension. *ACL 2017*.
- Fan, A., Jernite, Y., Perez, E., Grangier, D., Weston, J., Auli, M. (2019). ELI5 : Long Form Question Answering. *ACL 2019*.