



StatApp : Quantification statistique de
l'incertitude des grands modèles de langage
(LLM)

Rapport final

Auteurs : William Dejean, Grégoire Marguier, Kénan Darfilali et Samuel Macé

Encadrant : Alexis Vignard

1 Introduction

Les grands modèles de langage (*Large Language Models*, ou LLMs) occupent aujourd’hui une place croissante dans de nombreux usages, grâce à leur capacité à produire des réponses fluides, détaillées et souvent pertinentes sur une grande variété de sujets. Cependant, leur déploiement dans des environnements sensibles se heurte encore à une difficulté majeure : l’absence d’une mesure fiable de leur propre incertitude. Un LLM peut en effet produire une réponse erronée avec une assurance apparente comparable à celle d’une réponse correcte. Cette difficulté est renforcée par le fait que les scores de confiance verbalisés par les modèles sont souvent mal calibrés et peuvent être trompeurs. Dans ce contexte, il devient essentiel de disposer d’outils permettant d’évaluer plus rigoureusement la fiabilité des réponses générées.

Le projet **StatApp** s’inscrit dans cette perspective. Réalisé en partenariat avec **Société Générale**, il vise à développer des méthodes statistiques de quantification de l’incertitude des LLMs et de modèles associés.

1.1 Objectifs scientifiques

Le projet repose sur deux grandes familles d’approches complémentaires. Les approches *white-box* exploitent les signaux internes du modèle, tels que les log-probabilités des tokens, l’entropie, la perplexité ou la probabilité jointe de la séquence générée. À l’inverse, les approches *black-box* s’appuient sur des mécanismes externes, comme un LLM évaluateur, des méthodes d’auto-vérification telles que *SelfCheckGPT*, ou encore des approches supervisées comme *WEPR*.

Au-delà de la simple détection des réponses correctes, le projet s’intéresse également à des questions plus fines : calibration des scores, prédiction conforme, analyse de l’incertitude dans les générations longues, ou encore lien entre confiance et proximité à la vérité.

1.2 Cadre expérimental

Les expériences menées couvrent plusieurs types de tâches afin de tester la robustesse des méthodes proposées. Le benchmark **MMLU** est utilisé pour les questions à choix multiples, tandis que **GSM8K** et **TriviaQA** permettent d’étudier des réponses factuelles, souvent numériques ou courtes. Le dataset **ELI5** est mobilisé pour l’analyse de réponses longues et explicatives, et **MIDV** permet d’examiner la transférabilité de certaines approches à un cadre de classification de documents en vision par ordinateur.

L’ensemble de l’analyse repose sur plusieurs outils statistique comme le bootstrap, la validation croisée, ainsi que l’*accuracy-coverage*.

Table des matières

1	Introduction	i
1.1	Objectifs scientifiques	i
1.2	Cadre expérimental	i
2	Cas du QCM + conformal prediction ...	1
3	Lien entre score de confiance et proximité à la vérité	1
3.1	Motivation et cadre de l'analyse	1
3.2	Mesures de distance à la vérité	2
3.3	Définition des scores de confiance	3
3.4	Résultats	5
3.4.1	Dispersion des scores de confiance	5
3.4.2	Capacité de discrimination des scores de confiance	6
3.4.3	Calibration des scores probabilistes	7
3.4.4	Lien entre confiance et proximité à la vérité	8
3.4.5	Robustesse aux différentes mesures de distance	8
4	Analyse de l'incertitude dans les générations longues	9
4.1	Motivation et cadre de l'analyse	9
4.2	Construction des indicateurs à partir des log-probabilités	10
4.3	Résultats	11
4.3.1	Capacité globale de détection des erreurs	11
4.3.2	Analyse des variables les plus informatives	13
4.3.3	Rôle des différentes dimensions du signal	14
4.3.4	Conclusion	15
5	Détection d'hallucinations par WEPR	15
5.1	Motivation	15
5.2	Pipeline expérimental	16
5.3	Méthode	16
5.3.1	Contributions entropiques	16
5.3.2	Entropy Production Rate (EPR)	16
5.3.3	Weighted Entropy Production Rate (WEPR)	17
5.4	Apprentissage	17
5.5	Évaluation par bootstrap	18
5.6	Résultats	18
5.7	Interprétation	19
5.8	Conclusion	19

6 Conclusion	20
Annexes	21
A Prompts utilisés	21
A.1 Prompt pour la génération de la réponse et la confiance verbalisée	21
A.2 Prompt pour le jugement externe (LLM-as-a-judge)	21
B Tableaux de résultats	23

2 Cas du QCM + conformal prediction ...

3 Lien entre score de confiance et proximité à la vérité

3.1 Motivation et cadre de l'analyse

L'un des objectifs de ce projet est de mieux comprendre ce que signifie réellement la *confiance* exprimée par un Large Language Model. Lorsqu'un modèle produit une réponse accompagnée d'un score de confiance élevé, on s'attend intuitivement à ce que cette réponse soit plus fiable ou plus proche de la vérité.

Une manière naturelle d'évaluer cette intuition consiste à comparer deux quantités : d'une part un score de confiance associé à la réponse du modèle, et d'autre part une mesure de distance entre cette réponse et la vérité. Si le score de confiance constitue un bon indicateur de fiabilité, on devrait alors observer que les réponses associées à une confiance élevée sont, en moyenne, plus proches de la vérité.

Cette idée semble a priori simple, mais elle repose implicitement sur une hypothèse importante : celle selon laquelle la proximité à la réponse correcte reflète effectivement la qualité du raisonnement ayant conduit à cette réponse. Or cette hypothèse n'est pas toujours vérifiée. Dans certains cas, une réponse peut être numériquement proche de la vérité tout en reposant sur un raisonnement incorrect, tandis qu'un raisonnement plus pertinent peut conduire à une réponse légèrement plus éloignée en raison d'une erreur locale.

Un exemple simple permet d'illustrer ce phénomène. Considérons la question suivante :

Combien de paires différentes peut-on former avec 10 personnes ?

La bonne réponse correspond au nombre de combinaisons de deux personnes parmi dix :

$$\binom{10}{2} = \frac{10 \times 9}{2} = 45.$$

Supposons maintenant que deux modèles produisent les réponses suivantes.

Un premier modèle interprète la question comme : *combien de paires peut-on former simultanément avec 10 personnes*. Dans ce cas, il raisonne de la manière suivante : chaque paire contient deux personnes, donc avec dix personnes on peut former $10/2 = 5$ paires. La réponse proposée est alors 5.

Un second modèle adopte un raisonnement combinatoire plus proche du problème posé. Il observe que l'on peut choisir une première personne parmi dix, puis une seconde parmi

les neuf restantes, et conclut qu’il existe $10 \times 9 = 90$ paires possibles. Cette approche est structurellement proche du raisonnement correct, mais elle oublie que chaque paire est comptée deux fois.

Dans cet exemple, la réponse 5 est numériquement plus proche de la vérité que la réponse 90, bien qu’elle provienne d’une mauvaise compréhension du problème. À l’inverse, la réponse 90 résulte d’un raisonnement presque correct, mais conduit à une erreur plus importante.

Cet exemple met en évidence une difficulté fondamentale : la distance à la bonne réponse ne constitue pas nécessairement un indicateur fiable de la qualité du raisonnement sous-jacent. Autrement dit, une réponse peut être proche de la vérité pour de mauvaises raisons, et relativement éloignée pour de bonnes raisons.

Cette observation a une conséquence importante pour la construction de notre protocole expérimental. Si l’objectif est d’étudier la relation entre un score de confiance et la proximité à la vérité, il est nécessaire de travailler dans un cadre où la distance à la bonne réponse possède un sens interprétable.

Pour éviter cette ambiguïté, nous avons choisi de travailler sur des questions factuelles issues du dataset **TriviaQA**. Ces questions portent généralement sur des informations culturelles ou encyclopédiques bien définies (dates historiques, records, mesures, durées, etc.), pour lesquelles il existe une réponse correcte unique.

Nous avons cependant introduit une contrainte supplémentaire : nous avons conservé uniquement les questions dont la réponse attendue est un nombre. Ce filtrage permet de définir naturellement une notion de distance entre la réponse produite par le modèle et la vérité terrain.

Par exemple :

In what year were the Summer Olympic Games hosted in Montreal ?

La réponse correcte est : 1976

Dans ce type de question, une réponse comme 1975 ou 1977 est naturellement interprétée comme plus proche de la vérité qu’une réponse comme 1950. La distance numérique possède donc une signification claire et peut être utilisée comme une mesure d’erreur.

3.2 Mesures de distance à la vérité

Une fois le cadre expérimental défini, il reste à préciser comment mesurer l’écart entre la réponse produite par le modèle et la vérité terrain. Dans notre cadre, les réponses considérées sont des valeurs numériques, ce qui permet de définir naturellement différentes mesures de distance.

Soit y_i la valeur correcte associée à la question i , et $\hat{y}_i$ la réponse produite par le modèle. L’objectif est de quantifier l’erreur commise par le modèle à partir de ces deux quantités.

Nous considérons tout d’abord la **distance absolue**, définie par :

$$D_i^{(abs)} = |\hat{y}_i - y_i|.$$

Cette métrique correspond à l’erreur brute commise par le modèle. Elle constitue la mesure la plus directe de l’écart entre la prédiction et la valeur correcte.

Cependant, une même erreur absolue peut avoir des significations différentes selon l’ordre de grandeur de la valeur correcte. Par exemple, une erreur de 10 unités n’a pas la même importance si la valeur correcte est 50 ou si elle est 10 000. Pour tenir compte de cet effet d’échelle, nous introduisons également la **distance relative normalisée** :

$$D_i^{(rel)} = \frac{|\hat{y}_i - y_i|}{|y_i| + \varepsilon},$$

où $\varepsilon > 0$ est un terme de stabilisation permettant d’éviter les divisions par zéro lorsque la valeur correcte est proche de 0.

Enfin, pour certaines quantités strictement positives, il peut être pertinent de mesurer l’erreur sur une échelle logarithmique. Cela permet de capturer plus directement les écarts multiplicatifs entre la prédiction et la vérité. Nous considérons ainsi la **distance logarithmique** :

$$D_i^{(log)} = |\log(\hat{y}_i) - \log(y_i)|.$$

Ces différentes métriques permettent d’analyser la relation entre confiance et proximité à la vérité sous plusieurs angles, en capturant à la fois l’erreur brute, l’erreur relative et les écarts multiplicatifs.

3.3 Définition des scores de confiance

Afin d’étudier la relation entre confiance et proximité à la vérité, nous comparons plusieurs signaux de confiance produits par les modèles. Ces signaux correspondent à différentes manières d’estimer la fiabilité d’une réponse générée. Les prompts utilisés pour obtenir les scores fondés sur une interaction en langage naturel sont présentés en annexe.

Confiance verbalisée Dans un premier temps, le modèle est explicitement invité à fournir un score de confiance associé à la réponse qu’il vient de produire. La sortie attendue

est un objet JSON contenant une réponse numérique et un score de confiance compris entre 0 et 1. Ce score est interprété comme une probabilité subjective de correction de la réponse :

$$C_i^{(\text{verb})} \in [0, 1].$$

Par exemple, une valeur de 0.7 signifie que le modèle estime être correct environ 70% du temps pour ce type de réponse.

Confiance par jugement externe (*LLM-as-a-judge*) Nous considérons également une estimation externe de la plausibilité de la réponse. Dans ce cadre, un second modèle de langage reçoit la question ainsi que la réponse produite par le premier modèle et attribue un score de confiance reflétant la crédibilité de cette réponse :

$$C_i^{(\text{judge})} \in [0, 1].$$

Ce score peut être interprété comme une évaluation externe de la plausibilité de la réponse générée.

Scores fondés sur les log-probabilités internes du modèle Lors de la génération d’une réponse, le modèle produit une séquence de tokens

$$(t_1, \dots, t_T).$$

Pour chaque token généré t_k , l’API fournit la log-probabilité conditionnelle associée :

$$\log p(t_k \mid t_{<k}, x_i),$$

où x_i désigne la question et $t_{<k}$ représente les tokens générés précédemment.

Ces log-probabilités permettent de construire plusieurs scores de confiance internes.

Probabilité jointe de la séquence En exponentiant la somme des log-probabilités, on obtient la probabilité jointe de la séquence générée :

$$P_i^{(\text{joint})} = \prod_{k=1}^T p(t_k \mid t_{<k}, x_i).$$

Cette quantité correspond à la probabilité que le modèle attribue à la séquence exacte qu’il a produite.

Probabilité géométrique moyenne Afin d’obtenir une mesure indépendante de la longueur de la séquence, nous considérons également la moyenne géométrique des probabilités des tokens :

$$P_i^{(\text{geo})} = \left(\prod_{k=1}^T p(t_k \mid t_{<k}, x_i) \right)^{1/T}.$$

Cette métrique peut être interprétée comme la probabilité moyenne attribuée par le modèle à chaque token généré.

Perplexité Nous calculons également la perplexité associée à la séquence générée :

$$\text{Perplexity}_i = \exp \left(-\frac{1}{T} \sum_{k=1}^T \log p(t_k \mid t_{<k}, x_i) \right).$$

La perplexité mesure le degré d’incertitude du modèle : une perplexité plus faible correspond à une séquence jugée plus probable par le modèle.

Probabilité minimale des tokens Afin de détecter les tokens particulièrement incertains, nous considérons également la probabilité minimale parmi les tokens générés :

$$p_{\min} = \min_k p(t_k \mid t_{<k}, x_i).$$

Cette métrique permet d’identifier si la génération contient un token auquel le modèle attribue une probabilité très faible.

Scores restreints aux tokens de la réponse Dans la mesure où notre analyse porte sur des réponses numériques, nous calculons également l’ensemble de ces métriques en ne conservant que les tokens correspondant à la réponse du LLM.

Ces scores permettent d’isoler le niveau de confiance du modèle spécifiquement associé à la génération de la valeur numérique prédite.

3.4 Résultats

3.4.1 Dispersion des scores de confiance

Nous commençons par examiner la distribution des différents scores de confiance produits par les modèles. Le tableau 1 présente des statistiques descriptives pour chacun des signaux étudiés.

TABLE 1: Résumé descriptif des différents scores de confiance

Confidence score	n	Mean	Min	Max
Conf verbalisée	3395	0.959623	0.100000	1.000000
Conf judge	3391	0.908139	0.010000	1.000000
Prob joint seq	3395	0.973050	0.000001	1.000000
Prob mean seq	3395	0.986256	0.101102	1.000000
Logprob sum seq	3395	-0.054219	-13.531101	0.000013
Logprob mean seq	3395	-0.018517	-2.291625	0.000004
Perplexity seq	3395	1.029233	0.999996	9.890997
Prob min seq	3395	0.974415	0.041966	1.000004
Prob joint all	3395	0.643894	0.000000	0.998803
Prob mean all	3395	0.978124	0.629143	0.999954
Logprob sum all	3395	-0.632608	-16.218891	-0.001197
Logprob mean all	3395	-0.022516	-0.463397	-0.000046
Perplexity all	3395	1.023202	1.000046	1.589464
Prob min all	3395	0.664897	0.038462	0.999041

Un premier résultat frappant concerne le niveau moyen de confiance. La confiance verbalisée par le modèle et la confiance attribuée par le modèle juge présentent des moyennes élevées, respectivement proches de 0.96 et 0.91. Ces valeurs sont supérieures à l’exactitude empirique du modèle, d’environ 0.86, ce qui indique une tendance générale à la surconfiance.

Les probabilités internes associées aux tokens de la réponse sont elles aussi très concentrées vers des valeurs élevées, avec des moyennes souvent comprises entre 0.97 et 0.99. À l’inverse, les probabilités calculées sur l’ensemble de la génération sont un peu moins concentrées, avec des moyennes parfois nettement plus basses, autour de 0.64 à 0.98 selon la métrique considérée.

Ces écarts de dispersion sont importants pour la suite, car un score très concentré près de 1 peut difficilement produire une discrimination fine entre réponses correctes et incorrectes.

3.4.2 Capacité de discrimination des scores de confiance

Nous examinons ensuite dans quelle mesure les différents scores permettent de distinguer les réponses correctes des réponses incorrectes. Pour cela, nous utilisons l’aire sous la courbe ROC (AUC), présentée dans le tableau 2.

TABLE 2: Capacité de discrimination des scores de confiance mesurée par l’AUC

Confidence score	n	Accuracy	AUC
Logprob mean seq	3395	0.863623	0.857214
Logprob sum seq	3395	0.863623	0.856671
Prob min seq	3395	0.863623	0.849128
Prob mean seq	3395	0.863623	0.843973
Prob joint seq	3395	0.863623	0.843529
Conf verbalisée	3395	0.863623	0.719345
Conf judge	3391	0.864347	0.679321
Prob mean all	3395	0.863623	0.631333
Logprob mean all	3395	0.863623	0.631333
Prob joint all	3395	0.863623	0.628024
Logprob sum all	3395	0.863623	0.628024
Prob min all	3395	0.863623	0.599377

Continued on next page

TABLE 2: Capacité de discrimination des scores de confiance mesurée par l’AUC

Confidence score	n	Accuracy	AUC
Perplexity all	3395	0.863623	0.368667
Perplexity seq	3395	0.863623	0.142786

L’AUC mesure la probabilité qu’un score attribue une valeur plus élevée à une réponse correcte qu’à une réponse incorrecte choisie au hasard. Une valeur de 0.5 correspond à un classement aléatoire, tandis qu’une valeur proche de 1 indique une forte capacité de discrimination.

Les résultats mettent en évidence une hiérarchie assez claire entre les signaux étudiés. Les probabilités internes associées aux tokens de la réponse obtiennent les meilleures performances, avec des AUC de l’ordre de 0.84 à 0.86. Les scores explicites de confiance se situent à un niveau intermédiaire, avec des AUC proches de 0.68 à 0.72. Enfin, les métriques calculées sur l’ensemble de la génération sont les moins informatives, avec des AUC souvent comprises entre 0.60 et 0.63, et même beaucoup plus faibles pour la perplexité.

Autrement dit, les signaux les plus utiles pour distinguer les bonnes et les mauvaises réponses sont ceux qui portent directement sur les tokens de la réponse elle-même.

3.4.3 Calibration des scores probabilistes

Au-delà de leur capacité de discrimination, il est également important d’examiner si les scores interprétés comme des probabilités sont bien calibrés. Un score est bien calibré si une confiance annoncée de p correspond approximativement à une fréquence empirique de réponses correctes égale à p .

Le tableau 3 présente plusieurs indicateurs de calibration, notamment le score de Brier et l’Expected Calibration Error (ECE).

TABLE 3: Indicateurs de calibration des scores probabilistes

Confidence score	Brier	ECE
Prob joint seq	0.113852	0.113843
Conf verbalisée	0.117459	0.096000
Prob mean seq	0.120535	0.122633
Conf judge	0.124606	0.081828
Prob mean all	0.127775	0.114501
Prob min all	0.212136	0.223550
Prob joint all	0.215552	0.242211

Les résultats confirment l’impression donnée par l’analyse descriptive : les modèles ont tendance à être surconfiants. Les scores moyens de confiance se situent souvent entre 0.91 et 0.99, alors que l’exactitude empirique reste proche de 0.86. Les scores de Brier les plus faibles sont obtenus par certaines probabilités associées aux tokens de la réponse, avec des valeurs proches de 0.11 à 0.12, tandis que les probabilités calculées sur l’ensemble de la

génération peuvent dépasser 0.21. De même, les ECE les plus faibles restent de l'ordre de 0.08 à 0.10, ce qui indique que la calibration reste imparfaite.

Ainsi, même lorsque certains scores discriminent correctement les réponses justes et fausses, ils ne doivent pas être interprétés comme des probabilités parfaitement calibrées.

3.4.4 Lien entre confiance et proximité à la vérité

Nous analysons enfin la relation entre les scores de confiance et la distance entre la réponse produite par le modèle et la vérité terrain. Les résultats détaillés sont présentés en annexe dans les tableaux 7 et 8.

Afin d'évaluer cette relation, nous utilisons principalement la corrélation de Spearman, qui mesure une relation monotone entre deux variables et est moins sensible aux valeurs extrêmes que la corrélation de Pearson.

Sur l'ensemble des réponses, la confiance est globalement négativement corrélée avec l'erreur : les réponses auxquelles le modèle attribue davantage de confiance tendent en moyenne à être plus proches de la vérité terrain. Les corrélations les plus marquées sont observées pour les probabilités internes associées aux tokens de la réponse, avec des coefficients de Spearman pouvant approcher -0.5 . Les scores explicites de confiance présentent des corrélations plus modestes, de l'ordre de -0.26 , tandis que les métriques calculées sur l'ensemble de la génération restent plus faibles, souvent proches de -0.15 .

Lorsque l'on restreint l'analyse aux seules réponses incorrectes, ces corrélations diminuent nettement et se situent le plus souvent entre environ -0.13 et -0.22 pour les meilleurs signaux. Les scores de confiance semblent donc surtout utiles pour distinguer les réponses correctes des réponses incorrectes, mais beaucoup moins pour mesurer finement l'ampleur de l'erreur parmi les seules réponses fausses.

3.4.5 Robustesse aux différentes mesures de distance

Nous avons également examiné si les résultats dépendaient du choix de la métrique utilisée pour mesurer la distance à la vérité terrain. Plusieurs mesures ont été considérées : l'erreur absolue, l'erreur relative, l'erreur logarithmique et la transformation $\log(1 + |\hat{y} - y|)$.

Les corrélations obtenues sont très proches pour ces différentes métriques. Pour un même score de confiance, les coefficients de Spearman ne varient généralement que de quelques centièmes, et le classement des différents signaux reste inchangé.

Cette stabilité s'explique en partie par le fait que certaines de ces métriques correspondent à des transformations monotones de l'erreur absolue, auxquelles la corrélation de Spearman est invariante. Les résultats obtenus apparaissent donc robustes au choix de la mesure de distance utilisée.

4 Analyse de l’incertitude dans les générations longues

4.1 Motivation et cadre de l’analyse

Dans les sections précédentes, nous avons étudié la relation entre différents scores de confiance et la correction des réponses dans un cadre contraint, où l’espace des réponses possibles était limité.

Nous adoptons ici une perspective plus proche des usages réels des modèles de langage, en nous intéressant à des réponses longues et textuelles. En pratique, les Large Language Models produisent rarement des réponses brèves et formatées ; ils génèrent le plus souvent des explications détaillées, structurées en plusieurs phrases, voire en plusieurs étapes de raisonnement.

Ce changement de cadre introduit une difficulté fondamentale : l’espace des réponses possibles devient extrêmement vaste, ce qui rend difficile la détermination automatique de la correction d’une réponse.

Une première source de difficulté tient au fait que plusieurs formulations différentes peuvent exprimer la même information. Par exemple :

“Macron est le président de la France.”

“Le président de la France est Macron.”

Ces deux phrases sont sémantiquement équivalentes, mais peuvent être associées à des probabilités différentes sous le modèle en raison de variations syntaxiques ou de leur fréquence dans les données d’entraînement.

Plus généralement, une réponse peut être correcte tout en étant formulée de manière inhabituelle, ou incorrecte tout en restant linguistiquement plausible. Les log-probabilités reflètent ainsi avant tout la plausibilité conditionnelle des séquences, et non directement la véracité de leur contenu.

À cela s’ajoute une difficulté propre aux générations longues : l’information pertinente peut être noyée dans un texte étendu, ce qui rend son extraction et son évaluation à grande échelle particulièrement complexes.

Afin de contourner ces difficultés, nous introduisons un cadre expérimental dans lequel la véracité des réponses peut être définie de manière claire et automatisable. Nous utilisons pour cela le dataset **GSM8K**, composé de problèmes mathématiques associés à une solution numérique unique.

Dans ce contexte, chaque génération contient une réponse finale qui peut être comparée directement à la vérité terrain, permettant ainsi de définir une variable binaire indiquant

si la réponse est correcte ou non.

Pour exploiter pleinement la structure des générations longues, nous demandons explicitement au modèle de produire un raisonnement détaillé menant à sa réponse. Ce choix permet d’augmenter la longueur des séquences générées, mais surtout de garantir que le contenu produit est directement lié à la résolution du problème posé.

Ainsi, bien que la véracité soit évaluée uniquement à partir de la réponse finale, l’ensemble du raisonnement contribue à la génération et peut contenir des signaux d’incertitude.

Ce protocole permet donc de dissocier la variable d’intérêt, la correction de la réponse finale, du signal étudié, à savoir la distribution des log-probabilités sur l’ensemble de la génération.

L’objectif de cette section est d’analyser si ces signaux permettent de distinguer les générations conduisant à une réponse correcte de celles conduisant à une réponse incorrecte.

4.2 Construction des indicateurs à partir des log-probabilités

Considérons une génération produite par le modèle sous la forme d’une séquence de tokens

$$(t_1, \dots, t_T),$$

et notons

$$\ell_k = \log p(t_k \mid t_{<k}, x), \quad p_k = p(t_k \mid t_{<k}, x).$$

À partir de ces quantités, ainsi que des distributions conditionnelles associées, nous construisons un ensemble d’indicateurs résumant différentes propriétés de la génération.

Statistiques de niveau Nous considérons des statistiques descriptives appliquées aux suites (ℓ_k) et (p_k) , en particulier :

$$\bar{\ell} = \frac{1}{T} \sum_{k=1}^T \ell_k, \quad \bar{p} = \frac{1}{T} \sum_{k=1}^T p_k,$$

ainsi que les quantités min, max, médiane et écart-type.

Incertainité L’incertitude est mesurée à l’aide de l’entropie des distributions prédictives :

$$H_k = - \sum_{v \in \mathcal{V}} p(v \mid t_{<k}, x) \log p(v \mid t_{<k}, x).$$

Nous en extrayons des statistiques agrégées telles que $\bar{H}$, $H_{\max}$ et $H_{\min}$.

Marge On note $p_k^{(1)}$ et $p_k^{(2)}$ les probabilités des deux tokens les plus probables à l'étape k , et on définit :

$$m_k = p_k^{(1)} - p_k^{(2)}.$$

Nous utilisons ensuite des statistiques sur la suite (m_k) , notamment $\bar{m}$ et $m_{\min}$.

Événements extrêmes Afin de capturer des ruptures locales dans la génération, nous considérons :

$$p_{\min} = \min_k p_k, \quad \ell_{\min} = \min_k \ell_k, \quad H_{\max} = \max_k H_k.$$

Nous introduisons également des variables de persistance, par exemple la longueur maximale d'une séquence de tokens dont la log-probabilité est inférieure à un seuil c :

$$L_c = \max \left\{ r : \exists j \text{ tel que } \ell_j < c, \dots, \ell_{j+r-1} < c \right\}.$$

Structure temporelle Afin de capturer l'évolution des quantités au cours de la génération, nous découpons la séquence en segments (par exemple en tiers) et calculons, pour une variable z_k , des moyennes segmentées :

$$\bar{z}^{(j)} = \frac{1}{|I_j|} \sum_{k \in I_j} z_k.$$

Nous considérons également des différences entre segments, telles que :

$$\bar{z}^{(3)} - \bar{z}^{(1)}.$$

Sous-séquences Enfin, l'ensemble de ces indicateurs est calculé séparément sur :

- les tokens du raisonnement ;
- les tokens de la réponse finale ;
- l'ensemble de la génération.

4.3 Résultats

4.3.1 Capacité globale de détection des erreurs

Nous commençons par évaluer dans quelle mesure les variables construites à partir des log-probabilités permettent de distinguer les réponses correctes des réponses incorrectes.

Pour cela, nous entraînons plusieurs modèles de régression logistique reposant sur différents ensembles de variables, et nous évaluons leurs performances à l'aide de l'aire

sous la courbe ROC (AUC) ainsi que de l’Average Precision.

Les résultats sont présentés dans le tableau 4.

TABLE 4 – Performance des différents ensembles de variables pour la détection des erreurs.

Feature set	Nb. features	ROC-AUC	Average Precision
All variables	64	0.729	0.978
All variables (without length)	61	0.718	0.976
Interpretable subset	11	0.698	0.975
Reasoning only	21	0.679	0.972
Reasoning only (without length)	20	0.679	0.972
Full-generation only	21	0.669	0.969
Final-answer only	21	0.665	0.972
Full-generation only (without length)	20	0.663	0.968

Le modèle le plus complet, fondé sur l’ensemble des variables numériques, atteint une AUC de 0.729 et une Average Precision de 0.978. Ces performances indiquent que les log-probabilités contiennent un signal réel permettant de distinguer les réponses correctes des réponses incorrectes.

Cependant, cette capacité de discrimination reste imparfaite : une AUC de 0.729 correspond à une séparation partielle seulement. Autrement dit, les log-probabilités ne permettent pas de détecter de manière fiable toutes les erreurs, mais elles contiennent une information exploitable.

Afin de mieux comprendre l’origine de ce signal, nous comparons plusieurs variantes du modèle.

Tout d’abord, l’exclusion des variables de longueur entraîne une baisse modérée de la performance, l’AUC passant de 0.729 à 0.718. Cela montre que la longueur des générations contient une information partielle sur la probabilité d’erreur. Néanmoins, cette diminution reste limitée, ce qui indique que le signal prédictif ne se réduit pas à un simple effet de longueur.

Ensuite, la comparaison entre les modèles fondés uniquement sur le raisonnement et ceux fondés uniquement sur la réponse finale met en évidence une différence systématique. Le modèle `reasoning_only` atteint une AUC de 0.679, contre 0.665 pour le modèle `final_only`. Ce résultat suggère que le processus de raisonnement intermédiaire contient davantage d’information sur la probabilité d’erreur que la réponse finale elle-même.

Enfin, un modèle plus parcimonieux, construit à partir d’un sous-ensemble restreint de variables interprétables, atteint une AUC de 0.698, proche de celle du modèle complet. Cela indique qu’une partie importante du signal peut être capturée par un nombre limité d’indicateurs bien choisis.

Dans l'ensemble, ces résultats montrent que les log-probabilités permettent de détecter partiellement les erreurs du modèle, mais que cette détection reste nécessairement imparfaite.

4.3.2 Analyse des variables les plus informatives

Afin d'identifier plus précisément les sources du signal, nous examinons ensuite les performances des variables prises individuellement.

Le tableau 5 présente les variables univariées les plus discriminantes.

TABLE 5 – Plus discriminantes variables univariées entre réponses correctes et incorrectes.

Variable	Mean correct	Mean wrong	AUC	FDR-BH
Full generation : entropymeans on last third	0.077	0.158	0.681	0.000
Reasoning : entropymeans on last third	0.083	0.177	0.681	0.000
Reasoning : entropy max	1.220	1.349	0.675	0.000
Full generation : entropy max	1.220	1.349	0.674	0.000
Full generation : top1means on last third	-0.045	-0.099	0.670	0.000
Reasoning : entropy std	0.249	0.300	0.668	0.000
Full generation : entropy std	0.247	0.298	0.668	0.000
Reasoning : top1means on last third	-0.049	-0.110	0.667	0.000
Full generation : entropy mean	0.114	0.165	0.666	0.000
Reasoning : entropy mean	0.116	0.171	0.665	0.000

Un premier résultat marquant est la place centrale occupée par les variables d'entropie. Les variables les plus performantes sont celles qui mesurent l'entropie moyenne sur le dernier tiers de la génération, avec des AUC proches de 0.68.

Ces variables indiquent que les réponses incorrectes sont associées à un niveau d'incertitude plus élevé en fin de génération. Autrement dit, lorsque le modèle produit une réponse erronée, sa distribution de probabilité tend à être plus diffuse dans les dernières étapes du raisonnement.

Cette observation est cohérente avec l'idée que les erreurs apparaissent souvent au moment où le modèle doit conclure son raisonnement. Le modèle peut suivre un cheminement globalement cohérent, puis devenir plus incertain lorsqu'il s'approche d'une conclusion incorrecte.

Les autres variables les plus informatives confirment cette interprétation. Les mesures d'entropie maximale et d'écart-type figurent également parmi les meilleures variables, ce qui suggère que les réponses incorrectes sont associées à des épisodes localisés de forte incertitude.

Les variables fondées sur la probabilité du token le plus probable (**top1**) apportent également une information utile. Des valeurs plus faibles de ces variables sont associées à

des réponses incorrectes, ce qui traduit une confiance locale plus faible du modèle.

Enfin, certaines variables de dynamique temporelle apparaissent également parmi les plus pertinentes. En particulier, les variations d’entropie entre le début et la fin de la génération indiquent que, dans les réponses incorrectes, l’incertitude tend à augmenter ou à rester élevée, tandis qu’elle diminue plus souvent dans les réponses correctes.

Dans l’ensemble, l’analyse univariée met en évidence un signal cohérent : les erreurs sont associées à une augmentation de l’incertitude et à une plus grande instabilité dans la distribution des probabilités.

4.3.3 Rôle des différentes dimensions du signal

Afin de mieux comprendre la contribution relative des différentes variables, nous examinons les coefficients d’un modèle logistique construit sur un sous-ensemble restreint de variables interprétables.

Les résultats sont présentés dans le tableau 6.

TABLE 6 – Coefficients du modèle logistique construit sur le sous-ensemble interprétable de variables.

Variable	Coefficient
Reasoning : margin mean	1.526
Full generation : margin mean	-1.257
Reasoning : entropy last minus mean on first third	-0.473
Reasoning : length	-0.459
Reasoning : entropy mean	-0.294
Reasoning : longest run lp below -2	0.294
Reasoning : entropy max	-0.135
Full generation : length	-0.088
Reasoning : margin min	0.060
Final answer : margin mean	0.026
Reasoning : top1 min	0.021

Les variables ayant les coefficients les plus élevés en valeur absolue correspondent principalement à des mesures de marge et à des indicateurs liés à la dynamique de l’entropie.

En particulier, les variables de marge moyenne et de variation d’entropie entre le début et la fin de la génération jouent un rôle important dans la prédiction. Cela suggère que la capacité du modèle à privilégier clairement un token par rapport aux alternatives, ainsi que l’évolution de son incertitude au cours du raisonnement, sont des éléments clés pour détecter les erreurs.

Cependant, ces coefficients doivent être interprétés avec prudence, en raison des

corrélations potentielles entre variables. Ils doivent être compris comme des indications qualitatives sur les types de signaux pertinents plutôt que comme des effets causaux isolés.

4.3.4 Conclusion

Pris ensemble, ces résultats mettent en évidence une régularité claire : les réponses incorrectes tendent à être associées à une plus grande incertitude probabiliste, en particulier dans les dernières étapes de la génération.

Ce résultat ne signifie pas que les log-probabilités mesurent directement la véracité des réponses. Elles reflètent avant tout la plausibilité conditionnelle des tokens sous le modèle. Cependant, les erreurs semblent laisser une trace dans la structure probabiliste de la génération.

Lorsque le modèle s’engage dans un raisonnement incorrect, sa distribution de probabilité devient en moyenne plus diffuse, moins stable, et moins concentrée sur un token dominant. Ce phénomène peut être interprété comme une forme de désalignement interne du modèle.

Le fait que les variables issues du raisonnement soient plus informatives que celles issues de la seule réponse finale renforce cette interprétation. Le signal d’erreur ne se limite pas à la conclusion, mais se manifeste dans la dynamique même du processus de génération.

Enfin, le fait que les meilleures variables univariées restent limitées en performance, tandis que les modèles combinés atteignent de meilleures AUC, suggère que l’information pertinente est distribuée entre plusieurs dimensions complémentaires.

Ainsi, les log-probabilités ne constituent pas une mesure directe de la vérité, mais elles fournissent des indices indirects sur la fiabilité des générations, qui peuvent être exploités pour détecter des réponses potentiellement erronées.

5 Détection d’hallucinations par WEPR

5.1 Motivation

La détection des hallucinations constitue un enjeu central dans l’utilisation des grands modèles de langage. Dans un cadre *black-box*, où l’on ne dispose que des sorties probabilistes du modèle, il est nécessaire de construire des indicateurs de confiance à partir des distributions de probabilité sur les tokens générés.

Les métriques classiques, telles que la perplexité ou la log-probabilité moyenne, fournissent des signaux d’incertitude globaux, mais restent limitées dans leur capacité à discriminer efficacement les réponses correctes des hallucinations.

Dans cette section, nous étudions la méthode **WEPR** (*Weighted Entropy Production Rate*), proposée par Moslonka et al. [Moslonka et al., 2026], qui vise à exploiter plus finement ces distributions en analysant les contributions entropiques des K tokens les plus probables à chaque étape de génération.

5.2 Pipeline expérimental

Le protocole expérimental repose sur quatre étapes principales.

Génération des données Le modèle Gemini 2.0 Flash est interrogé sur des questions issues du dataset **TriviaQA**. Pour chaque réponse générée, on conserve les log-probabilités des $K = 10$ tokens les plus probables à chaque position. Le jeu de données brut contient environ 74,000 réponses.

Annotation Chaque réponse est ensuite annotée à l’aide d’un juge LLM (*LLM-as-a-judge*), qui détermine si elle est correcte ou hallucinée en la comparant aux réponses de référence. Après filtrage, on obtient un jeu de données de 73,793 observations, dont 62,530 réponses correctes et 11,263 hallucinations, soit environ 84.7

Entraînement Un modèle de régression logistique est entraîné sur des variables construites à partir des distributions de probabilité des tokens.

Évaluation Les performances sont évaluées par validation croisée et par bootstrap, et comparées à plusieurs baselines non supervisées.

5.3 Méthode

5.3.1 Contributions entropiques

Pour chaque position $j \in 1, \dots, L$ et chaque rang $k \in 1, \dots, K$, on définit la contribution entropique :

$$s(k, j) = -p(k, j) \log p(k, j), \quad (1)$$

où $p(k, j)$ est la probabilité du k -ème token le plus probable à la position j .

Cette quantité mesure l’incertitude locale associée aux différents candidats.

5.3.2 Entropy Production Rate (EPR)

L’Entropy Production Rate est défini comme :

$$\text{EPR} = \frac{1}{L} \sum_{j=1}^L \sum_{k=1}^K s(k, j). \quad (2)$$

Un EPR élevé correspond à une incertitude globale importante et est donc associé à un risque accru d'hallucination.

5.3.3 Weighted Entropy Production Rate (WEPR)

La méthode WEPR introduit une pondération apprise des contributions entropiques. Le score de séquence s'écrit :

$$\text{WEPR} = \frac{1}{L} \sum_{j=1}^L \left(\beta_0 + \sum_{k=1}^K \beta_k s(k, j) \right) + \sum_{k=1}^K \gamma_k \max_{1 \leq j \leq L} s(k, j). \quad (3)$$

Le vecteur de features est constitué de

$$s(k) = \frac{1}{L} \sum_{j=1}^L s(k, j), \quad k = 1, \dots, K, \quad (4)$$

$$m(k) = \max_{1 \leq j \leq L} s(k, j), \quad k = 1, \dots, K. \quad (5)$$

On obtient ainsi un vecteur de dimension $2K$, utilisé comme entrée d'une régression logistique.

5.4 Apprentissage

Le problème est formulé comme une classification binaire :

$$y_i = \begin{cases} 1 & \text{si la réponse est correcte,} \\ 0 & \text{si la réponse est hallucinée.} \end{cases} \quad (6)$$

On utilise une régression logistique :

$$\hat{p}_i = \sigma(\theta^\top x_i). \quad (7)$$

avec une fonction de perte d'entropie croisée :

$$\mathcal{L}(\theta) = -\frac{1}{n} \sum_{i=1}^n (y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)). \quad (8)$$

Aucune régularisation n'est utilisée, ce qui se justifie par le faible nombre de paramètres

($2K + 1 = 21$) relativement au nombre d'observations ($n \approx 74,000$).

L'optimisation est réalisée à l'aide de l'algorithme L-BFGS, qui permet une convergence rapide grâce à une approximation de la hessienne.

Une validation croisée stratifiée à 5 folds est utilisée pour évaluer les performances, conduisant à une AUC d'environ 0.681 ± 0.007 .

5.5 Évaluation par bootstrap

Afin d'obtenir des intervalles de confiance robustes, un bootstrap avec $B = 1000$ itérations est utilisé.

Pour les méthodes non paramétriques, le score est recalculé sur chaque échantillon bootstrap sans ré-entraînement.

Dans le cas de WEPR, le modèle est ré-entraîné à chaque itération. On utilise un schéma *out-of-bag* : le modèle est entraîné sur l'échantillon bootstrap et évalué sur les observations non tirées, qui représentent environ 36.8% des données.

Ce protocole évite un biais optimiste, mais introduit une variance plus importante, car chaque itération correspond à un modèle différent.

5.6 Résultats

Les performances obtenues sont résumées dans le tableau suivant :

Méthode	AUC	Écart-type	IC 95%
WEPR	0.682	0.0105	[0.662, 0.702]
EPR	0.656	0.0029	[0.650, 0.662]
Mean log-prob	0.633	0.0030	[0.627, 0.639]
Perplexité	0.633	0.0030	[0.627, 0.639]
Min log-prob	0.622	0.0029	[0.616, 0.628]

WEPR obtient la meilleure performance, avec un gain de +2.6 points d'AUC par rapport à EPR.

Les courbes ROC montrent que WEPR domine les autres méthodes sur l'ensemble du spectre.

Les distributions de scores se chevauchent fortement, ce qui explique les performances modérées observées.

Méthode	AUC moyenne	Écart-type	IC à 95 %
WEPR	0.682	0.0105	[0.662, 0.702]
EPR	0.656	0.0029	[0.650, 0.662]
Mean log-prob	0.633	0.0030	[0.627, 0.639]
Perplexité	0.633	0.0030	[0.627, 0.639]
Min log-prob	0.622	0.0029	[0.616, 0.628]

FIGURE 1 – Courbes ROC comparant les différentes méthodes




FIGURE 2 – Distribution des scores pour réponses correctes et hallucinations

5.7 Interprétation

L'analyse des coefficients du modèle permet de mieux comprendre les signaux exploités.

L'intercept positif reflète le déséquilibre des classes, le modèle étant biaisé vers la prédiction « correcte ».

Le signal principal provient de la compétition entre les deux premiers tokens : une incertitude élevée sur le second token indique que plusieurs réponses plausibles sont en concurrence, ce qui est caractéristique d'une hallucination.

Par ailleurs, la présence de pics d'incertitude locaux dans la séquence constitue un signal d'alerte important, même lorsque l'incertitude moyenne reste faible.

Enfin, l'information discriminante se concentre principalement sur les premiers rangs et sur les événements extrêmes, les rangs intermédiaires contribuant peu.

5.8 Conclusion

La méthode WEPR permet d'améliorer la détection d'hallucinations par rapport aux approches non supervisées, en exploitant de manière plus fine les distributions de

probabilité des tokens.

Cependant, les performances restent limitées ($AUC \approx 0.68$), ce qui reflète la difficulté intrinsèque du problème dans un cadre *black-box*. Ces résultats suggèrent que ces signaux doivent être combinés à d'autres sources d'information pour obtenir une détection plus fiable.

6 Conclusion

Annexes

A Prompts utilisés

Les réponses des modèles sont demandées au format `JSON` afin de garantir la stabilité des sorties et de faciliter l'extraction automatique des informations nécessaires à l'analyse.

Les prompts sont rédigés en anglais. Ce choix est motivé par deux raisons : d'une part les questions du dataset TriviaQA sont formulées en anglais, et d'autre part les modèles de langage présentent généralement de meilleures performances dans cette langue.

A.1 Prompt pour la génération de la réponse et la confiance verbalisée

You must answer in STRICT JSON with exactly two keys: "answer" and "confidence".

Rules:

- Return ONLY the JSON object. No extra text, no markdown, no explanation.
- "answer": a number in decimal notation (examples: 1945, 3.14, -12.5).
No commas. No units. No text.
- "confidence": a float between 0 and 1 (inclusive). This number must be the confidence you have in the answer. If you respond 0.7 then 7 times out of 10 you are correct. Be careful, you must not overstate your confidence. It must be a JSON number, not a string.

Question:

{q}

A.2 Prompt pour le jugement externe (LLM-as-a-judge)

You are an assistant that evaluates the correctness of a model's answer to a question.

Return a single JSON object with exactly one key: "judge_confidence".

- "judge_confidence" must be a JSON number in [0, 1].
- Return ONLY the JSON object. No markdown, no extra text.

The judge confidence must be the probability that the model's answer

is correct, calibrated as best as possible. If the model's answer is very likely correct, return a value close to 1. If it's likely incorrect, return a value close to 0.

Question:

```
{question.strip()}
```

Model answer (numeric text):

```
{model_answer_text.strip()}
```

B Tableaux de résultats

TABLE 7: Corrélations entre les signaux de confiance et la distance à la vérité terrain (ensemble des réponses)

Confidence score	Distance	n	Pearson	Spearman	Effect
Conf verbalisée	abs_error	3395	-0.042457	-0.270188	faible à modéré
Conf verbalisée	log1p_abs_error	3395	-0.284130	-0.270188	faible à modéré
Conf verbalisée	log_error	3395	-0.126969	-0.264358	faible à modéré
Conf verbalisée	rel_error	3395	-0.044167	-0.261465	faible à modéré
Conf judge	abs_error	3391	-0.015042	-0.266805	faible à modéré
Conf judge	log1p_abs_error	3391	-0.162569	-0.266805	faible à modéré
Conf judge	log_error	3391	-0.111472	-0.265185	faible à modéré
Conf judge	rel_error	3391	-0.017058	-0.263898	faible à modéré
Logprob mean all	abs_error	3395	-0.018171	-0.156858	faible
Logprob mean all	log1p_abs_error	3395	-0.156985	-0.156858	faible
Logprob mean all	log_error	3395	-0.063546	-0.158993	faible
Logprob mean all	rel_error	3395	-0.021559	-0.155558	faible
Logprob sum all	abs_error	3395	-0.024755	-0.152897	faible
Logprob sum all	log1p_abs_error	3395	-0.152380	-0.152897	faible
Logprob sum all	log_error	3395	-0.062083	-0.154579	faible
Logprob sum all	rel_error	3395	-0.028308	-0.151168	faible
Prob min all	abs_error	3395	-0.011096	-0.117806	faible
Prob min all	log1p_abs_error	3395	-0.088027	-0.117806	faible
Prob min all	log_error	3395	-0.031333	-0.118992	faible
Prob min all	rel_error	3395	-0.014023	-0.115786	faible
Perplexity all	abs_error	3395	0.017245	0.156858	faible
Perplexity all	log1p_abs_error	3395	0.156418	0.156858	faible
Perplexity all	log_error	3395	0.062005	0.158993	faible
Perplexity all	rel_error	3395	0.020503	0.155558	faible
Prob mean all	abs_error	3395	-0.018971	-0.156858	faible
Prob mean all	log1p_abs_error	3395	-0.156938	-0.156858	faible
Prob mean all	log_error	3395	-0.064649	-0.158993	faible
Prob mean all	rel_error	3395	-0.022465	-0.155558	faible
Prob joint all	abs_error	3395	-0.030863	-0.152897	faible
Prob joint all	log1p_abs_error	3395	-0.135008	-0.152897	faible
Prob joint all	log_error	3395	-0.063948	-0.154579	faible
Prob joint all	rel_error	3395	-0.035082	-0.151168	faible
Logprob mean seq	abs_error	3395	-0.002167	-0.425641	modéré
Logprob mean seq	log1p_abs_error	3395	-0.230650	-0.425641	modéré
Logprob mean seq	log_error	3395	-0.103590	-0.426609	modéré
Logprob mean seq	rel_error	3395	-0.002963	-0.425326	modéré
Logprob sum seq	abs_error	3395	-0.014186	-0.425553	modéré
Logprob sum seq	log1p_abs_error	3395	-0.192564	-0.425553	modéré
Logprob sum seq	log_error	3395	-0.077316	-0.426768	modéré
Logprob sum seq	rel_error	3395	-0.015566	-0.425616	modéré
Prob min seq	abs_error	3395	-0.025617	-0.414901	modéré
Prob min seq	log1p_abs_error	3395	-0.277212	-0.414901	modéré
Prob min seq	log_error	3395	-0.129688	-0.415452	modéré
Prob min seq	rel_error	3395	-0.027940	-0.413848	modéré
Perplexity seq	abs_error	3395	-0.000183	0.425641	modéré
Perplexity seq	log1p_abs_error	3395	0.170671	0.425641	modéré
Perplexity seq	log_error	3395	0.070058	0.426609	modéré
Perplexity seq	rel_error	3395	0.000278	0.425326	modéré
Prob mean seq	abs_error	3395	-0.005150	-0.493118	modéré
Prob mean seq	log1p_abs_error	3395	-0.262131	-0.493118	modéré
Prob mean seq	log_error	3395	-0.123225	-0.495540	modéré
Prob mean seq	rel_error	3395	-0.006231	-0.492954	modéré
Prob joint seq	abs_error	3395	-0.042301	-0.492527	modéré
Prob joint seq	log1p_abs_error	3395	-0.294001	-0.492527	modéré
Prob joint seq	log_error	3395	-0.141104	-0.494483	modéré
Prob joint seq	rel_error	3395	-0.045566	-0.491914	modéré

TABLE 8: Corrélations entre les signaux de confiance et la distance à la vérité terrain (réponses incorrectes uniquement)

Confidence score	Distance	n	Pearson	Spearman	Effect
Conf verbalisée	abs_error	463	-0.030027	-0.131958	faible
Conf verbalisée	log1p_abs_error	463	-0.119430	-0.131958	faible
Conf verbalisée	log_error	463	-0.053670	0.142835	faible
Conf verbalisée	rel_error	463	-0.035792	0.156776	faible
Conf judge	abs_error	460	-0.006305	-0.032685	quasi nul
Conf judge	log1p_abs_error	460	-0.125426	-0.032685	quasi nul
Conf judge	log_error	460	-0.129213	0.037922	quasi nul
Conf judge	rel_error	460	-0.012207	0.047376	quasi nul
Logprob mean all	abs_error	463	-0.005060	-0.047283	quasi nul
Logprob mean all	log1p_abs_error	463	-0.011949	-0.047283	quasi nul
Logprob mean all	log_error	463	-0.003188	-0.039990	quasi nul
Logprob mean all	rel_error	463	-0.012972	-0.021579	quasi nul
Logprob sum all	abs_error	463	-0.016364	-0.043605	quasi nul
Logprob sum all	log1p_abs_error	463	-0.013528	-0.043605	quasi nul
Logprob sum all	log_error	463	-0.004346	-0.021224	quasi nul
Logprob sum all	rel_error	463	-0.024170	-0.003246	quasi nul
Prob min all	abs_error	463	-0.006719	-0.002648	quasi nul
Prob min all	log1p_abs_error	463	-0.009901	-0.002648	quasi nul
Prob min all	log_error	463	0.009012	0.038276	quasi nul
Prob min all	rel_error	463	-0.016270	0.053115	très faible
Perplexity all	abs_error	463	0.003264	0.047283	quasi nul
Perplexity all	log1p_abs_error	463	0.008786	0.047283	quasi nul
Perplexity all	log_error	463	0.000089	0.039990	quasi nul
Perplexity all	rel_error	463	0.010631	0.021579	quasi nul
Prob mean all	abs_error	463	-0.006841	-0.047283	quasi nul
Prob mean all	log1p_abs_error	463	-0.015102	-0.047283	quasi nul
Prob mean all	log_error	463	-0.006134	-0.039990	quasi nul
Prob mean all	rel_error	463	-0.015233	-0.021579	quasi nul
Prob joint all	abs_error	463	-0.047488	-0.043605	quasi nul
Prob joint all	log1p_abs_error	463	-0.061255	-0.043605	quasi nul
Prob joint all	log_error	463	-0.041647	-0.021224	quasi nul
Prob joint all	rel_error	463	-0.060540	-0.003246	quasi nul
Logprob mean seq	abs_error	463	0.023010	-0.146024	faible
Logprob mean seq	log1p_abs_error	463	-0.003988	-0.146024	faible
Logprob mean seq	log_error	463	-0.012803	-0.214042	faible à modéré
Logprob mean seq	rel_error	463	0.019848	-0.192430	faible
Logprob sum seq	abs_error	463	0.005245	-0.152643	faible
Logprob sum seq	log1p_abs_error	463	-0.003516	-0.152643	faible
Logprob sum seq	log_error	463	-0.000056	-0.185736	faible
Logprob sum seq	rel_error	463	0.001876	-0.165006	faible
Prob min seq	abs_error	463	0.000384	-0.132909	faible
Prob min seq	log1p_abs_error	463	-0.032132	-0.132909	faible
Prob min seq	log_error	463	-0.032686	-0.158881	faible
Prob min seq	rel_error	463	-0.005630	-0.138356	faible
Perplexity seq	abs_error	463	-0.018036	0.146024	faible
Perplexity seq	log1p_abs_error	463	0.000509	0.146024	faible
Perplexity seq	log_error	463	0.001004	0.214042	faible à modéré
Perplexity seq	rel_error	463	-0.015957	0.192430	faible
Prob mean seq	abs_error	463	0.024038	-0.149965	faible
Prob mean seq	log1p_abs_error	463	-0.010225	-0.149965	faible
Prob mean seq	log_error	463	-0.023712	-0.222229	faible à modéré
Prob mean seq	rel_error	463	0.020074	-0.198807	faible
Prob joint seq	abs_error	463	-0.020382	-0.152014	faible
Prob joint seq	log1p_abs_error	463	-0.051953	-0.152014	faible
Prob joint seq	log_error	463	-0.044534	-0.180300	faible
Prob joint seq	rel_error	463	-0.027630	-0.158374	faible

Références

[Moslonka et al., 2026] Moslonka, C. et al. (2026). Learned hallucination detection in black-box llms using token-level entropy production rate. *arXiv preprint arXiv :2509.04492*.