Comparaison des méthodes d'incertitude

MMLU — Gemini 2.0 Flash

Évaluation sur les mêmes 107 questions
(logits A/B/C/D complets)

Logprobs vs Confiance déclarée vs Prédiction conforme
Signaux : Entropie normalisée, Probabilité max
Méthodes conformes : LAC, APS

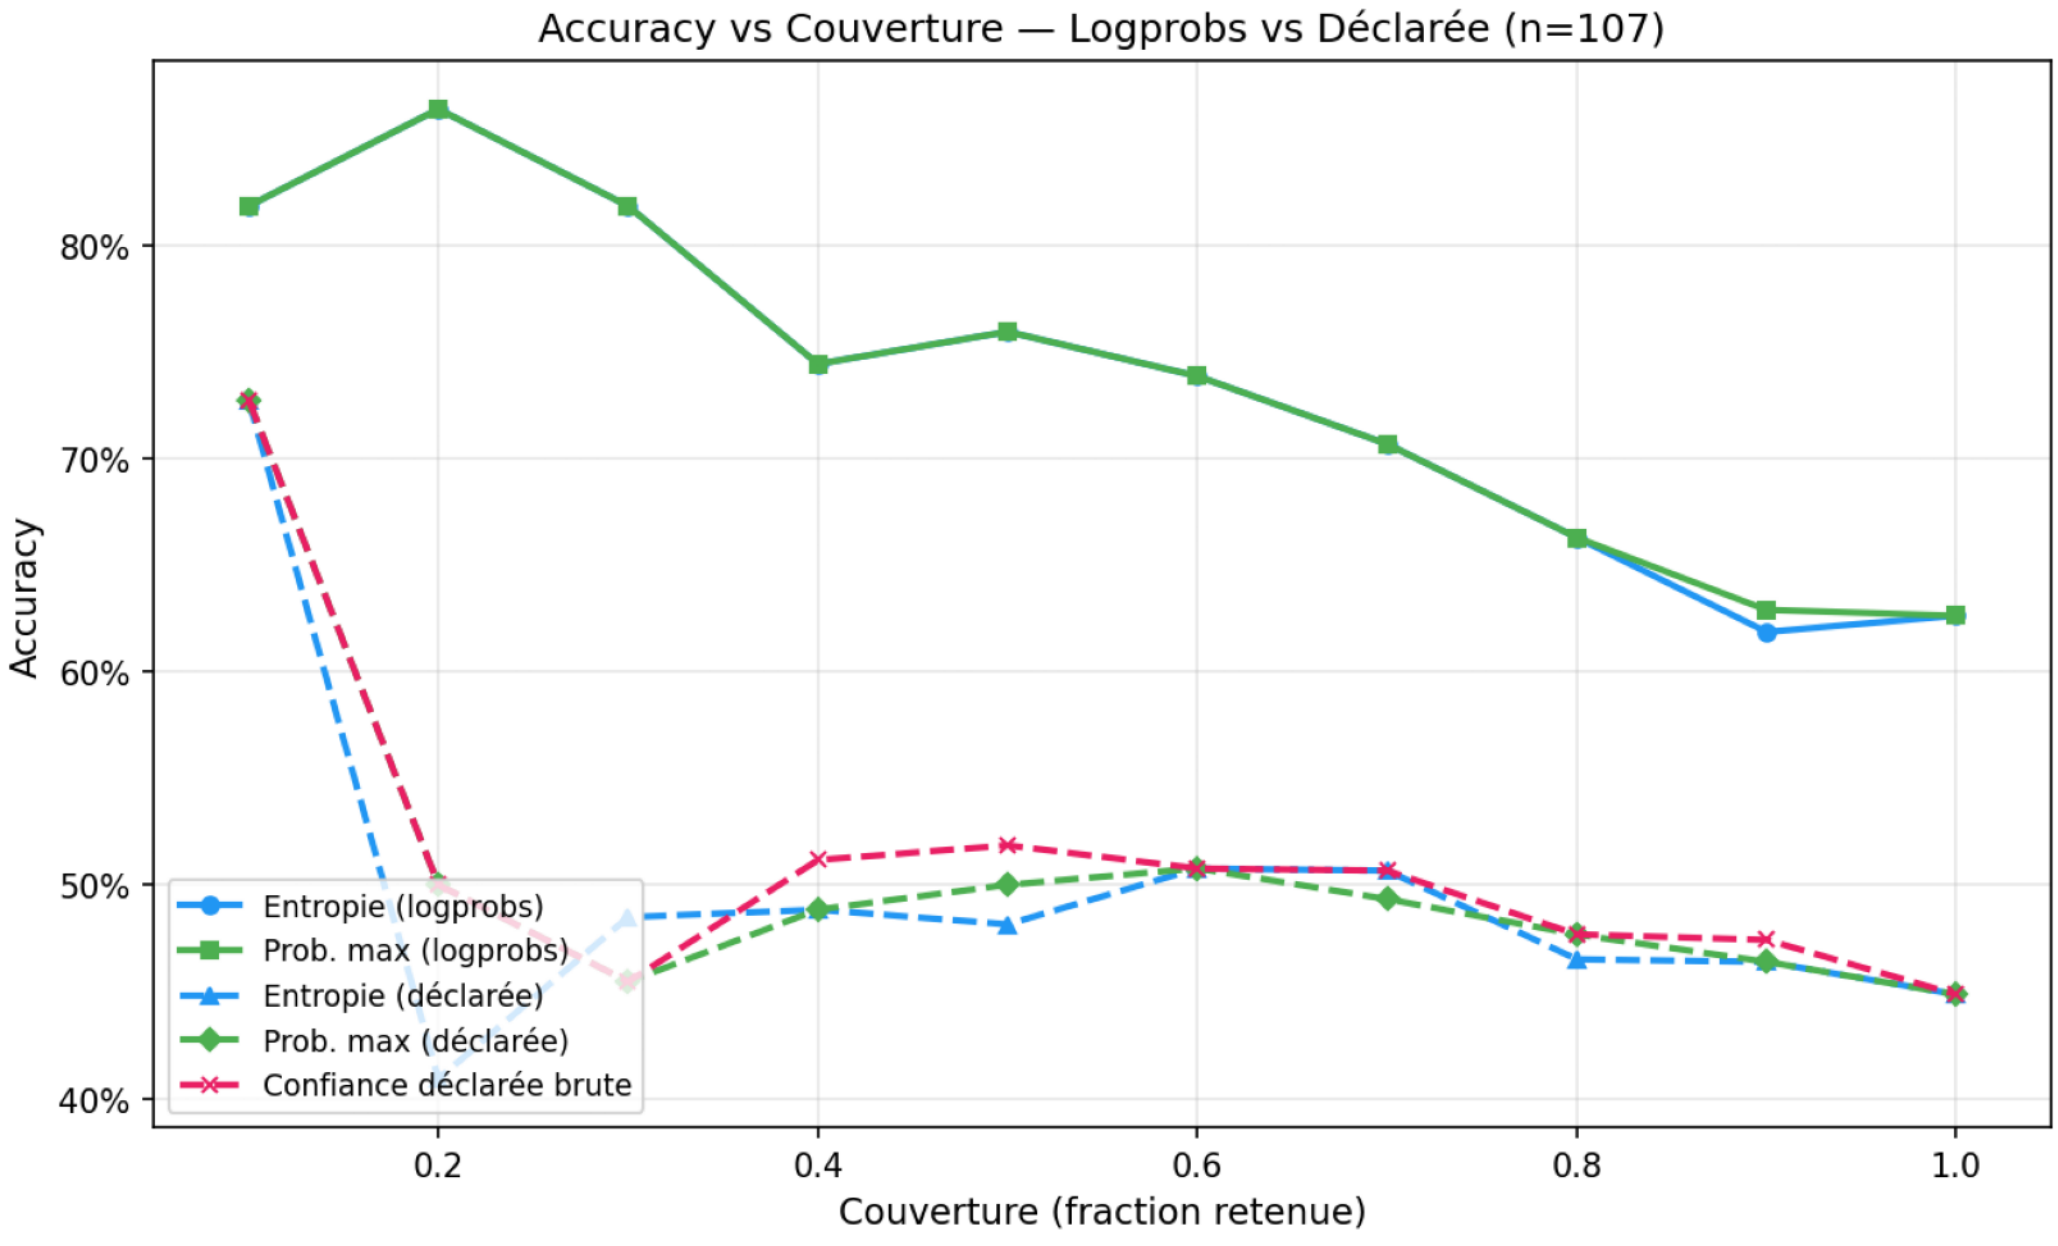
Accuracy vs Couverture — Logprobs vs Déclarée (n=107)
Accuracy
80%
70%
60%
50%
40%
0.2
0.4
0.6
0.8
1.0
Couverture (fraction retenue)
Entropie (logprobs)
Prob. max (logprobs)
Entropie (déclarée)
Prob. max (déclarée)
Confiance déclarée brute

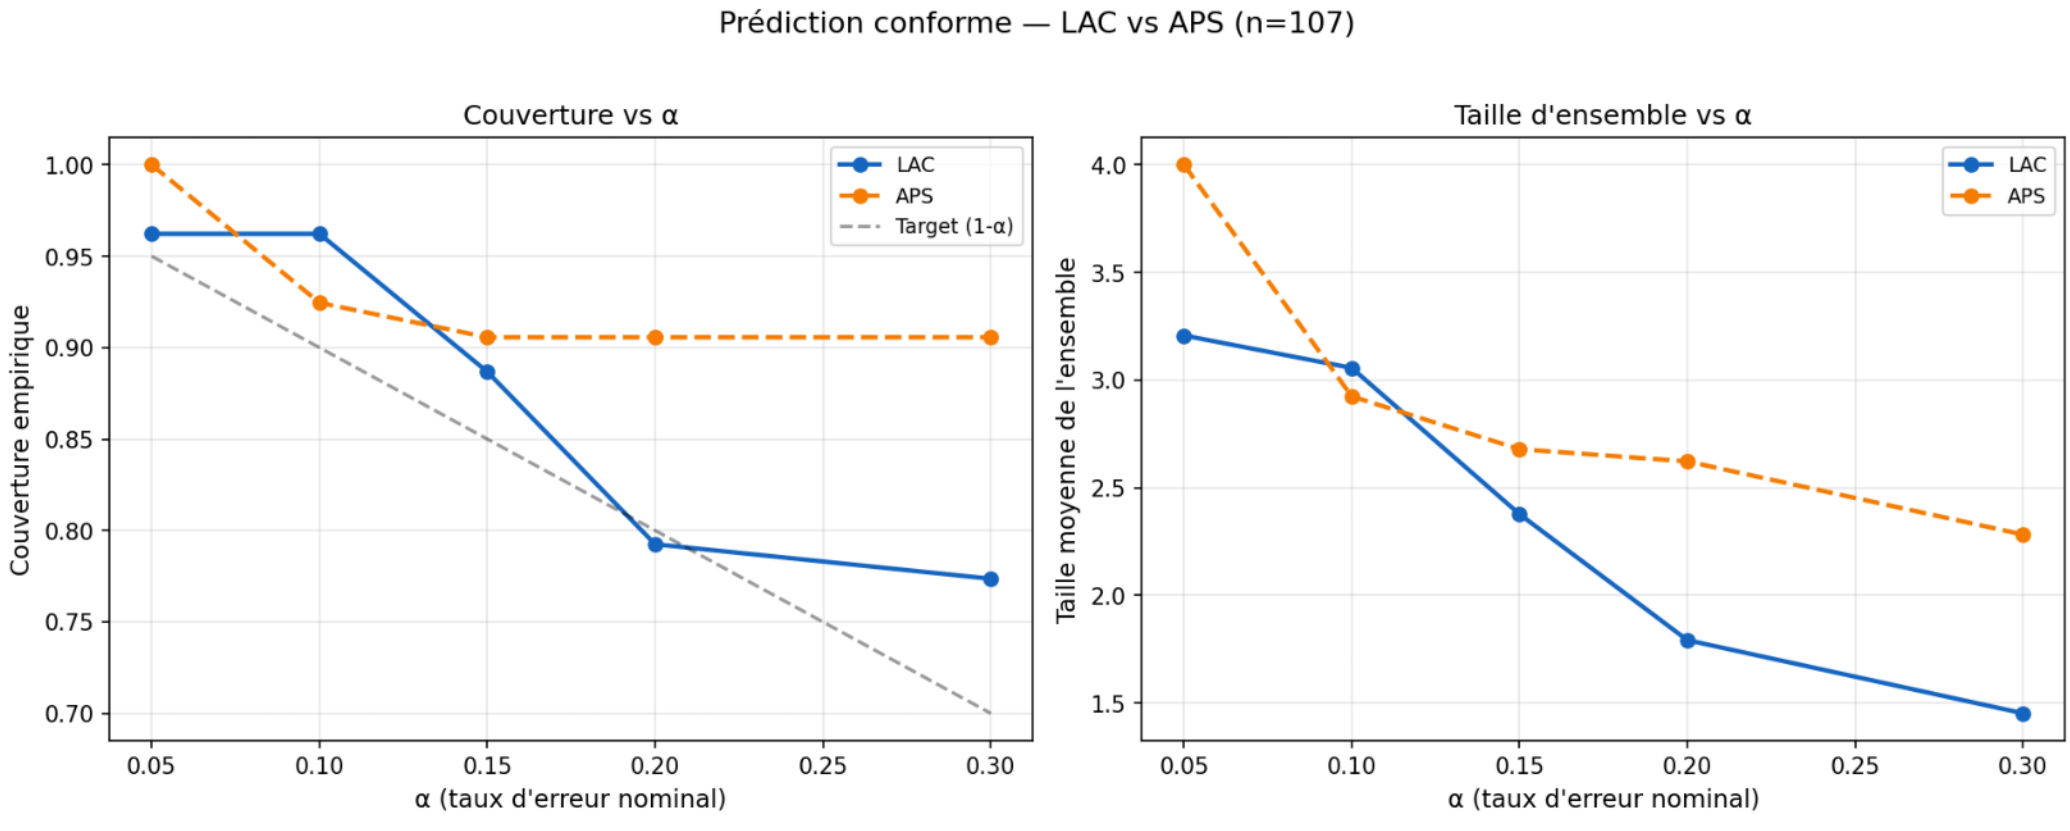
Prédiction conforme — LAC vs APS (n=107)
Couverture vs α
Couverture empirique
α (taux d'erreur nominal)
LAC
APS
Target (1-α)
1.00
0.95
0.90
0.85
0.80
0.75
0.70
0.05
0.10
0.15
0.20
0.25
0.30
Taille d'ensemble vs α
Taille moyenne de l'ensemble
α (taux d'erreur nominal)
LAC
APS
4.0
3.5
3.0
2.5
2.0
1.5
0.05
0.10
0.15
0.20
0.25
0.30

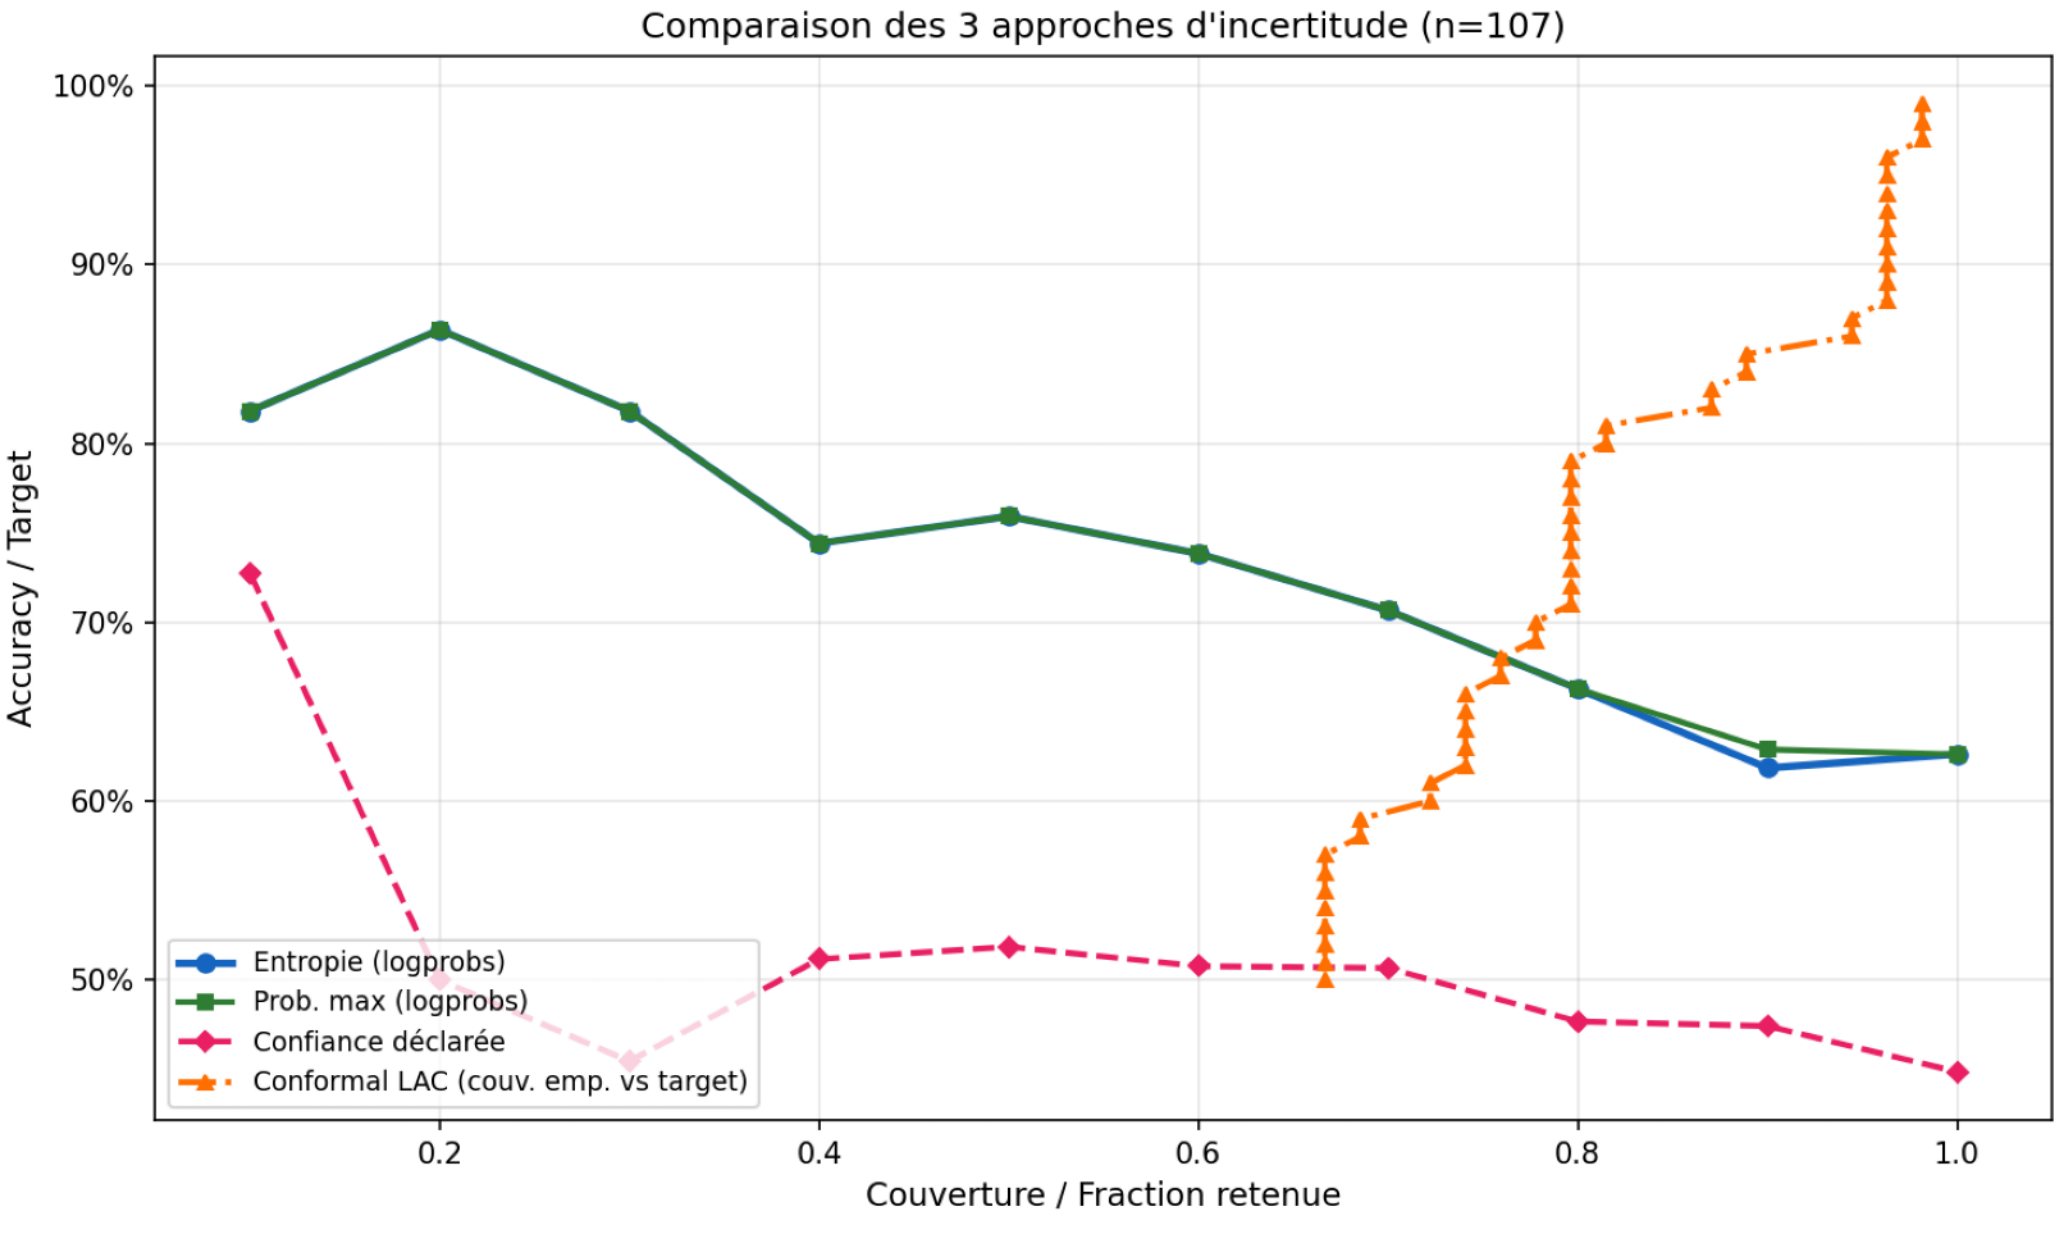
Comparaison des 3 approches d'incertitude (n=107)
100%
90%
80%
70%
60%
50%
Accuracy / Target
0.2
0.4
0.6
0.8
1.0
Couverture / Fraction retenue
Entropie (logprobs)
Prob. max (logprobs)
Confiance déclarée
Conformal LAC (couv. emp. vs target)

Distribution des scores — Correctes vs Incorrectes (n=107)

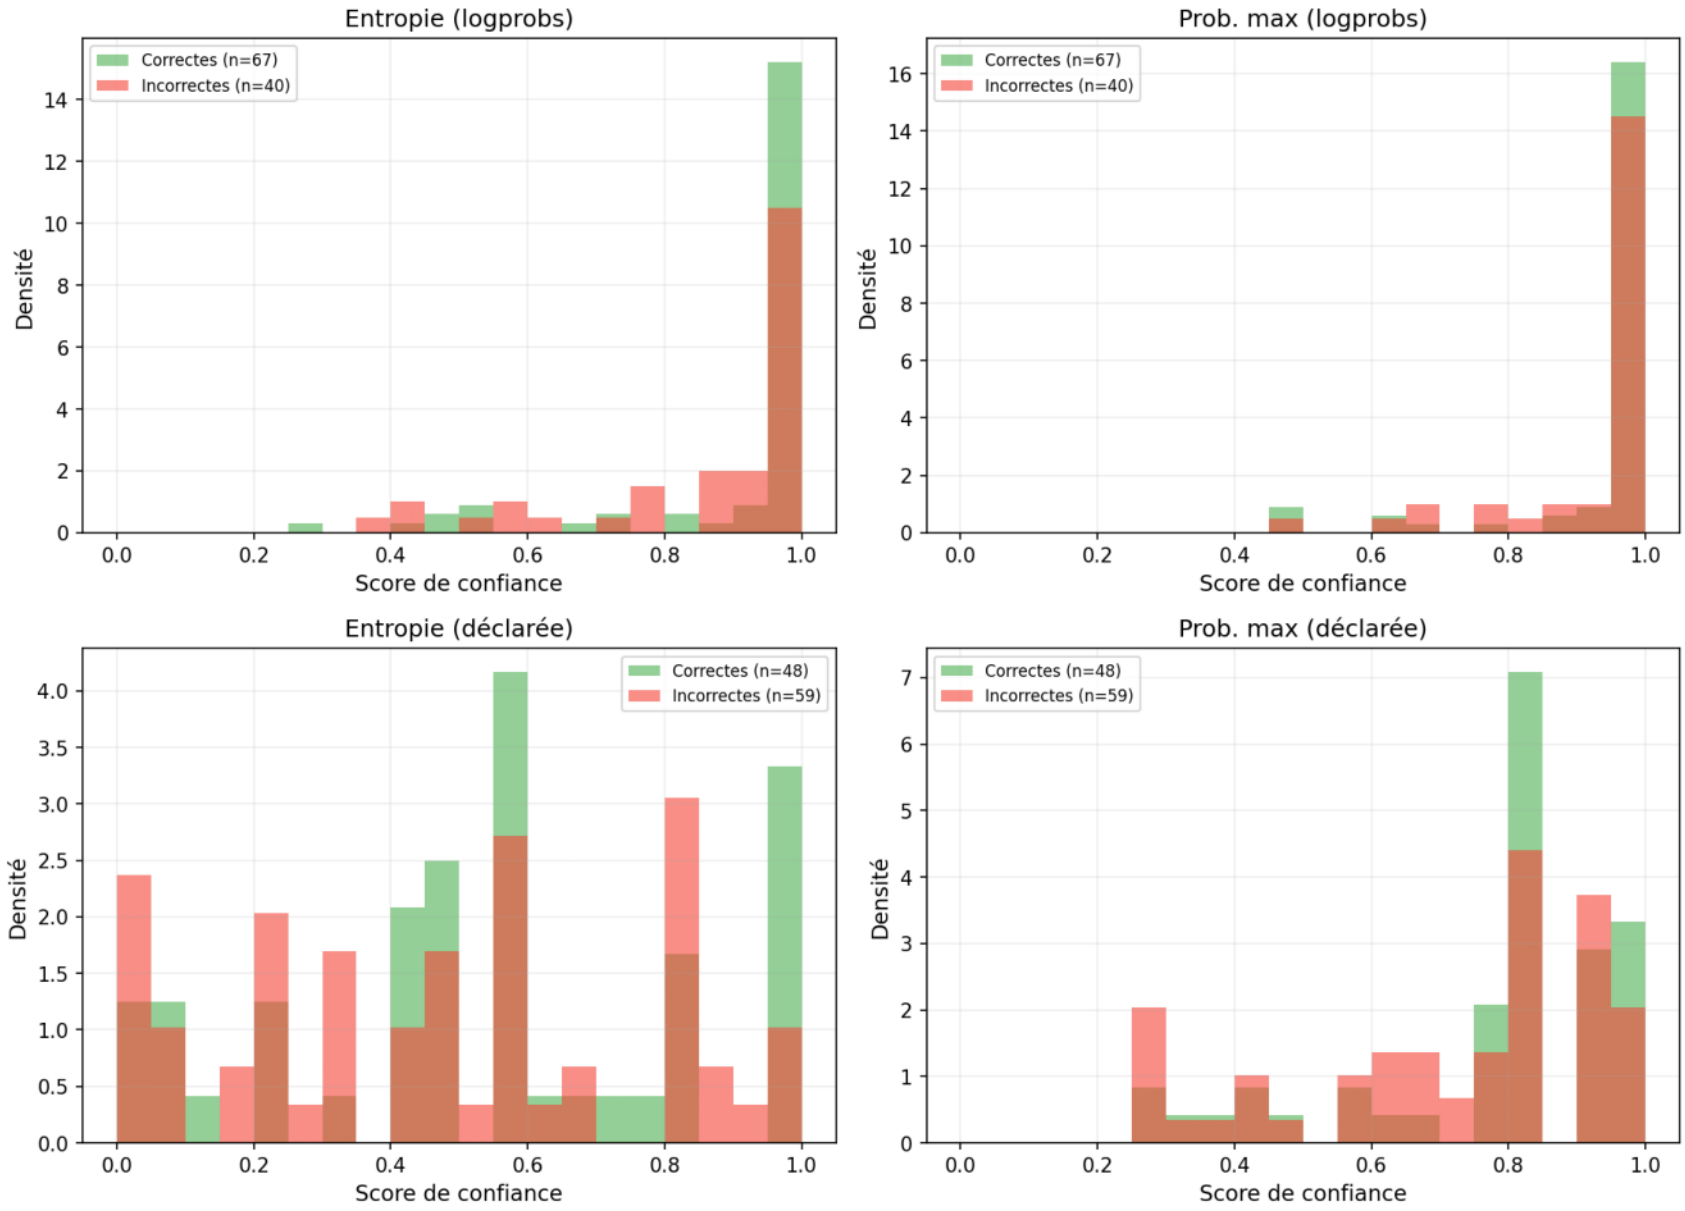

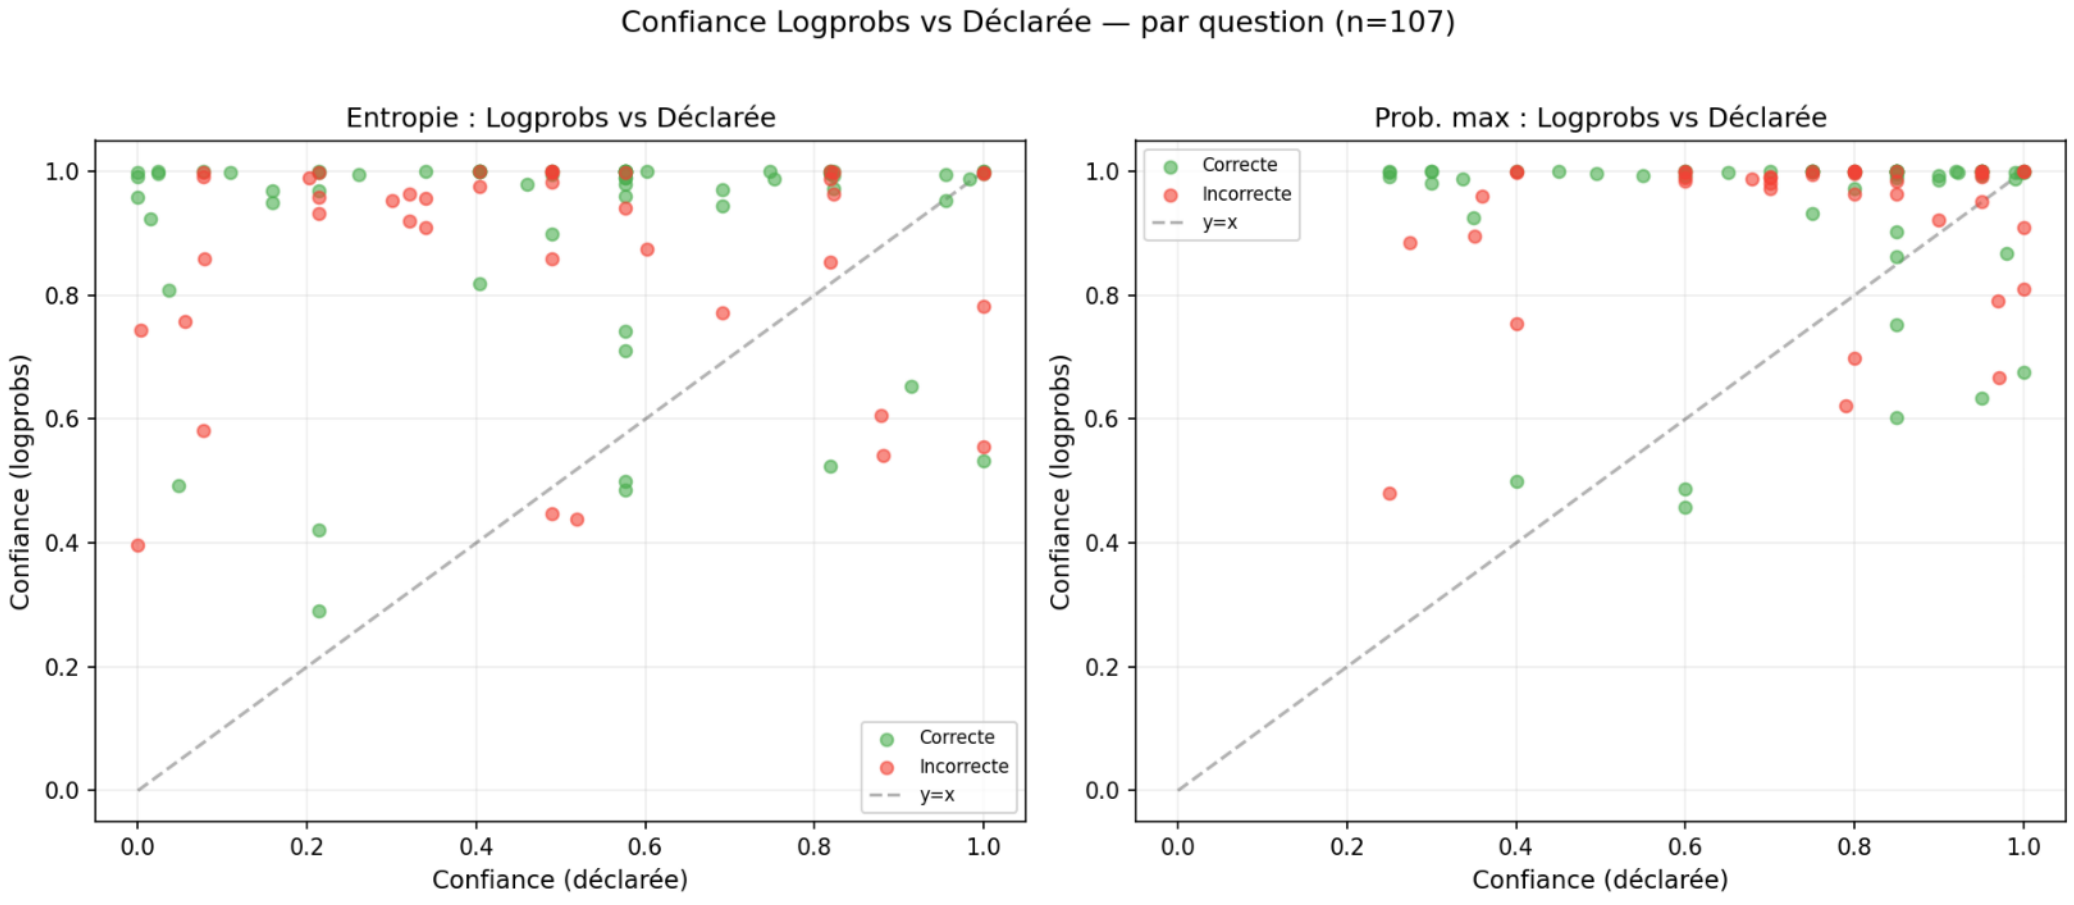
Confiance Logprobs vs Déclarée — par question (n=107)
Entropie : Logprobs vs Déclarée
Prob. max : Logprobs vs Déclarée
Confiance (logprobs)
Confiance (déclarée)
Correcte
Incorrecte
y=x
0.0
0.2
0.4
0.6
0.8
1.0

Tableau récapitulatif — Accuracy par signal (n=107)

Source	Signal	Acc. globale	Acc. top 50%	Acc. top 10%
Logprobs	Entropie	62.6%	75.9%	81.8%
Logprobs	Prob. max	62.6%	75.9%	81.8%
Déclarée	Entropie	44.9%	48.1%	72.7%
Déclarée	Prob. max	44.9%	50.0%	72.7%
Déclarée	Conf. brute	44.9%	51.9%	72.7%

Prédiction conforme — Résultats (n=107)

Méthode	α	Couverture	Taille moy.	Acc. top-1	q̂
lac	0.05	0.962	3.21	0.679	1.0000
aps	0.05	1.000	4.00	0.679	1.0000
lac	0.1	0.962	3.06	0.679	1.0000
aps	0.1	0.925	2.92	0.679	1.0000
lac	0.15	0.887	2.38	0.679	0.9999
aps	0.15	0.906	2.68	0.679	1.0000
lac	0.2	0.792	1.79	0.679	0.9985
aps	0.2	0.906	2.62	0.679	1.0000
lac	0.3	0.774	1.45	0.679	0.9910
aps	0.3	0.906	2.28	0.679	1.0000